

Doble Grado en Ingeniería Informática y ADE
2025-2026

Trabajo Fin de Grado

“Asistente de detección de enfermedades cerebrales con imágenes y datos médicos”

Ángela Morales Valverde

Tutor/es

Alfonso Alejandro Sánchez-Macián Pérez

María del Acebo Sánchez-Macián Pérez

Colmenarejo, febrero 2026

ÍNDICE GENERAL

RESUMEN	v
PALABRAS CLAVE	vii
ÍNDICE DE FIGURAS	viii
LISTA DE ABREVIATURAS	x
1. INTRODUCCIÓN	1
1.1. Motivación	1
1.2. Objetivos	1
1.3. Estructura	2
1.4. Metodología	2
1.5. Marco regulador	3
1.6. Entorno socio-económico	4
1.6.1. Presupuesto	4
1.6.2. Impacto socio-económico	6
2. MÉTODOS	8
2.1. Concepto de inteligencia artificial	8
2.1.1. Diferencia entre el IA, machine learning y el deep learning	8
2.1.2. Principales usos	9
2.2. Concepto de red de neuronas	10
2.2.1. Principios básicos de una red neuronal	10
2.2.2. Evolución histórica	12
2.2.3. Problemas clásicos	14
2.3. Tipos de redes neuronales	16
2.3.1. Fundamentos y redes pre-deep learning	16
2.3.2. Auge de la especialización	18
2.3.3. Arquitecturas de reconstrucción y generación	21
2.3.4. La revolución de la atención	24
2.3.5. Nuevos paradigmas y bio-inspiración	27
2.4. Aplicación de las Redes Neuronales en Medicina	27
2.4.1. Aplicaciones generales	27
2.4.2. Aplicaciones en diagnóstico por imagen	28
2.4.3. Arquitecturas clásicas aplicadas a imágenes médicas	29

2.4.4. Modelos específicos diseñados para imágenes médicas	30
2.4.5. Modelos multimodales aplicados a medicina	32
2.4.6. Modelos planteados para el presente trabajo	33
2.4.7. Aplicaciones de diagnóstico en enfermedades neurológicas	41
2.4.8. Reto de la explicabilidad	43
2.4.9. Retos éticos y regulatorios del uso de la IA en medicina	45
2.5. Limitaciones de los enfoques actuales	46
3. RESULTADOS	48
3.1. Estructura del desarrollo	48
3.2. Preparación de los <i>datasets</i> para el estudio.....	48
3.3. Métricas de evaluación de resultados.....	52
3.4. Entrenamiento de los modelos de deep learning	53
3.5. Evaluación de resultados de deep learning	56
4. CONCLUSIONES Y TRABAJOS FUTUROS.....	67
5. BIBLIOGRAFÍA	69
6. ANEXOS.....	1
6.1. Anexo A. Declaración del uso de IA	1
6.2. Anexo B. Declaración de originalidad.....	5

RESUMEN

El propósito de este trabajo es analizar, desarrollar y evaluar un sistema de ayuda al diagnóstico de enfermedades neurológicas mediante MRI, siendo capaz de clasificar entre siete clases diferentes. El enfoque central no es la obtención de métricas, sino que se pretende establecer un punto de partida para el estudio de este tipo de iniciativas en el entorno sanitario. Se quiere demostrar que se pueden obtener resultados explicables si se aprovechan las herramientas de explicabilidad disponibles.

Dentro del análisis, se ha hecho un procesamiento multiclase, entrenando los modelos para una clasificación compleja entre enfermedades. Se ha hecho un *benchmark* de cinco modelos con arquitecturas distintas dentro del ámbito del *deep learning*. Desde las redes convolucionales (CNN) clásicas hasta las últimas arquitecturas como son los *transformers*. Además, se ha incluido una parte fundamental referente a la explicabilidad de los resultados que arrojan los modelos, habiendo mostrado imágenes sobre qué se obtendría exactamente de estas técnicas. Esta práctica permite auditar las decisiones de los modelos, verificando si estos son coherentes o no.

En general, los resultados obtenidos por los modelos son buenos, aunque destacan principalmente dos de ellos, el EfficientNetB0 y el ConvNextLarge, ambos siendo CNN y obteniendo una precisión global por encima del 95%. En cuanto a la explicabilidad, los resultados obtenidos muestran que, con un entrenamiento de este tamaño, los modelos localizan mejor patologías más localizadas como tumores cerebrales que otras con áreas afectadas más difusas como puede ser el Alzheimer o el Parkinson.

La principal conclusión que se ha conseguido obtener es que hay un camino de investigación dentro de este ámbito de estudio, pudiendo aplicar técnicas avanzadas de inteligencia artificial dentro del sector médico, consiguiendo que sean entendibles e interpretables. Se ha conseguido establecer un punto de partida en el desarrollo de un asistente al diagnóstico para apoyar la labor de los profesionales sanitarios, acelerando así la detección de estas patologías y demostrando que se puede generar un gran impacto.

3. RESULTADOS

3.1. Estructura del desarrollo

En esta parte de desarrollo se hace un recorrido desde el punto de partida en el que se tiene que decidir de dónde se va a empezar el proyecto, eligiendo las características del *dataset* y de dónde sacarlo, hasta las conclusiones sobre los resultados finales obtenidos. Se pretende plasmar cómo, mediante la metodología elegida de CRISP-ML(Q) se consigue llevar a cabo el proyecto que se planteó en apartados anteriores. Esta estructura se puede ver reflejada de manera resumida en la Figura 26.




Figura 26. Planificación del desarrollo del proyecto.

3.2. Preparación de los *datasets* para el estudio

Para poder comenzar la parte de desarrollo, y tras haber hecho todo el análisis previamente comentado, se necesitaba partir de la búsqueda de los *datasets* que se usarían en la prueba de los modelos. Concretamente, se estaban buscando imágenes de resonancias magnéticas del cerebro (MRI) y que tuviesen una vista de corte axial del cráneo, viéndose estas representadas en escala de grises.

Teniendo en cuenta las enfermedades en las que se ha decidido poner el foco, de las cuales se ha hablado previamente, se establecen 7 clases de clasificación distintas, siendo esto una clase por enfermedad y añadiendo una clase para los cerebros sanos sin ninguna patología neurológica. De esta forma, no solo se pretende conseguir que se clasifique correctamente la enfermedad que se muestre en la imagen, sino que también ayuda a hacer una clasificación adicional entre sí se encuentra alguna patología o no. Se trata de conseguir que los modelos estén sesgados lo mínimo posible, no haciendo así que por defecto tenga que detectar una enfermedad. Esta decisión también favorece al escalado de este tipo de soluciones, ya que abarca más posibilidades de detección.

El obtener un *dataset* con un tamaño suficiente y que estuviese compuesto por unas imágenes de calidad no fue sencillo, ya que no hay *datasets* extensos de uso general de estas enfermedades, por lo que se tuvo que recurrir a obtener *datasets* distintos por cada

una de las enfermedades a estudiar. Todos ellos fueron obtenidos de Kaggle y se validó que se podrían usar para fines como el del presente trabajo.

- En este *dataset* se encuentran imágenes de distintas enfermedades, las cuales todas se utilizan en este trabajo. Por un lado, se tienen imágenes divididas en carpetas sobre tres distintas etapas de la progresión de la enfermedad de Alzheimer. Por otro lado, se tienen tres carpetas con las imágenes referentes a los tres tipos de tumores cerebrales estudiados y otra carpeta de la enfermedad de esclerosis múltiple. También se tiene una carpeta de control con imágenes de cerebros sanos. Todo este contenido se encontraba en formato JPG/PNG. Se puede ver un ejemplo en la Figura 27 [\[123\]](#).





Figura 27. Ejemplos de imágenes del dataset [\[123\]](#).

- En el caso del Parkinson, se encontró un *dataset* que va enfocado a la clasificación binaria de la enfermedad, diferenciando así entre si se padece la patología o no. Todo este contenido se encontraba en formato JPG/PNG. Se puede ver un ejemplo de estas imágenes en la Figura 28. [\[124\]](#).



(Parkinson)

(Sano)

Figura 28. Ejemplos de imágenes del *dataset* [124].

- En el caso de la enfermedad de esclerosis múltiple fue complejo poder encontrar imágenes, ya que los *datasets* contenían imágenes en formato de “.nii”, que es un formato médico para captar mejor los volúmenes. Se eligió un *dataset* que disponía de imágenes de muchos pacientes distintos, en los cuales se incluían diferentes vistas [125]. Para poder utilizar estas imágenes junto al resto, se cambiaron de formato las imágenes con un código desarrollado para ello, quedando como en el Figura 29 [126].





Figura 29. Ejemplo de las imágenes del *dataset* [126].

- En el caso de los distintos tumores cerebrales, se tuvo que recurrir a distintos *datasets* ya que se necesitaba más volumen de imágenes que el que se encontró en uno solo. En estos, se pueden apreciar distintas carpetas de imágenes dependiendo del tipo de tumor del que se trate, así como en algunos casos una extra de control con cerebros sanos. Todo este contenido se encontraba en formato JPG/PNG y se puede ver un ejemplo en la Figura 30. [127] [128] [129].



(Glioma)

(meningioma)

(tumor pituitario)

Figura 30. Ejemplos de imágenes del *dataset* [\[127\]](#) [\[128\]](#) [\[129\]](#).

Con todo esto, después de haber limpiado las imágenes que no tuvieran buena resolución o el corte axial del cerebro que se quiere estudiar, se consiguen siete clases de clasificación distintas, una por cada enfermedad más la de los cerebros sanos. En este punto, se pasó a una fase en la que se decidió adaptar el *dataset* final obtenido a las características particulares de cada uno de los modelos que se quería evaluar, configurando así aspectos como la resolución de la imagen o la normalización que se hacía de la misma. Se decidió dedicar el 70% de las imágenes a entrenamiento, el 15% a validación y el 15% restante a test [\[130\]](#).

De esta forma se consiguió adaptar el *dataset* base a los distintos modelos haciendo transformaciones deterministas y no estadísticas, garantizando así que las imágenes resultantes tienen un significado físico e interpretable. Gracias a hacerlo de esta forma, se puede usar el mismo *dataset* base para todos los modelos, independientemente de que luego tengan arquitecturas o configuraciones particulares. Para tratar de evitar sesgos derivados del orden y disposición del *dataset* base, se hace un barajado explícito antes de dividir las imágenes.

Al estar obteniendo las imágenes de las enfermedades de distintas fuentes, podía darse el caso de que hubiese imágenes repetidas, lo que podía influir negativamente en los resultados del modelo. Este hecho podría causar que los modelos aprendan artificios de las imágenes en vez de las características clínicas relevantes de estas. Para tratar de reducir este riesgo al máximo, y al no poder decidir en base de las imágenes ya que variaba según la fuente, se decidió hacer una comparación de los *hashes* de las imágenes, evitando así que hubiese duplicados y obteniendo un conjunto de *dataset* final más pulido [\[130\]](#).

Esta manera de proceder, aun así, incurre en la aparición de un posible sesgo o leakage en el conjunto de *dataset* final a usar y, aunque se conocía este riesgo, se decidió seguir el estudio con ello y evaluar los resultados que se obtuvieron teniendo esto en cuenta. Este sesgo aparecía por el hecho de que, las imágenes de los cerebros están divididas en capas o *slices*, pero no se pueden detectar y separar las *slices* que pertenecen al mismo paciente en algunos *datasets*. Esto causa que puedan existir *slices* del mismo paciente en diferentes particiones, generando así esa fuga de información entre los datos de

entrenamiento, validación y test. Esta casuística causa que haya modelos de los estudiados que, en vez de aprender de las características clínicas más relevantes, se estén viendo influenciados y aprendiendo sobre artefactos concretos de las imágenes y/o el formato de estas. Aunque este es un riesgo esperado y controlado dentro de las posibilidades, es importante mencionar que por el objetivo del presente estudio que se está realizando, no es crítico y permite realizar un desarrollo bastante enfocado.

Con estos *datasets* finales, se pasa a una fase en la que se pretende que los distintos modelos sepan clasificar correctamente las imágenes en sus clases correspondientes.

3.3. Métricas de evaluación de resultados

Para poder analizar los modelos evaluados, hay que tener en cuenta una serie de métricas que se van a poder obtener de cada uno de los modelos ejecutados y con las que se va a evaluar su desempeño.

Por un lado, se tiene un informe de clasificación, el cual tiene distintas métricas que resultan de gran utilidad. Una de ellas es la **precisión**, que es la calidad de las predicciones positivas que se hacen, es decir, cuántas de las predicciones hechas eran correctas. Otra de ellas es la sensibilidad o exhaustividad (**recall**) que tengan los modelos, que indica la cantidad total de positivos que el modelo encontró. Puede parecer parecido a la precisión, pero en este caso se trata de, entre todos los positivos que existan, saber cuántos se lograron detectar. Esta métrica es importante ya que el coste de un falso negativo es especialmente alto cuando se trata de detectar enfermedades como las que se están estudiando.

Una vez que se tienen estas dos métricas, se puede obtener el **F1-score**, que es la combinación en medida de la media armónica entre las dos métricas anteriores. Sirve para equilibrar la visión global que se obtiene del resultado. Adicionalmente se muestra el soporte que tan solo indica el número real de ocurrencias de la clase en el set de datos, con lo cual entre todos los modelos debería ser el mismo. Si este valor está muy desbalanceado entre las clases, puede indicar que los resultados no serán muy confiables.

Al final de este informe, se añaden además tres métricas adicionales. La primera de ellas es la exactitud o *accuracy*, la cual indica el porcentaje total de aciertos, aunque es útil, no es una métrica suficiente para poder basarse solo en ella ya que depende del contexto del estudio que se esté haciendo. La segunda de ellas es el *macro average* que se calcula a partir del cálculo de la métrica para cada clase y saca el promedio simple, tratando todas las clases por igual. La tercera, y relacionada con la segunda, es el *weighted average* que calcula el promedio teniendo en cuenta el número de soporte de cada clase. Las clases con más ejemplos pueden tener más peso en el resultado final que se obtenga.

Por otro lado, se tiene la matriz de confusión de la clasificación entre las clases en la fase de test por parte de cada uno de los modelos. Básicamente esta matriz enfrenta lo que se predijo frente a la realidad, teniendo en el eje Y los valores reales y en el eje X las

predicciones del modelo. Con ella podemos ver entre qué clases se está equivocando el modelo, pudiendo así estudiar si tiene sentido o indica un posible fallo de entrenamiento.

3.4. Entrenamiento de los modelos de deep learning

Para poder desarrollar el entrenamiento y, pese a que se trata de un proceso de *fine-tuning*, se tiene una gran necesidad computacional. Se creó un notebook de Google Colab [\[131\]](#) en el que se fueron poniendo cada uno de los modelos pero, al tener esta necesidad computacional, ejecutarlo en local no era una opción ya que no se disponía de un equipo suficiente en el que no se llegara al tiempo máximo de ejecución de la versión gratuita del Colab.

Se solicitó el uso de entornos de ejecución de investigación a través de la universidad, consiguiendo acceso durante 3 meses a una GPU NVIDIA H200. Gracias a disponer de este equipamiento, se pudieron ejecutar los distintos modelos sin problemas, obteniendo los resultados que se van a pasar a comentar en el siguiente apartado.

El planteamiento inicial que se dio a este trabajo fue de trabajar sobre cinco modelos con características distintas que pudiesen proporcionar conclusiones distintas. Se empezó decidiendo usar el ResNet, ya que es ampliamente usado cuando se trata de clasificación médica, al que posteriormente se le sumó el DenseNet para poder comparar. Como versión más optimizada de CNN se decidió incorporar el EfficientNet y evaluar si esa optimización se notaba también en los resultados que se obtuviesen. Adicionalmente se querían añadir algunos modelos que estuviesen especialmente enfocados en el área médica y en la segmentación médica, y se eligieron el modelo de Google con imágenes médicas el Med-Gemma y el nnU-Net que destaca para segmentación.

Con todos ellos se pretendía hacer un ejercicio de *fine-tuning* y así poder hacer un estudio más específico y adaptado al conjunto de *dataset* que se había creado. Para poder hacer esto, se buscaron una serie de pesos de los modelos ResNet50 y DenseNet121 que estuvieran preentrenados con imágenes médicas, concretamente con RadImageNet [\[83\]](#). En el caso de EfficientNet, se optó por usarlo preentrenado con *ImageNet* y medir así posibles variaciones. Estas variaciones vendrían dadas por el hecho de que usando el modelo de esa forma, no estaría preentrenado tan solo con imágenes del contexto médico, sino que tendría distintos tipos de imágenes, estando así menos focalizado en la tipología de las imágenes que iba a recibir.

En el caso de los modelos de Med-Gemma y de nnU-Net, no se consiguió obtener estos pesos iniciales con los que poder hacer *fine-tuning* ya que no están disponibles públicamente. Pese a que se evaluaron distintas formas de seguir usándolos, al final se desistió con su evaluación ya que no se disponía de una forma viable que pudiese equipararse a los otros modelos que ya se estaban evaluando.

Como se ha comentado, para entrenar los modelos se creó un Google Colab en la que se fueron introduciendo las distintas partes de los modelos para su posterior ejecución.

El desarrollo comenzaba con la importación e instalación de las librerías necesarias, así como la configuración general de cada uno de los modelos. En esta parte es en la que se establecen los parámetros de entrenamiento como el número de *epoch* o los distintos directorios a los que necesita acceder. Posteriormente se configuran los generadores de datos para poder utilizarlos, en los que en la parte de *train* se hace un *shuffle* explícito para evitar así posibles sesgos del modelo.

- ResNet50
 - Se carga el modelo con los pesos que se han obtenido gracias a RadImageNet [\[83\]](#), pudiendo así hacer *fine-tuning* con las imágenes de MRI que se están estudiando en este proyecto.
 - Se añade la cabeza en la que se fija un *dropout* del 30% para evitar el sobreajuste y una capa “Dense” con función de activación *softmax* para hacer la clasificación.
 - Se añade una parte en la que se quiere conseguir adicionalmente la métrica de F1-Macro para poder obtener unas conclusiones más precisas.
 - Hay un bloque que trabaja los callbacks, que es donde se producen las siguientes acciones:
 - El guardado de *checkpoints*.
 - El *EarlyStopping*, que hace que si la validación empeora 3 *epochs* seguidos se pare el entrenamiento.
 - Se genera la matriz de confusión y el *heatmap* que arroja el Grad-CAM.
 - Se registran todos los *logs* para su posterior tratamiento y así poder obtener gráficas sobre el desarrollo del entrenamiento.
 - Con todo esto, cuando se termina el entrenamiento, se prueba con la parte de test, viendo así el rendimiento del modelo. Se guardan los pesos finales que se han obtenido, así como un reporte detallado con las métricas que se obtienen y la matriz de confusión final.
- DenseNet121
 - La estructura de este modelo es prácticamente idéntica a la del ResNet50, teniendo en cuenta que se cargan los pesos también de RadImageNet [\[83\]](#).
- EfficientNetB0
 - La estructura de este modelo vuelve a ser similar a la de los anteriores, pero con una característica diferencial. En lugar de cargar los pesos de RadImageNet, en este caso se usa ImageNet. Esto podría suponer un punto

de partida teóricamente peor que los demás modelos, aunque se demostrará que no es así.

Al comenzar a hacer pruebas en el entorno de ejecución, se vio su gran capacidad computacional, por lo que se decidieron añadir dos modelos nuevos que aportan nuevas visiones en cuanto al tipo de modelos que son. Dichos modelos son concretamente el ConvNextLarge, como CNN mejorada para competir con *transformers*, y ViT, un *transformer*.

- ConvNextLarge
 - Este modelo está entrenado de manera mucho más precisa y optimizada, tratando de aprovechar al máximo los recursos de la GPU H200. Se usa “*mixed_float16*”, que hace que los cálculos se realicen en 16 bits, manteniendo variables críticas en 32 bits. Con eso se consigue un entrenamiento más rápido, aunque la última capa se fuese a que sea de 32 bits para evitar errores.
 - Usa también *ImageNet* en vez de *RadImageNet*.
 - Su entrenamiento tiene dos partes. La primera de ellas sirve para entrenar lo que sería una cabeza nueva, haciendo así que el conocimiento previo no se pierda. La segunda es en sí ya llevar a cabo el *fine-tuning* con las imágenes que se tenían, utilizando un *learning rate* muy bajo.
 - Con este modelo sí que se llevan a cabo transformaciones en las imágenes con “*train_datagen*”, permitiendo así que el modelo soporte mejor el ruido y no aprenda de los artefactos de estas.
 - Se sustituye Grad-CAM por Layer-CAM ya que esta permite proporcionar una explicabilidad mejorada.
- ViT
 - Hay que tener en cuenta que este modelo es un *transformer*, no una CNN como lo eran los anteriores. Coge la imagen de 224x224 y la divide en *patches* de 16x16, teniendo un total de 196. El modelo va tratando las imágenes con Atención Global, tratando así de reconocer relaciones entre los *patches* que ha sacado.
 - Este modelo, en vez de estar entrenado con *ImageNet*, lo está con ImageNet-21k, habiendo pasado así de conocer 1.000 clases a 21.000.
 - En este caso, se utilizan tres funciones de activación distintas, dependiendo en qué fase se esté.

- En el *backbone*, la base del modelo se utiliza GELU ya que tiene una curvatura más suave que ReLu, no cortando en seco valores negativos.
 - En la capa “*Dense*” se utiliza ReLu ya que es el estándar en las capas intermedias por ser menos costosa computacionalmente a la par que efectiva.
 - En la capa de salida se usa la función *softmax* para convertir los números en probabilidades entre las 7 clases.
- Este modelo también entrena en dos fases, por un lado, se entrena la cabeza y por otro lado se hace el *fine-tuning*. Una característica de este proceso de entrenamiento es que se usa una *learning rate* muy baja, tratando así de no influir bruscamente en su conocimiento preentrenado.
 - El ViT está diseñado con HuggingFace/PyTorch, que requiere las imágenes en (canales, alto y ancho), pero el TensorFlow usa (alto, ancho, canales), por lo que hay una función “*Permute*” que hace de traductor. Por otro lado, el modelo devuelve un objeto con mucha información y la capa “*Lambda*” hace de filtro para el Keras para quedarse solo con las características principales, almacenadas en “*last_hidden_state*”.
 - En cuanto a la explicabilidad se utiliza *Attention Rollout* que accede a las matrices de atención del modelo, combina las de todas las capas y muestra un *heatmap* que representa en qué *patches* concretos está mirando el *CLS Token*, que es el nodo que toma la decisión final. Al final de cada *epoch* se llama a una función *callback* que muestra este *heatmap*.

Con los resultados de cinco modelos se consiguió una visión muy amplia ante CNN, arquitecturas modernas y *transformers*, viéndose sólo limitada por la falta que se ha comentado de modelos médicos especializados.

3.5. Evaluación de resultados de deep learning

Una vez que se ejecutaron los modelos, de cada uno de ellos se sacó el informe de clasificación de la parte del test y la matriz de confusión entre las distintas clases que se estaban evaluando en dicho test [\[132\]](#).

Se va a pasar a comentar cada uno de los cinco modelos evaluados teniendo en cuenta que se ha señalado los valores en los que se considera que hay especial relevancia. En las tablas del informe de clasificación, se ha marcado con un color verde claro los datos que superan el 90%, considerándose así buenos, y en un verde más intenso aquellos valores que superan el 95% por ser especialmente buenos. También, en las matrices de confusión, se ha resaltado en rojo intenso cuando los modelos se equivocan excesivamente en la clasificación, habiendo establecido el límite en diez o más errores para un error grave, y cualquier valor inferior se considera error leve y está indicado en un rojo claro.

Para la facilidad de visualización de las tablas, se ha abreviado el nombre de las enfermedades en Alzheimer (A), Esclerosis Múltiple (ES), Glioma (G), Meningioma (M), Parkinson (PA), Pituitaria (PI) y Sano (S).

Conclusiones generales

ResNet					DenseNet				
	Precisión	Recall	F1-Score	Support		Precisión	Recall	F1-Score	Support
Alzheimer	0,93	0,94	0,93	480	Alzheimer	0,88	0,95	0,91	480
Esclerosis múltiple	0,91	0,88	0,9	688	Esclerosis múltiple	0,87	0,88	0,87	688
Glioma	0,95	0,87	0,9	617	Glioma	0,91	0,83	0,87	617
Meningioma	0,86	0,83	0,84	546	Meningioma	0,76	0,73	0,74	546
Parkinson	0,92	0,96	0,94	681	Parkinson	0,9	0,91	0,91	681
Pituitaria	0,91	0,97	0,94	511	Pituitaria	0,85	0,93	0,89	511
Sano	0,84	0,89	0,86	618	Sano	0,82	0,79	0,8	618
Accuracy	-	-	0,9	4141	Accuracy	-	-	0,86	4141
Macro avg	0,9	0,9	0,9	4141	Macro avg	0,86	0,86	0,86	4141
Weighted avg	0,9	0,9	0,9	4141	Weighted avg	0,86	0,86	0,86	4141

(a)

(b)

EfficientNet				
	Precisión	Recall	F1-Score	Support
Alzheimer	0,95	0,97	0,96	480
Esclerosis múltiple	0,98	0,99	0,98	688
Glioma	0,99	0,97	0,98	617
Meningioma	0,96	0,99	0,98	546
Parkinson	1	1	1	681
Pituitaria	0,99	0,99	0,99	511
Sano	0,96	0,94	0,95	618
Accuracy	-	-	0,98	4141
Macro avg	0,98	0,98	0,98	4141
Weighted avg	0,98	0,98	0,98	4141

(c)

ConvNetLarge					ViT				
	Precisión	Recall	F1-Score	Support		Precisión	Recall	F1-Score	Support
Alzheimer	0,9874	0,9812	0,9843	480	Alzheimer	0,91	0,97	0,94	480
Esclerosis múltiple	0,9956	0,9826	0,989	688	Esclerosis múltiple	0,9	0,89	0,9	688
Glioma	0,9951	0,987	0,991	617	Glioma	0,93	0,88	0,91	617
Meningioma	0,9854	0,9872	0,9863	546	Meningioma	0,86	0,86	0,86	546
Parkinson	0,9956	1	0,9978	681	Parkinson	0,92	0,91	0,92	681
Pituitaria	0,9942	1	0,9971	511	Pituitaria	0,92	0,95	0,94	511
Sano	0,9713	0,9871	0,9791	618	Sano	0,87	0,87	0,87	618
Accuracy	-	-	0,9894	4141	Accuracy	-	-	0,9	4141
Macro avg	0,9892	0,9893	0,9892	4141	Macro avg	0,9	0,91	0,9	4141
Weighted avg	0,9894	0,9894	0,9894	4141	Weighted avg	0,9	0,9	0,9	4141

(d) (e)

Figura 31. Resultados del informe de clasificación de los modelos.

En la Figura 31 se muestran las distintas métricas para cada uno de los modelos evaluados en cada una de las enfermedades que se trata de clasificar. Se puede observar a simple vista que los modelos que han obtenido métricas generales muy buenas son el EfficientNet y el ConvNextLarge, teniendo prácticamente todos sus valores por encima del 95%. Esto indica que a estos modelos no les cuesta clasificar las imágenes correctamente.

También se aprecia en la Figura 31 (b) que en el caso del modelo DenseNet sí que le cuesta más clasificar las imágenes, teniendo valores en sus métricas incluso por debajo del 70%. Los modelos ResNet y ViT tienen buenos resultados, aunque muestran un margen de mejora en su clasificación.

Precision		Recall		F1 - Score	
AVG Precision A	0,93	AVG Recall A	0,96	AVG F1-Score A	0,94
AVG Precision ES	0,93	AVG Recall ES	0,92	AVG F1-Score ES	0,93
AVG Precision G	0,96	AVG Recall G	0,91	AVG F1-Score G	0,93
AVG Precision M	0,89	AVG Recall M	0,88	AVG F1-Score M	0,88
AVG Precision PA	0,95	AVG Recall PA	0,96	AVG F1-Score PA	0,95
AVG Precision PI	0,93	AVG Recall PI	0,97	AVG F1-Score PI	0,95
AVG Precision S	0,89	AVG Recall S	0,90	AVG F1-Score S	0,89

Figura 32. Comparativa de métricas medias entre modelos por enfermedad.

Por otra parte, se ha querido estudiar para cuál de las enfermedades estudiadas se consiguen métricas promedio mejores, y esto es precisamente lo que se recoge en la Figura 32.

Se aprecia que en general, para todas las enfermedades, se consiguen resultados buenos, teniendo gran parte de los mismos por encima del 90%. Esto muestra que en general hay una buena capacidad de clasificación por parte de los modelos.

Las enfermedades que mejor se identifican son las de PA, referente al parkinson, y PI que se trata del tumor de pituitaria. Dentro de la clase del Parkinson se puede destacar que sus métricas están muy equilibradas, y en cuanto al tumor de pituitaria, destaca su Recall con un valor del 97% indicando que los modelos prácticamente nunca pasan por alto imágenes que pertenecen a esta clase. Se puede apreciar que las clases del tumor de meningioma y de los cerebros sanos tienen bastante margen de mejora, teniendo por lo general valores por debajo del 90%.

Con todos estos resultados, se observa que son coherentes tanto desde la parte técnica como desde la parte clínica. Las clases con un mayor rendimiento general hacen referencia a enfermedades que tienen características más representativas, por lo que puede ser más sencillo para los modelos el detectarlas correctamente. Por ejemplo, el tumor pituitario tiene una ubicación concreta, lo cual lo hace más sencillo de identificar.

Por otro lado, las dos clases con menor rendimiento, los sanos y con meningioma, poseen unas características que hacen que sean más fácilmente confundibles. El meningioma puede confundirse con algunos tipos de gliomas o con otras patologías, y en el caso de los cerebros sanos lo que puede estar pasando es que los modelos se confunden buscando alguna patología arrojando así falsos positivos. Esto puede estar pasando porque las características patológicas sean en algunos casos muy sutiles o porque las imágenes no tengan la mejor calidad posible y hagan que aparezca un sesgo en la clasificación.

ResNet								DenseNet							
	A	ES	G	M	PA	PI	S		A	ES	G	M	PA	PI	S
A	449	0	0	0	0	0	31	A	454	0	0	0	0	0	26
ES	0	608	2	2	45	4	27	ES	0	604	4	10	37	1	32
G	0	5	534	53	3	9	13	G	0	9	511	70	7	9	11
M	0	5	22	452	4	38	25	M	1	10	29	396	4	75	31
PA	0	21	1	2	655	0	2	PA	0	46	2	3	620	2	8
PI	0	0	2	11	0	497	1	PI	0	0	8	26	1	475	1
S	36	30	3	5	8	0	536	S	58	24	9	19	19	0	489

(a) (b)

EfficientNet							
	A	ES	G	M	PA	PI	S
A	466	0	0	0	0	0	14
ES	0	678	0	1	0	0	9
G	0	0	600	16	0	1	0
M	0	0	3	541	0	2	0
PA	0	1	0	1	678	0	1
PI	0	0	1	4	0	506	0
S	23	12	1	0	1	0	581

(c)

ConvNetLarge								ViT							
	A	ES	G	M	PA	PI	S		A	ES	G	M	PA	PI	S
A	471	0	0	0	0	0	9	A	465	0	0	0	0	0	15
ES	0	676	0	0	3	0	9	ES	0	614	2	3	35	2	32
G	0	0	609	8	0	0	0	G	0	5	546	52	6	4	4
M	0	1	3	539	0	3	0	M	0	4	25	467	2	37	11
PA	0	0	0	0	681	0	0	PA	0	39	3	1	623	0	15
PI	0	0	0	0	0	511	0	PI	0	0	4	15	4	488	0
S	6	2	0	0	0	0	610	S	44	19	5	6	7	0	537

(d)

(e)

Figura 33. Resultados de las matrices de confusión de los modelos.

La Figura 33 representa los errores de clasificación que han tenido los distintos modelos evaluados. Como se podría ver con las métricas comentadas anteriormente, la mayor parte de las clasificaciones erróneas provienen de las clases de cerebro sano y meningioma. Pese a eso, hay modelos que se equivocan en la clasificación considerablemente más que otros.

En cuanto a sobre qué enfermedades son las que se están confundiendo en la clasificación, se sacan las siguientes conclusiones generales:

- Las imágenes de la enfermedad de Alzheimer se confunden en exclusiva con los cerebros sanos. En etapas iniciales de la enfermedad es común confundir esta enfermedad con un cerebro sano, ya que la enfermedad está provocada por una atrofia en áreas específicas que hace que se pierda volumen. Esto mismo puede pasar con el propio envejecimiento del cerebro, por lo que en algunos casos puede ser difícil diferenciar si se trata de un envejecimiento normal o el desarrollo de esta enfermedad en etapas iniciales.

- La enfermedad con la que más se confunde la esclerosis múltiple es el Parkinson, seguido por la clase de cerebros sanos. Es relativamente frecuente que se confundan las imágenes de cerebros con esclerosis múltiple con cerebros sanos ya que a veces es complejo detectar las lesiones provocadas por la enfermedad.
- Como se ha comentado anteriormente, el meningioma y el glioma se suelen confundir a la hora del diagnóstico, viéndose este hecho reflejado también la Figura 33. Destaca especialmente el caso de la confusión entre el meningioma con el tumor pituitario, ya que el número de errores es significativamente alto.
- La enfermedad con la que más se confunde el Parkinson es con la esclerosis múltiple, aunque también hay casos en los que se confunde con cerebros sanos. Aunque clínicamente no se confundan tanto, tiene sentido que los modelos las confundan debido a posibles artefactos de las imágenes que condicionen el diagnóstico y generen estos falsos positivos. También, en etapas avanzadas de ambas enfermedades, se pueden mostrar atrofas en la estructura del cerebro, lo que puede hacer que se malinterpreten los resultados.
- El tumor de pituitaria se suele confundir principalmente con los otros dos tipos de tumores cerebrales evaluados, principalmente con el meningioma pero también con el glioma.
- Los cerebros sanos se confunden mayoritariamente con la enfermedad de Alzheimer y con la esclerosis múltiple.

SUMA -->	Error grave	Error leve	Total
ResNet	352	56	408
DenseNet	523	67	590
EfficientNet	65	22	87
ConvNextLarge	0	44	44
ViT	339	62	401

Figura 34. Errores totales por modelo evaluado.

Como se puede observar en la Figura 34, el modelo Densenet tiene el peor rendimiento general por tener el mayor número de errores clasificando. En un punto medio se encontraría el ResNet y el ViT, con un número de errores similar. Este dato es relevante ya que el ViT no supera en rendimiento a los modelos convolucionales, habiéndose esperado que fuese un mayor competidor en cuanto a rendimiento. Esto puede deberse a la alta heterogeneidad de las imágenes del *dataset*, el número limitado de imágenes de las que se dispone y un sesgo ya comentado en cuanto a la distribución de las imágenes. Esto puede haber causado que el modelo ViT tuviese mayores problemas para generalizar, causando estos resultados peores que los esperados. Finalmente, los modelos EfficientNet y ConvnextLarge muestran resultados mucho mejores al tener un número de errores totales bastante inferior al resto.

Esta comparativa no es del todo justa ya que el modelo de ConvNextLarge ha sido entrenado por más epoch que el resto de los modelos, con lo cual era esperable que

arrojase resultados mejores. Los modelos de CNN tienen un *fine-tuning* con 10 *epoch*, mientras que en el caso de este modelo comentado se trataba de 5 *epoch* para entrenar la cabeza y 20 para hacer *fine-tuning*. Esto se quería hacer para ver la gran capacidad que muestra este modelo y demostrar que es competidor directo de los *transformers* actuales en cuanto a rendimiento. Por ello, de igual forma, se quería profundizar en las capacidades de los *transformers*, al ser estos el estado del arte actual, habiendo hecho el doble de *epoch*, es decir 20 en total, repartidos en 10 para la cabeza y 10 de *fine-tuning*.

Para sacar una visión más justa de la comparativa de los modelos, cuando el ConvNextLarge había hecho los 5 *epoch* para la cabeza, tenía las siguientes métricas, teniendo en cuenta que son las de entrenamiento.

Accuracy	F1-macro	Loss	Val Accuracy	Val F1-macro	Val loss
0,8854	0,8839	0,3048	0,8838	0,8821	0,2969

Figura 35. Métricas del ConvNextLarge en los 5 *epoch* de entrenamiento de la cabeza.

Cuando había realizado los 10 primeros *epochs* de *fine-tuning*, las métricas que se tenían eran las siguientes.

Epoch	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
5	0,9874	0,9869	0,0334	0,9708	0,9698	0,098
10	0,9964	0,9962	0,0115	0,9795	0,9788	0,0893

Figura 36. Métricas del ConvNextLarge en los 10 primeros *epoch* de *fine-tuning*.

De igual forma, en la Figura 37 se muestran los resultados de las métricas obtenidas en el caso del modelo ViT cuando había realizado 10 y 20 *epochs*.

Epoch	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
10	0,8914	0,8930	0,3046	0,8887	0,8900	0,3038
20	0,9053	0,9066	0,2716	0,8969	0,8978	0,2893

Figura 37. Métricas arrojadas por ViT en los primeros 10 y 20 *epoch*.

Para ahora poder comparar los resultados de las métricas de los entrenamientos de los distintos modelos, se han recogido dichas métricas tras los 10 *epoch* en la Figura 38. Para

ello, en los modelos de ConvNextLarge y ViT se han contado los *epoch* dedicados al entrenamiento de la cabeza.

Modelo	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
ResNet	0,9134	0,9113	0,2279	0,8928	0,8868	0,3064
DenseNet	0,8265	0,8263	0,4724	0,8515	0,8501	0,3919
Efficient Net	0,9827	0,9821	0,0498	0,9754	0,8747	0,076
ConvNext Large	0,9874	0,9869	0,0334	0,9708	0,9698	0,098
ViT	0,8914	0,8930	0,3046	0,8887	0,8900	0,3038


Figura 38. Desempeño de los 5 modelos tras 10 *epoch*.

Teniendo ahora una visión de cómo se encontraban los cinco modelos exactamente cuándo llevaban 10 *epoch* de entrenamiento, se observa que se llega al mismo resultado que el que se comentaba al inicio de esta sección, confirmando así que el hecho de tener distinto número de *epoch* los dos últimos modelos no ha sesgado los resultados.

También, como conclusión, también se puede observar que el hecho de haber decidido entrenar más los modelos más modernos, ConvNextLarge y ViT, no ha hecho que sus resultados aumenten con respecto a las métricas que arrojaban en la Figura 38.

Explicabilidad

Como se ha comentado anteriormente, la explicabilidad dentro de los resultados que arrojan los modelos empleados para la ayuda al diagnóstico es crucial, por lo que se han empleado este tipo de técnicas en los modelos evaluados. En las siguientes figuras se aprecian los resultados del Grad-CAM de tres de los modelos evaluados sobre las enfermedades del meningioma en la Figura 39 y del Alzheimer en la Figura 40.



(ResNet)

(DenseNet)

(EfficientNet)

Figura 39. Resultados del *heatmap* del Grad-CAM para el meningioma.

Como se aprecia en las imágenes de la Figura 39 por los colores rojizos, el modelo que más acierta en localizar el tumor es el EfficientNet, mientras que en el caso de los otros dos modelos está más disperso. El DenseNet sí que consigue localizar el tumor, aunque también se centre en otras zonas sanas, pero en el caso del ResNet ni se consigue detectar dónde está ubicada la patología.




Figura 40. Resultados del *heatmap* del Grad-CAM para el Alzheimer.

En la Figura 40 se ven las regiones marcadas del *heatmap* en los distintos modelos, siendo los resultados obtenidos a partir de imágenes distintas. Se supone que las áreas más rojizas es donde los modelos identifican que se encuentra la patología. Aunque a simple vista no es fácil determinar dónde está la enfermedad, cómo sí se podría hacer en el ejemplo anterior, se pueden usar las métricas de precisión para determinar si se ha localizado bien o no. Observando las imágenes de la Figura 40 de izquierda a derecha, se puede apreciar que cuanto más dispersa sea la zona que muestra, menos precisión en la localización tiene. Por ello, la figura referente al modelo EfficientNet es la que consigue, de nuevo, detectar la patología y localizarla con la mayor exactitud.




Figura 41. Ejemplo conseguido de salida del Attention Rollout con ViT

En el caso de los transformers, como es el caso del ViT, en vez de usar Grad-CAM se usa *Attention Rollout*, que genera un *heatmap* sobre la imagen, pero basándose en la estructura de patches de este tipo de modelos. Se puede ver un ejemplo de esto en la Figura 41.

En esta figura lo que está buscando el modelo son signos de atrofia, que son los patrones que va causando la enfermedad de Alzheimer. Ésta, suele detectarse en los ventrículos laterales, que están a los lados de la zona más oscura del medio, y en la corteza temporal. Estas áreas son las que están comprendidas dentro del rectángulo rojo de la Figura 42.




Figura 42. Ejemplo conseguido de salida del *Attention Rollout* con ViT

El color celeste indicaría que el modelo tiene una mayor activación al lado de los ventrículos, lo que tendría sentido ya que con esta enfermedad estos se expanden por la pérdida de tejido cerebral circundante. También se aprecia que ese mismo color está en los bordes del cerebro, por lo que se está detectando un ensanchamiento de los surcos cerebrales. También se aprecia que las características que detecta no son simétricas, lo que es común en etapas iniciales o moderadas de la enfermedad.

Pese a que se puedan empezar a concluir diagnósticos de figuras como la 42, el modelo aún arroja resultados con zonas difusas y poco precisas ($\approx 90\%$).

Rendimiento

Se ha querido también hacer una comparativa sobre el rendimiento que han tenido los modelos durante el entrenamiento, viéndolo de forma visual. No se tiene la gráfica del modelo ViT pero su rendimiento se presupone similar al mostrado en el ConvNextLarge ya que sus arquitecturas son las más parecidas.




Figura 43. *Epoch loss* para cada uno de los modelos.

En las gráficas de la Figura 42, se puede observar cómo han ido mejorando los modelos, viendo representado en naranja lo referente al entrenamiento y en morado lo de la validación. Se aprecia como en los primeros 5 *epoch* hay una mejora significativa de todos los modelos, tanto en entrenamiento como validación, a excepción de la validación del ConvNextLarge. Este modelo tras 10 *epoch* prácticamente se estanca y no sigue mejorando, aunque tiene aun así el mejor valor de todos.

Viendo que en la Figura 42 la pérdida del ViT está en torno a 0,3 se puede ver que, aunque su arquitectura se parezca más al ConvnextLarge, tiene un rendimiento muy similar al Resnet, lo que es coherente con otras conclusiones que se han ido sacando sobre los modelos en este estudio.

Pese a que los resultados obtenidos son buenos y muestran que los modelos han funcionado satisfactoriamente, para considerarlos hay que tener en cuenta el sesgo que se comentó al principio de esta sección, ya que hace que no puedan ser fiables al 100% si se estuviese buscando la máxima rigurosidad.

4. CONCLUSIONES Y TRABAJOS FUTUROS

Una vez realizado todo el trabajo, se puede concluir que se ha cumplido exitosamente el objetivo principal que se había fijado ya que se ha hecho un estudio completo de cómo se podrían establecer las bases de un asistente al diagnóstico. Se han evaluado distintas arquitecturas y modelos, habiendo obtenido una vista general del estado del arte aplicable a un proyecto de estas características.

No solo se ha tratado de obtener métricas de los modelos y hacer una comparación de ellas, sino que se ha ido más allá tratando de entender la profundidad de los conceptos que se estaban tratando y los posibles riesgos o sesgos que se podrían presentar. Se ha abordado en profundidad cómo sería el tratamiento de datos médicos óptimo para este tipo de desarrollos en ámbitos en los que se quiera la máxima rigurosidad.

El estudio que se ha realizado proporciona una amplia visión general sobre el panorama actual de la aplicación de modelos de IA al entorno médico. En consecuencia, se han conseguido cumplir todos los objetivos que se habían planteado para este proyecto.

El valor aportado por el presente trabajo son las lecciones aprendidas y el conocimiento práctico que se ha obtenido, independientemente de que los resultados no busquen tener una rigurosidad minuciosa. El trabajo aporta valor al sector médico mediante los siguientes puntos:

- Se ha tratado de hacer una selección lo más minuciosamente posible de los datos que conformaban el *dataset* final, pudiendo así validar mejor los resultados y poder sacar conclusiones relevantes. Este paso es crucial ya que hay muchos artículos de los comentados que obvian este paso, induciendo así un sesgo en las conclusiones y limitando las posibilidades del estudio realizado.
- En cuanto a la tipología de los datos utilizados, estos son relevantes ya que al haber utilizado distintos *datasets* dependiendo de las enfermedades, pese a inducir un sesgo inevitable, también hace que el estudio deba tener en cuenta más factores, aumentando así el análisis que se realiza.
- Se han generado las bases de un asistente al diagnóstico médico de enfermedades neurológicas al haber conseguido replicar a pequeña escala una detección con precisión superior del 95% en alguno de los casos. Al no ser una clasificación binaria, entre enfermo o sano, se consigue establecer un modelo robusto de diagnóstico de las principales patologías neurológicas estudiadas.
- Se han utilizado distintos modelos de redes de neuronas, habiendo así tratado distintos tipos de arquitecturas convolucionales y de *transformers*. A esto se le suma el hecho de que se han tenido que hacer transformaciones de las imágenes para que los modelos pudieran usarlas.
- Se obtiene un análisis completo, a través de las conclusiones obtenidas, que no sirve solo de manera teórica, sino que se puede extrapolar al conocimiento

práctico aplicable en entornos sanitarios como hospitales y que puede ayudar a entender cómo funcionan estos modelos en casos en los que los datos sean heterogéneos.

Una conclusión general que se puede sacar de este trabajo es que hace falta una democratización de los modelos médicos especializados, ya que el hecho de que no la haya supone una barrera significativa a la hora de avanzar en este campo. La limitación de acceso a estos modelos, así como la dificultad de obtención de datos de estudio hace que se ralentice la investigación de este tipo de modelos en entornos reales.

Como trabajos futuros se podría tratar de replicar el presente trabajo disponiendo de un dataset con más clases de enfermedades neurológicas, con más imágenes por clase y tratando así de evitar el sesgo en el que se ha tenido que incurrir para desarrollar este estudio. De esta forma, y pudiendo plantear modelos actuales y específicos del sector médico, se conseguirían resultados a mayor escala y con una capacidad superior de aplicación real.

También se podría plantear el hecho de, dentro del propio asistente de diagnóstico, añadir técnicas avanzadas de *machine learning* para mejorar el diagnóstico de enfermedades mediante biomarcadores y así conseguir ayudar a todas las personas que las sufren.

Este trabajo sirve como evidencia de que las herramientas de inteligencia artificial pueden dejar de ser una caja negra, en la que no se entiende el proceso y se obtienen conclusiones sin explicación. Al confrontar cinco modelos distintos con siete clases de clasificación distintas, dependiendo de la enfermedad que se esté diagnosticando, se consigue apoyar a la detección de diagnósticos neurológicos complejos. Se ha logrado que este tipo de herramientas sean entendibles para un público más general mediante técnicas de explicabilidad, ahondando en el hecho de que no importa solo que los modelos acierten, sino que se comprendan sus resultados.

Se ha conseguido mostrar que la inteligencia artificial es aplicable y necesaria en entornos tan complejos y relevantes como es el ámbito sanitario, y concretamente el diagnóstico médico, pudiendo generar así un gran impacto en el.