

Doble Grado en Ingeniería Informática y ADE
2025-2026

Trabajo Fin de Grado

“Asistente de detección de enfermedades cerebrales con imágenes y datos médicos”

Ángela Morales Valverde

Tutor/es

Alfonso Alejandro Sánchez-Macián Pérez

María del Acebo Sánchez-Macián Pérez

Colmenarejo, febrero 2026



[Incluir en el caso del interés de su publicación en el archivo abierto]

Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento – No Comercial – Sin Obra Derivada**

ÍNDICE GENERAL

RESUMEN	v
PALABRAS CLAVE	vii
ÍNDICE DE FIGURAS	viii
LISTA DE ABREVIATURAS.....	x
1. INTRODUCCIÓN.....	1
1.1. Motivación	1
1.2. Objetivos	1
1.3. Estructura	2
1.4. Metodología	2
1.5. Marco regulador.....	3
1.6. Entorno socio-económico	4
1.6.1. Presupuesto	4
1.6.2. Impacto socio-económico	6
2. MÉTODOS.....	8
2.1. Concepto de inteligencia artificial	8
2.1.1. Diferencia entre el IA, machine learning y el deep learning	8
2.1.2. Principales usos	9
2.2. Concepto de red de neuronas	10
2.2.1. Principios básicos de una red neuronal	10
2.2.2. Evolución histórica	12
2.2.3. Problemas clásicos.....	14
2.3. Tipos de redes neuronales	16
2.3.1. Fundamentos y redes pre-deep learning	16
2.3.2. Auge de la especialización	18
2.3.3. Arquitecturas de reconstrucción y generación	21
2.3.4. La revolución de la atención.....	24
2.3.5. Nuevos paradigmas y bio-inspiración	27
2.4. Aplicación de las Redes Neuronales en Medicina	27
2.4.1. Aplicaciones generales	27
2.4.2. Aplicaciones en diagnóstico por imagen	28
2.4.3. Arquitecturas clásicas aplicadas a imágenes médicas	29

2.4.4. Modelos específicos diseñados para imágenes médicas	30
2.4.5. Modelos multimodales aplicados a medicina	32
2.4.6. Modelos planteados para el presente trabajo	33
2.4.7. Aplicaciones de diagnóstico en enfermedades neurológicas	41
2.4.8. Reto de la explicabilidad	43
2.4.9. Retos éticos y regulatorios del uso de la IA en medicina	45
2.5. Limitaciones de los enfoques actuales	46
3. RESULTADOS	48
3.1. Estructura del desarrollo	48
3.2. Preparación de los <i>datasets</i> para el estudio.....	48
3.3. Métricas de evaluación de resultados.....	52
3.4. Entrenamiento de los modelos de deep learning	53
3.5. Evaluación de resultados de deep learning	56
4. CONCLUSIONES Y TRABAJOS FUTUROS.....	67
5. BIBLIOGRAFÍA	69
6. ANEXOS.....	1
6.1. Anexo A. Declaración del uso de IA	1
6.2. Anexo B. Declaración de originalidad.....	5

RESUMEN

El propósito de este trabajo es analizar, desarrollar y evaluar un sistema de ayuda al diagnóstico de enfermedades neurológicas mediante MRI, siendo capaz de clasificar entre siete clases diferentes. El enfoque central no es la obtención de métricas, sino que se pretende establecer un punto de partida para el estudio de este tipo de iniciativas en el entorno sanitario. Se quiere demostrar que se pueden obtener resultados explicables si se aprovechan las herramientas de explicabilidad disponibles.

Dentro del análisis, se ha hecho un procesamiento multiclase, entrenando los modelos para una clasificación compleja entre enfermedades. Se ha hecho un *benchmark* de cinco modelos con arquitecturas distintas dentro del ámbito del *deep learning*. Desde las redes convolucionales (CNN) clásicas hasta las últimas arquitecturas como son los *transformers*. Además, se ha incluido una parte fundamental referente a la explicabilidad de los resultados que arrojan los modelos, habiendo mostrado imágenes sobre qué se obtendría exactamente de estas técnicas. Esta práctica permite auditar las decisiones de los modelos, verificando si estos son coherentes o no.

En general, los resultados obtenidos por los modelos son buenos, aunque destacan principalmente dos de ellos, el EfficientNetB0 y el ConvNextLarge, ambos siendo CNN y obteniendo una precisión global por encima del 95%. En cuanto a la explicabilidad, los resultados obtenidos muestran que, con un entrenamiento de este tamaño, los modelos localizan mejor patologías más localizadas como tumores cerebrales que otras con áreas afectadas más difusas como puede ser el Alzheimer o el Parkinson.

La principal conclusión que se ha conseguido obtener es que hay un camino de investigación dentro de este ámbito de estudio, pudiendo aplicar técnicas avanzadas de inteligencia artificial dentro del sector médico, consiguiendo que sean entendibles e interpretables. Se ha conseguido establecer un punto de partida en el desarrollo de un asistente al diagnóstico para apoyar la labor de los profesionales sanitarios, acelerando así la detección de estas patologías y demostrando que se puede generar un gran impacto.

PALABRAS CLAVE

Inteligencia artificial

Redes convolucionales

Transformers

Deep learning

Machine learning

Redes de neuronas

Redes recurrentes

ÍNDICE DE FIGURAS

Figura 1. Funcionamiento de las fases de la metodología CRISP-ML(Q) [2]	3
Figura 2. Planificación del proyecto.....	5
Figura 3. La IA y dos de sus subdisciplinas. [16]	8
Figura 4. Estructura básica de un perceptrón [19].....	10
Figura 5. Estructura simplificada de las capas de una red neuronal. [20].....	11
Figura 6. Método de <i>dropout</i> ejemplificado [36].....	15
Figura 7. Pérdida en el entrenamiento con el dataset MNIST [37].	16
Fuente 8. Estructura básica de una CNN [51].	19
Figura 9. Estructura de una RNN [55].....	21
Figura 10. Estructura del U-Net [57].....	22
Figura 11. Estructura del <i>Encoder-Decoder</i> [59].....	23
Fuente 12. Estructura de las GAN [61].....	23
Figura 13. Estructura de una DCGAN [62].....	24
Figura 14. Estructura de un transformer base [63].....	25
Figura 15. Estructura del ViT [64].	26
Figura 16. Tabla comparativa de los modelos	30
Figura 17. Estructura de TransUNet. Siendo (a) la capa del transformer y (b) la estructura que propone este modelo [84].....	31
Figura 18. Estructura general del modelo UNETR, con codificador <i>transformer</i> y decodificador CNN [85].....	32
Figura 19. Estructura del ResNet50 [90].....	34
Figura 20. Estructura del DenseNet121. Se están mostrando cinco capas y con $k=4$ [93].	35
Fuente 21. Estructura del EfficientNetB0 [95].	36
Fuente 22. Estructura del Med-Gemma [89].	37
Figura 23. Estructura general del ConvNext [99].	39
Figura 24. Comparativa del tratamiento de la imagen entre Swin Transformer y ViT [101]. ...	41
Figura 25. Número de artículos publicados al año de análisis de imágenes médicas [114].	43
Figura 26. Planificación del desarrollo del proyecto.....	48
Figura 27. Ejemplos de imágenes del dataset [123].	49
Figura 28. Ejemplos de imágenes del dataset [124].	50
Figura 29. Ejemplo de las imágenes del dataset [126].....	50
Figura 30. Ejemplos de imágenes del dataset [127] [128] [129].	51
Figura 31. Resultados del informe de clasificación de los modelos.....	58
Figura 32. Comparativa de métricas medias entre modelos por enfermedad.....	58
Figura 33. Resultados de las matrices de confusión de los modelos.....	60

Figura 34. Errores totales por modelo evaluado.	61
Figura 35. Métricas del ConvNextLarge en los 5 <i>epoch</i> de entrenamiento de la cabeza.....	62
Figura 36. Métricas del ConvNextLarge en los 10 primeros epoch de <i>fine-tuning</i>	62
Figura 37. Métricas arrojadas por ViT en los primeros 10 y 20 <i>epoch</i>	62
Figura 38. Desempeño de los 5 modelos tras 10 epoch.....	63
Figura 39. Resultados del <i>heatmap</i> del Grad-CAM para el meningioma.	64
Figura 40. Resultados del <i>heatmap</i> del Grad-CAM para el Alzheimer.....	64
Figura 41. Ejemplo conseguido de salida del Attention Rollout con ViT	64
Figura 42. Ejemplo conseguido de salida del Attention Rollout con ViT	65
Figura 43. <i>Epoch loss</i> para cada uno de los modelos.	66

LISTA DE ABREVIATURAS

CNN	Convolutional neural network
IA	Inteligencia artificial
RNN	Recurrent neural network
MRI	Magnetic Resonance Imaging
CT	Computed Tomography
LLM	Large Multimodal Model

1. INTRODUCCIÓN

1.1. Motivación

Hay enfermedades en las que el tiempo juega en contra y cada instante que se pueda ganar a la hora de diagnosticar puede ayudar al paciente a paliar o controlar la enfermedad. En los últimos años ha crecido la investigación médica de cánceres y enfermedades neurodegenerativas, pero aún no se sabe lo suficiente de ellas como para que esos avances se traduzcan en una mejor calidad de vida de aquellos que las padecen.

Este tipo de enfermedades cuesta mucho detectarlas, teniendo en cuenta que muchas de ellas no tienen una cura asociada, sino que es vital su detección precoz para tratarlas cuanto antes y así permitir al paciente tener una vida lo más dentro de la normalidad posible.

Por ello, gracias a todos los avances que hay en materia de IA para ayudar al diagnóstico, como puede ser a través del tratamiento de imágenes médicas como son las MRI, se abre una oportunidad de desarrollo crucial, consiguiendo poner así una vez más la tecnología a nuestro favor y alcance.

1.2. Objetivos

El objetivo principal de este trabajo es conseguir crear las bases fundamentales de lo que sería un asistente de inteligencia artificial para la ayuda al personal sanitario para la detección de enfermedades neurológicas, concretamente a través de imágenes de resonancias magnéticas (MRI).

Para ello, se consideran una serie de subobjetivos que ayuden a conseguir ese propósito principal.

- Ser capaz de explicar el comportamiento complejo de los sistemas que hay detrás de los procesos que involucran a la IA para tratar así de democratizar su conocimiento y hacerlos entendibles para personas con una base tecnológica menor.
- Se pretende demostrar que hay un camino viable, aunque con una serie de riesgos, que puede proporcionar una mejora considerable en los tiempos de detección de enfermedades neurológicas.
- Se trata de ver qué modelos actuales son los que proporcionarán mayores mejoras y, por tanto, cuáles son en los que se deberían centrar los recursos para la investigación.
- Se quiere elaborar un estudio sobre cómo debería ser el tratamiento de los datos que se usen para los modelos entrenados, viendo si se generan sesgos en ellos y, en caso de tenerlos, proporcionar alternativas que los solucionen.

La conclusión de este trabajo no pretende ser una mera recopilación de extracciones de pruebas que se han hecho con distintos modelos, sino que pretende mostrar que hay un gran campo posible de investigación que realmente aporta valor y puede ayudar a mucha población.

1.3. Estructura

Este documento presenta la información en cuatro bloques principales, cada uno de los cuales con un tipo de contenido distinto.

El primero de ellos es esta parte de introducción, la que se ve el contexto del proyecto, así como el presupuesto que llevaría asociado y el marco regulador que le aplica.

La segunda parte trata del estado del arte en materia de inteligencia artificial y en el campo concreto en el que se centra este proyecto, que es el de la ayuda a la detección de enfermedades neurológicas en el ámbito médico. Se hace un recorrido desde los conceptos más fundamentales necesarios para entender qué se va a desarrollar, hasta una discusión de referencias en las que tratan enfermedades neurológicas con modelos como los que se van a recrear en este trabajo. Se pretende generar un entendimiento profundo del tema tratado para así conseguir evidenciar que hay un gran margen de evolución en este campo y que se debe explotar para detectar enfermedades.

El tercer bloque es la parte de desarrollo, en la que se muestra el proceso seguido desde los primeros pasos que se dieron hasta las conclusiones de los resultados obtenidos una vez hecho todo el proceso de investigación. Se elabora un discurso donde se parte de la obtención de las imágenes iniciales necesarias, su tratamiento, la búsqueda y puesta en marcha de los modelos y se concluye con una discusión sobre los valores que estos han arrojado.

El último punto recoge todas las conclusiones a nivel global que se extraen de la elaboración de este proyecto, así como la propuesta de posibles trabajos a desarrollar en el futuro. Se recalca el valor añadido que hacen esta serie de trabajos en el desarrollo de herramientas como es el caso de la inteligencia artificial y todas las variantes que presenta.

1.4. Metodología

Inicialmente se valoró usar la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*), ya que esta es ampliamente utilizada en procesos en el ámbito de la ingeniería y proyectos tecnológicos, aunque tiene una limitación importante [1]. Tiene una estructura lineal de trabajo, lo que no se ajusta con el proceso de desarrollo que se ha llevado a cabo en el presente trabajo que ha sido más bien iterativa.

Posteriormente, tratando de encontrar una metodología no lineal, se encontró la variante de CRISP-DM que está enfocada al ciclo de vida de la IA, el cual es iterativo y cíclico. Esta metodología es la CRISP-ML(Q) (*Cross-Industry Standard Process for the development of Machine Learning applications with Quality*) y tiene una estructura como la que se muestra en la Figura 1 [2].




Figura 1. Funcionamiento de las fases de la metodología CRISP-ML(Q) [2]

Esta metodología tiene la siguiente estructura [2] [3] [4]:

- En la parte izquierda de la Figura 1 se puede observar que todo parte de una idea, la cual necesita concretarse en casos de uso concretos (*Use case for Machine Learning*) que se quieran conseguir o probar. Cuando se tiene claro qué se quiere hacer, empieza una parte crucial de entendimiento del problema a resolver y de los datos de los que se dispone (*Business and Data Understanding*), así como posibles limitaciones o riesgos que haya que tener en cuenta. Es en esta fase del proceso en el que es importante considerar la calidad de los datos que se usan, así como controlar la división correcta de los mismos para los modelos hacia los que vayan dirigidos (*Dataset Development Lifecycle*).
- Cuando ya se tiene el dataset definitivo con el que se quiere trabajar, entonces se pasa al conjunto de fases que se muestra en la parte derecha de la Figura 1 (*Model Development and Model Operations*). En este proceso de *Model Development* se experimenta con los modelos, haciendo pruebas con modelos simplificados o primeras versiones para así ir ajustando según se necesite (*Model Operations*). Mediante estas pruebas, se van analizando las métricas que van arrojando los distintos modelos, y así se van descubriendo posibles problemas, limitaciones o hechos en los que centrar el estudio. Este proceso cíclico continúa hasta obtener unos resultados suficientes para la investigación.

La metodología CRISP-ML(Q) ha sido de gran utilidad dentro del proyecto, aunque se ha encontrado una limitación importante en su uso que era la gran necesidad computacional que requerían los modelos y no permitían distintas pruebas en local o experimentar más con el entorno.

1.5. Marco regulador

Por un lado, una de las medidas más importantes a tener en cuenta es el marco de la inteligencia artificial que, en el caso de este proyecto, al tratarse de diagnósticos médicos,

se clasificaría como IA de alto riesgo según el Reglamento de la UE 2024/1689 o AI Act [5]. Este reglamento es la base que se debe seguir y establece los requisitos de gobernanza de datos, documentación técnica y supervisión humana que debe haber en un proyecto de este estilo. Proporciona un enfoque en el que se centra en la calidad de los *datasets* para tratar de no tener sesgos o que estos sean lo menor posibles y que se pueda tener una cierta trazabilidad de los modelos.

Otra parte fundamental a considerar es el hecho de la protección de datos, ya que al final las imágenes son datos personales de los pacientes y deben tratarse con la debida consideración. Para ello hay dos normativas principales que hay que seguir, una en el marco nacional español y otra a nivel de la Unión Europea. Esta última, mediante el Reglamento General de Protección de Datos (RGPD) define cómo se deben anonimizar las imágenes y la base legal para el tratamiento de estas, abriendo el debate entre el consentimiento de uso y el interés público de investigación [6]. A nivel nacional se recoge en el BOE la Ley Orgánica de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD) donde se adapta la normativa europea y se detalla el uso de los datos relacionados con la salud y destinados a investigación científica [7].

Ya concretamente tratando sobre la tipología de los datos, al ser de salud, la Comisión Europea recoge un nuevo reglamento, el Espacio Europeo de Datos de Salud (EEDS), para así facilitar el uso secundario de datos de salud para entrenamientos de la IA en toda la UE [8].

Al pretender ayudar al diagnóstico médico, ya no se consideraría un producto de software, sino que pasaría a ser un *Medical Device Software* (SaMD), lo cual implicaría que se debería cumplir con el Reglamento de la UE que obliga a que dicho software esté marcado con la distinción “CE”. Para ello, se necesitará una evaluación clínica que demuestre que el algoritmo es seguro y eficaz [9].

Concretamente en el caso de este proyecto, se han tenido que considerar con especial cuidado las licencias de los *datasets* que se han usado, para así asegurarse que se dispone del permiso de uso de dichos datos para esta investigación. De esta forma, se estaría respetando la ley de Protección de Datos de los pacientes y sólo se estaría trabajando con datos anonimizados.

1.6. Entorno socio-económico

1.6.1. Presupuesto

El proyecto se ha elaborado durante un periodo de 6 meses aproximadamente y se ha seguido una planificación como la que se muestra en la Figura 2.

Etapas	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Business & Data Understanding						
Data Engineering						
ML Model Engineering						
Model Evaluation						
Model Reportment						

Figura 2. Planificación del proyecto.

En el primer mes, en la etapa de conocimiento de los datos y el negocio, es cuando se define el problema que se quiere solucionar, así como buscar los *datasets* y verificar su calidad inicial. El segundo y tercer mes estuvo centrado en la etapa de ingeniería de datos en la que se puso el foco en el preprocesamiento de los *datasets*, la adaptación de estos a los modelos, la eliminación de ruido, normalización de las imágenes y la eliminación de duplicados. Desde el cuarto mes es cuando se empezó a mover el uso de los modelos de *deep learning*, y es cuando se pudo disponer del entorno de ejecución con la H200. En el quinto mes, a la vez que se terminaban de rematar las pruebas sobre los modelos, se empezó a evaluar estos, a la par que se empezaba a generar documentación sobre el proceso seguido y los datos que se estaba obteniendo.

En cuanto a la estimación de presupuesto que tendría este proyecto, se parte de la base de haber usado una GPU H200 externa, en este caso proporcionada por la universidad la cual tendría un coste de 3,80 dólares por hora ejecutada, habiendo ejecutado un total aproximado de 18 horas [10].

$$\text{Coste H200} = 18h \text{ de ejecución} * \$3,80 = \$60,40 \approx 51,19€ \quad (1)$$

Teniendo en cuenta que parte del desarrollo del proyecto se ha ejecutado en un portátil gaming de gama media-alta, hay que tener en cuenta la amortización de este material, habiéndose estimado en un total de unos 150€ para los 6 meses de proyecto.

En cuanto a la energía eléctrica necesaria para llevar a cabo ese desarrollo en el portátil, se estima el consumo en 0,1 kWh, suponiendo un uso de 4 horas diarias, unos 5 días a la semana durante 6 meses, es decir, aproximadamente 24 semanas. Esto equivaldría a unas 480 horas de uso, si se estima en promedio un coste de 0,20€ el kWh se obtiene el siguiente coste.

$$\text{Coste energía} = 480h * 0,1 kWh * 0,20€/kWh \approx 10€ \quad (2)$$

La mayor parte del coste vendría dada por los salarios de las personas que desarrollasen el proyecto. Se supone un salario bruto mensual de unos 1.500€ en 14 pagas o, de manera equivalente, 1.700€ en 12 pagas. Teniendo en cuenta que se trataría de un trabajo a media jornada, se trataría de 20 horas al mes y la mitad del salario.

$$\text{Salario} = 1.750\text{€/mes} * 6 \text{ meses} * 0,5 = 5.250\text{€} \quad (3)$$

Con todos estos datos, el presupuesto total que se necesitaría para llevar a cabo el proyecto es el siguiente.

$$\text{Coste presupuestado} = 51,19 + 150 + 10 + 5.250 = 5.461,19\text{€} \quad (4)$$

1.6.2. Impacto socio-económico

1.6.2.1. Impacto médico y clínico

El ámbito principal en el que se centra el proyecto es en el médico y en este, gracias a investigaciones como la que se presenta en este documento, se puede generar un impacto significativo a nivel global. La idea de este proyecto puede ayudar a la detección precoz de enfermedades neurológicas, teniendo la capacidad de detectar patrones sutiles que el ojo humano no detecta, antes de que aparezcan síntomas clínicos evidentes. También, aunque tiene una precisión no perfecta, ayuda a reducir el fallo humano, aportando valor como segunda opinión para el médico, minimizando los falsos negativos y las posibles variaciones de interpretación. También, al conseguir agilizar el diagnóstico, se permite una intervención precoz por parte de los médicos, lo que evita saturación de los centros y facilita el desempeño de los sanitarios, permitiendo así centrarse en casos más complejos o que necesiten una evaluación más completa.

1.6.2.2. Impacto social

Teniendo en cuenta que, en términos generales, la sociedad está cada vez más envejecida, proyectos como el que se presenta hacen que se mejore la calidad de vida de las personas mayores, ya que hay ciertas enfermedades en las que la edad juega un papel importante. El diagnóstico temprano hace que las enfermedades se puedan tratar antes, lo que ayuda a paliar posibles deterioros mayores o dependencias que se generen. Ya no se trata solo de proporcionar un diagnóstico objetivo a los pacientes, sino de ayudar a todos aquellos que sufran enfermedades como las que se tratan en este trabajo a sentirse más acompañados en el proceso.

Otro problema que solucionarían los asistentes de IA al diagnóstico es el de poder democratizar el diagnóstico de enfermedades complejas, pudiendo llegar así de igual forma a centros con menos especialistas o con menos recursos médicos. Se debe tener en cuenta que el personal sanitario sigue siendo la pieza fundamental a la hora de diagnosticar enfermedades, siendo estos asistentes una ayuda a ellos y no un sustitutivo.

1.6.2.3. Impacto económico

La eficiencia en los procesos que pueden traer estos asistentes de IA se traduce en ahorros directos para todo el sistema sanitario, así como una mejora de sus operaciones y, por tanto, de los pacientes que pueden tratar. Usando esta tecnología, se conseguiría una reducción del coste por paciente. Pese a esto, hay que tener en cuenta que, aunque en el

largo plazo se materialicen ahorros, en un primer momento habría que hacer una inversión para la transformación de los sistemas, incurriendo así en un gasto inicial.

También supone una agilización de las listas de espera de los centros sanitarios, optimizando así los recursos disponibles, pudiendo ayudar más pacientes con los medios de los que se dispone. Así, las máquinas de resonancias magnéticas no quedan bloqueadas en diagnósticos dudosos, ya que el asistente de IA aporta información relevante al personal sanitario, facilitando así el diagnóstico.

1.6.2.4. Impacto medioambiental

La Inteligencia artificial tiene una huella ecológica que se debe tener en cuenta a la hora de plantear su uso generalizado. En el caso de este proyecto, la IA permite tener una eficiencia energética en el diagnóstico ya que optimiza los flujos de trabajo evitando que haya pruebas repetitivas o innecesarias, ahorrando así en el consumo energético que se haga con los equipos médicos de resonancias y diagnóstico. Además, este tipo de tecnologías favorece a que crezcan corrientes de telediagnóstico, reduciendo así emisiones asociadas al transporte, ya que facilita la comunicación de diagnósticos de manera remota o llevar a cabo consultas de manera remota.

Sin embargo, el consumo energético y de recursos para la refrigeración de los modelos de IA es considerablemente alto, por lo que habría que usar este tipo de herramientas con conciencia y siempre midiendo que el impacto global que se genere sea positivo.

1.6.2.5. Impacto ético y en la investigación

Gracias a este tipo de proyectos se podrá conseguir llevar a cabo investigaciones mucho más amplias en el ámbito sanitario, pudiendo así llegar a conclusiones y aportaciones que la ciencia a día de hoy desconoce.

También hace aparecer nuevas necesidades globales sobre el tratamiento de los datos personales, y concretamente los datos médicos, haciendo crecer el debate sobre cuál es su uso correcto. Se debe garantizar en todo momento la protección de datos del paciente, y por ello, es necesario que se generalicen medidas de anonimización de estos datos, para así poder usarlos.

Otro aspecto importante es el hecho de la explicabilidad de los datos que se obtengan gracias a los modelos de IA, ya que funcionan como una caja negra en su ejecución y se necesita de mecanismos que hagan entendible el proceso y las conclusiones que se han conseguido. Se debe asegurar la transparencia en el diagnóstico en todo el momento, explicando y mostrando exactamente qué cosas son las que inclinan a los modelos en el diagnóstico para arrojar la conclusión que aporten. Se debe proporcionar una completa autonomía humana del uso de las herramientas de IA como los asistentes al diagnóstico, haciendo que estos sean un apoyo y no un sustitutivo, pero que a la vez faciliten su trabajo. La tecnología debe fomentar y potenciar el juicio clínico de los profesionales sanitarios, no reemplazarlo.

2. MÉTODOS

2.1. Concepto de inteligencia artificial

La IA cada vez se conoce y se usa más, pudiendo observar aplicaciones en distintos sectores y mercados. Aunque sea reciente su conocimiento más generalizado por parte de la población general, la inteligencia artificial viene desarrollándose desde hace ya bastante tiempo. Originalmente, se pretendía ser capaz de simular el razonamiento humano a través de la tecnología, y de ahí se han ido desarrollando distintas ramas de estudio que hacen tareas automatizadas, con la ventaja que la posibilidad de hacerlo con grandes cargas de trabajo y en tiempos de ejecución cortos.

Con distintos artículos que han sido relevantes a lo largo de la evolución de la inteligencia artificial se puede obtener una definición bastante concreta y completa de lo que es.

“Un campo de la ciencia computacional que busca crear sistemas capaces de aprender representaciones jerárquicas a partir de datos [11] [12], modelando relaciones complejas mediante mecanismos de atención [13] para simular o superar las capacidades cognitivas humanas en tareas específicas [14] [15] ”

Partiendo de este concepto de inteligencia artificial es con el que se va a desarrollar este trabajo.

2.1.1. Diferencia entre el IA, machine learning y el deep learning

La inteligencia artificial es un concepto muy amplio, en el que tienen cabida distintas maneras de procesar la información. Desde la primera definición de IA, se ha ido evolucionando a subdisciplinas más específicas y focalizadas, las cuales se centran en obtener conocimiento de los datos que reciben, como se puede ver en la Figura 3 con el caso del *machine learning* y el *deep learning*.




Figura 3. La IA y dos de sus subdisciplinas. [16]

Para poder entender qué es en sí la IA, primero se debe conocer su funcionamiento, el cuál es a través de las redes neuronales. Estas son nodos conectados que reciben entradas,

procesan la información, y proporcionan una salida [17]. Se entrará a describir el comportamiento específico en apartados posteriores.

Tomando como referencia la definición de la IA como ese conjunto de representaciones jerárquicas, el siguiente paso es que la propia red aprenda patrones de los datos y pueda sacar conclusiones de ellos. Ese proceso de que el propio sistema sea el que aprenda de los datos, los procesa y proporciona conclusiones de ellos, es el que se denomina *machine learning* [11]. Este proceso de aprendizaje puede ser tanto supervisado como no supervisado, y es importante conocer las características básicas de los datos que se deben usar para cada tipo, como si se necesita que sean estructurados o no [18]. El *machine learning* se puede basar en redes de neuronas, aunque las más simples, usando mayoritariamente algoritmos y modelos con los cuales estudia los datos y es capaz de sacar conclusiones y/o patrones, entre otros.

Cuando ese proceso de aprendizaje se hace mediante redes neuronales profundas es cuando se introduce la subdisciplina del *deep learning* [12]. A diferencia del *machine learning*, esta subdisciplina aprende de las características que detecta, no necesitando ayuda para priorizar los datos en los que fijarse o más relevantes. A través de múltiples capas de la red, se aprende de manera autónoma, pudiendo detectar así, por ejemplo, órganos o tumores.

2.1.2. Principales usos

Los usos de la IA se pueden dividir en cuatro grandes grupos dependiendo de la finalidad que tenga en concreto su actuación.

- Categorización de información
 - Los modelos de IA tratan de clasificar, imitando la capacidad visual humana, la información que reciben. Al aprender a cómo clasificar los datos que se les entrega, pueden ser de gran utilidad para la ayuda al diagnóstico médico o para el reconocimiento facial, por ejemplo.
- Procesamiento de lenguaje natural
 - Este tipo de uso lo que trata es de entender y procesar el lenguaje de manera similar a la que lo hacen las personas, siendo capaces de captar, interpretar y responder ante situaciones en las que haya una interacción directa entre un sistema de IA y una persona. Un ejemplo de ello pueden ser los asistentes de voz que disponen muchos teléfonos móviles.
- Predicción y análisis predictivo
 - Se busca el poder encontrar patrones en la información que reciben para poder obtener de ellos predicciones futuras de su comportamiento. Esto hace que puedan resultar de gran utilidad a la hora de tomar decisiones, ya

que sirven como apoyo. Un ejemplo puede ser el uso de estas herramientas para la detección del fraude financiero o la medicina preventiva.

- IA generativa
 - Se trata de crear nueva información y/o contenidos a través del uso de herramientas de IA. Un ejemplo de uso puede ser la generación de imágenes sintéticas o la creación de contenido audiovisual.

2.2. Concepto de red de neuronas

2.2.1. Principios básicos de una red neuronal

Las redes de neuronas nacen de la motivación de recrear el procesamiento de la información que hacen las neuronas en el cerebro humano, tratando de elevar ese comportamiento al ámbito del procesamiento de la información.

Como se ha comentado anteriormente, aunque el *machine learning* puede usar las redes neuronales, es el *deep learning* el que las explota principalmente. Por ello, es importante saber cuál es la base del funcionamiento de estas redes neuronales para poder entender cómo ocurre el aprendizaje y la toma de decisiones dentro de este tipo de sistemas.

Parten de una estructura general en la que se componen de una entrada que va hacia una serie de capas ocultas, las cuales están interconectadas, y que finalmente acaban obteniendo una salida que equivaldría al culmen del razonamiento humano.

La unidad básica de una red neuronal es la neurona, al igual que en el caso del cerebro humano, es la parte más pequeña que conforma la red y también se le puede llamar perceptrón. La estructura básica de un perceptrón se puede ver en la Figura 4.




Figura 4. Estructura básica de un perceptrón [\[19\]](#).

La neurona recibe una serie de entradas, que equivaldrían a los impulsos en el cerebro, que tienen una cierta ponderación en base a su importancia. Con esas ponderaciones se hace una suma total, de la cual, para poder normalizar la información recibida, se le aplica una función de activación. Esta función puede ser de distintos tipos dependiendo de lo

que se quiera conseguir concretamente, y es de donde se obtiene una salida que sería el fin del razonamiento o la conclusión.

Esta función de activación es necesaria ya que si no sería muy complejo el poder establecer cómo tiene que aprender la red las relaciones complejas que tienen las distintas variables que se estudian. Con ella se consigue introducir la no linealidad, que es la que permite hacer esto último que se ha mencionado.

Con lo cual, la estructura general quedaría definida por una capa inicial de input en la cual se recibe la información, de 1 a N capas ocultas que procesan la información y son las que aprenden y extraen características de estas entradas, y una última capa de salida en la que se obtiene bien sea la clasificación o la predicción. Estas capas están compuestas por neuronas artificiales que están interconectadas con neuronas de otras capas, esta estructura se puede apreciar en la Figura 5.




Figura 5. Estructura simplificada de las capas de una red neuronal. [20]

Una vez que se tiene esta estructura general de cómo funciona una red neuronal, falta conocer cómo se hace el proceso que se denomina aprendizaje de la red, y cómo esta va tratando las entradas que recibe hasta obtener la salida que devuelve.

Cada entrada tiene varias partes a su vez que la componen. Cuando se recibe una información, este tiene una serie de características principales las cuales llevan asociado un peso. Para tener en cuenta todas las características, se hace una suma de todas ellas a las que adicionalmente se le suma un extra que se denomina sesgo. El resultado de toda esa suma es lo que se manda a la función de activación. A todo este paso de las entradas a través de las capas hasta obtener una salida se le denomina propagación hacia delante o *forward propagation*.

Durante todo este proceso, el aprendizaje de la red neuronal sucede cuando se van ajustando los pesos de estas características para reducir el error entre la salida que se esperaba tener y la que se ha terminado obteniendo. Esto último se hace con el algoritmo de retropropagación o *backpropagation* al que a su vez se le añade un denominado optimizador, como puede ser el caso del descenso de gradiente.

Una red neuronal no memoriza la información de la que aprende, tan sólo reconoce patrones y características que posteriormente irá comparando con la nueva información que reciba en el futuro.

Como se explica en el artículo de Wu y Feng [20], se establecen las cuatro principales características de las redes neuronales. La primera característica de la que se habla es de la no linealidad, que es lo que constituye el comportamiento inteligente de estas redes. Esto se debe al uso de funciones de activación no lineales. La segunda característica es que no es limitada, en el sentido de que su comportamiento no depende de tan solo una neurona a nivel individual, sino que depende de las interacciones y conexiones que haya entre todas las neuronas. La tercera característica es la no cualitatividad, que alude a la capacidad de autoaprendizaje, autoorganización y adaptación dinámica que tienen las redes neuronales. La cuarta característica es la no convexidad, con la cual se describe que hay distintos y múltiples estados de equilibrio.

En el artículo de Aggarwal [21] se puede tener una visión mucho más completa de qué son y cómo funcionan las redes neuronales, en el que tratan los principales problemas que hay que tener en cuenta cuando se trabaja con ese tipo de modelos. También aborda algunos de los distintos tipos de redes neuronales que existen y cómo funcionan cada una de ellas.

2.2.2. Evolución histórica

La idea de las redes de neuronas artificiales tuvo como comienzo la publicación del artículo en 1943 de Warren McCulloch y Walter Pitts en el cual hacían una primera aproximación de lo que acabarían siendo las redes que conocemos hoy en día [17]. En esta etapa se empezó a plantear que se podía simular el funcionamiento del cerebro humano mediante un modelo matemático, demostrando que una red neuronal simple podía hacer operaciones lógicas como el AND o el OR.

En 1949, el psicólogo Donald Hebb publicó *“The organization of behavior”* donde introduciría la regla de Hebb, con la que según la fuerza de las conexiones entre dos neuronas de la red se activaría cuando las dos neuronas se activan de forma simultánea. Con esto, se pudieron empezar a sentar las bases de lo que sería el aprendizaje de las redes [22].

Posteriormente, en 1950, Alan Turing publicaría otro artículo con el que introducía la prueba de Turing, con la cual se podría llegar a evaluar la inteligencia de las máquinas [14]. Aunque este artículo no trataba sobre las redes neuronales, sería influencia directa en el marco conceptual de la inteligencia artificial del momento.

En 1957, Frank Rosenblatt desarrollaría el concepto del perceptrón, el cual se considera que fue el primer modelo de red neuronal que se podría entrenar, pudiendo clasificar la información de forma binaria [23]. Es en este punto cuando surge la idea del entrenamiento de ajustes de pesos, pudiendo así identificar patrones y acabar tomando decisiones. Se crea una estructura como la que se muestra en la Figura 5.

Poco después, en 1960, Bernard Widrow y Marcian Hoff presentarían el modelo ADALINE (*Adaptive Linear Element*) con el cual se podía llevar a cabo un aprendizaje supervisado usando la técnica de los mínimos cuadrados para así ajustar los pesos de la red y favorecer la toma de decisiones del modelo [24].

Fue en 1969 cuando Marvin Minsky y Seymour Papert, a través del libro que publicaron llamado “*Perceptrons*”, demostraron que las redes neuronales con tan solo una capa no podían resolver problemas lineales, poniendo como ejemplo el caso del XOR [25]. Tras este acontecimiento, sucedería lo que se considera el primer invierno de la IA, entrando así en un periodo en el que la financiación en esta materia se detendría por casi una década.

En la década de los 70 hubo dos principales acontecimientos que supusieron una gran evolución dentro del marco de las neuronas artificiales, los cuales eran enfoques mucho más teóricos y experimentales que lo que se había estado haciendo hasta el momento. Primero, en 1972 con el profesor Kohonen que creó el SOM (Self-Organizing Map), la cual era una un tipo de red neuronal no supervisada que se quería usar para el reconocimiento de patrones y la clasificación [26]. Más tarde, Grossberg lanzó ART (Adaptive Resonance Theory) en 1976 la cual se basaba en redes autoorganizadas que tuvieran una estabilidad dinámica [27].

En la década de los 80, hubo un resurgimiento de la investigación sobre las redes neuronales. En 1982 Hopfield, físico americano, estableció la red de Hopfield la cual se trataba de una red recurrente que usaba la función de Lyapunov para así poder garantizar la estabilidad de la propia red [28]. Rumelhart *et al.* [29] introdujeron el algoritmo de retropropagación o “*backpropagation*” en 1986, el cual se utiliza actualmente. Este algoritmo solucionaba la limitación que había con los perceptrones simples, pudiendo entrenar redes neuronales multicapa. Aparte de esos dos mencionados, hubo bastantes más avances dentro del estudio de las redes neuronales y esta década supuso un cambio de ritmo dentro del estudio de este tipo de contenidos.

En la década de los 90 la evolución en las redes neuronales estaba mucho más centrada en el reconocimiento de patrones, pudiendo tener procesos de autoorganización de la información. Un hito importante que sucedió fue el hecho de que en 1998, LeCun Y. *et al.* [30] introdujeron las redes de neuronas convolucionales (CNN) para poder reconocer caracteres escritos.

Desde los 2000, se ha visto un gran auge tanto del estudio como del inicio de la implementación de soluciones que se basen en general en inteligencia artificial, teniendo cada vez más usos de cualquiera de las subdisciplinas de la IA. El concepto del *deep learning* surge en el 2006 a partir del artículo de Hinton y Salakhutdinov [31] en el cual se sientan las bases de lo que hoy conocemos como dicha subdisciplina de la IA.

Con el paso del tiempo, y debido al aumento de la capacidad de cómputo de las GPUs, al haber más cantidad de datos, las redes neuronales podían superar a cualquier otro método, generalizando así el uso del *deep learning*.

En 2012, un modelo de redes neuronales convolucionales (CNN) mucho más profundas, que posteriormente pasaría a llamarse AlexNet, consiguió obtener un error del 15,3%, mientras que el segundo algoritmo con el que competía obtuvo un error del 26,2% [32]. Este hito consiguió que ganase fuerza el uso de redes neuronales y, por tanto, del *deep learning*.

Otro gran paso fue cuando en 2014 aparecieron las Redes Generativas Adversarias (GAN) con las cuales dos redes neuronales compiten entre sí para la generación de contenidos sintéticos [33]. Este fue el primer gran paso hacia la IA Generativa y la creación de *deepfakes*.

A partir del 2017, los mecanismos de atención como son los *transformers* empezaron a coger peso, introduciendo así una arquitectura nueva que reemplaza a las RNN [13]. Este tipo de arquitectura permite procesar datos en paralelo, lo que reduce la necesidad computacional requerida para su uso.

Desde el año 2020 en adelante el estado del arte en cuando a IA lo han marcado los LLMs y los modelos multimodales, donde la IA no es tan solo una herramienta sino que se ha integrado en distintos ámbitos y sistemas del día a día.

Más recientemente, en 2023, surgen nuevos modelos como es el caso de Mamba [34], basado en los Modelos de Espacio de Estados (o SSM en inglés) [35]. A diferencia de los *transformers* que miran todos los *patches* a la vez, Mamba procesa la información continuamente y con una compresión constante de la información, lo que favorece considerablemente su rendimiento. Tiene una gran variedad de aplicaciones, estando también presente en el ámbito médico con modelos como el U-Mamba, sucesor del nnU-Net.

2.2.3. Problemas clásicos

En el proceso de aprendizaje de estas redes neuronales pueden surgir diversos problemas que afecten al resultado que esta es capaz de obtener.

Uno de estos problemas es el **sobreaprendizaje** (*overfitting*) que sucede cuando el modelo aprende demasiado de las características específicas de los inputs de un conjunto de entrenamiento en concreto. Esto hace que el modelo pierda la capacidad de generalizar sus conclusiones, lo que genera una falta de rendimiento en el modelo. Para tratar de paliar este problema, Srivastava *et al.* [36] en su trabajo “*Dropout: A Simple Way to Prevent Neural Networks from Overfitting*” propusieron la idea del método *dropout* que consiste en desactivar de manera aleatoria un porcentaje de las neuronas con las que se trabaja durante el entrenamiento, como se aprecia en la Figura 6.




Figura 6. Método de *dropout* ejemplificado [36].

Este método consigue que las neuronas no aprendan en exceso de las demás, garantizando la generalización del modelo. Gracias a esta práctica se pudo reducir el error que se producía por sobreajuste a la hora de procesar imágenes para reconocimiento o el procesamiento del lenguaje natural.

A partir de este problema anterior, surge la necesidad de **generalizar** los modelos que se utilizan, para que dichos modelos sigan teniendo un rendimiento alto aun cuando se enfrentan a inputs que nunca antes habían recibido. Salman y Liu [37], en su estudio “*Overfitting Mechanism and Avoidance in Deep Neural Networks*”, hacen un análisis sobre cómo las redes de neuronas tienden a aprender de aquellas características más atípicas o de datos mal etiquetados, lo que afecta gravemente a la generalización del modelo. Los autores tratan la idea de que se debe tener un balance entre la complejidad del modelo, la regularización y el volumen de datos que trata el modelo, pudiendo así reducir el sobreajuste y garantizando, por tanto, la generalización. No solo se quedan en el análisis, sino que proponen una serie de técnicas que eviten el sobreajuste en los modelos. Dichas técnicas son la normalización (*batch normalization*) y el hecho de detener el modelo antes de que le dé tiempo a sobre aprender de los datos (*early stopping*). Como se puede apreciar en la Figura 7, sacada de un estudio que los autores hicieron con el *dataset* MNIST, en la imagen (a) se puede ver cómo a partir de un número de *epoch*, la pérdida que se produce en el entrenamiento es cada vez menor pero la pérdida en la parte de validación cada vez es más grande, precisamente por este sobreajuste a los datos. En la imagen (b) se ve que de igual manera afecta a la precisión del modelo.




Figura 7. Pérdida en el entrenamiento con el dataset MNIST [37].

Adicionalmente, Kawaguchi, Kaelbling y Bengio [38] hacen un estudio más en profundidad sobre la generalización en el *deep learning* en el que abordan el hecho de que los enfoques tradicionales de control de la capacidad del modelo no explican del todo el desempeño que se observa por parte del modelo. Apuntan que las redes de neuronas profundas tienen una capacidad casi ilimitada de representación de la realidad

Al final, el aprendizaje de estas redes neuronales depende del volumen de datos que sean capaces de tratar, siendo esta una de sus principales necesidades. Cuantos más datos, por tanto más ejemplos, más patrones de los datos va a poder sacar la red neuronal. De esto es precisamente lo que trata el estudio “*High-dimensional dynamics of generalization error in neural networks*” [39], en el cual se trata la relación que existe en estos modelos entre la dimensionalidad que tengan, es decir, el número de parámetros con los que trabaje, y el tamaño en sí que tenga el conjunto de entrenamiento con el error de generalización que tenga dicho modelo. Los autores muestran algunas estrategias que permiten mitigar la dependencia de los datos masivos como puede ser la de aprendizaje por transferencia (*transfer learning*), que consiste en que un modelo aprovecha el conocimiento que ya ha adquirido en una tarea previa para aplicar este a una nueva tarea relacionada.

2.3. Tipos de redes neuronales

2.3.1. Fundamentos y redes pre-deep learning

Perceptrón Multicapa (MLP)

El MLP es una arquitectura de redes neuronales artificiales del tipo *feedforward*, es decir, se propaga hacia delante. Esta arquitectura se compone de una serie de capas con neuronas, que también se denominan nodos, las cuales se organizan de forma jerárquica. Una de sus características principales es que se trata de una red neuronal densa, lo que implica que todas las neuronas de una capa están conectadas con todas las neuronas de la capa siguiente [40]. Tienen una estructura que se divide en tres grandes partes, la capa de entrada, las distintas capas ocultas que tenga la arquitectura en cuestión, y la capa de salida.

El hecho de que utilice *feedforward* quiere decir que la información solo va en una dirección y que en cada neurona se realiza un cálculo que ya se ha mencionado anteriormente. En cada una de ellas, se multiplican las entradas que se reciben por los pesos, se le suma un cierto sesgo y, al resultado, se le aplica la función de activación, como puede ser una ReLu o una función Sigmoide. Gracias a esta función de activación se pueden conseguir resultados no lineales, ayudando así a que la red aprenda relaciones más complejas [41].

El aprendizaje se lleva a cabo con la retropropagación. Como se ve en el artículo de [29], el MLP usa el error de la salida para así ir ajustando los pesos hacia atrás, siendo esto lo que llamamos el aprendizaje de esta red neuronal. Mediante el descenso de gradiente, la red calcula cuánto contribuyó cada conexión al error y va ajustando los pesos para corregirlos.

Este tipo de arquitectura sirve como aproximador universal, demostrando en el artículo publicado por [42] que el MLP con al menos una capa oculta puede aproximar cualquier función continua.

Como se puede observar, el funcionamiento del MLP sienta las bases del funcionamiento de las redes neuronales y, por tanto, de la inteligencia artificial. Cuando se explica cómo funcionan las redes neuronales, se está describiendo en parte cómo funciona el MLP. Casi todas las arquitecturas avanzadas como las CNN o las RNN utilizan principios de capas densas que derivan del MLP.

Red de Hopfield

Esta red es recurrente simétrica y fue propuesta por John Hopfield en 1982, tiene memoria asociativa de contenido. A diferencia de una red densa, este tipo de red lo que hace es almacenar patrones y “recordarlos” incluso con información incompleta o que tenga ruido. Tiene una estructura mono-capa, con la cual todas las neuronas están en la misma capa y actúan tanto como entrada como de salida. Todas las neuronas están conectadas con todas las demás, menos consigo misma. Tiene la característica de que sus pesos son simétricos, es decir, la conexión entre la neurona A y la B, es la misma que de la B a la A [43] [44] .

Este tipo de red neuronal trata de imitar el comportamiento físico del cerebro, tratando de buscar un estado de equilibrio con el concepto de la energía. Los patrones que se van detectando se van guardando según se ajustan los pesos de las conexiones entre las neuronas. Cuando alguno de esos patrones está corrupto o incompleto, las neuronas tratan de cambiar su estado de forma iterativo, entre activado y desactivado. La red tiene una función de energía que consume con las interacciones entre neuronas, la cual trata de minimizar para consumir la menor cantidad posible.

Es relevante ya que tiene una capacidad de recuperarse, es decir, de ser robusta y única, que destaca en cuanto a su optimización, como en el caso de la resolución de problemas como el de *Traveling Salesman Problem* [45]. Es el antecesor directo a las Máquinas de

Boltzmann y ha sido importante por mostrar cómo las redes neuronales pueden almacenar representaciones internas.

Máquina de Boltzmann Restringidas (RBM)

La RBM es un tipo de red neuronal recurrente estocástica que actúa como modelo generativo basado en energía [46]. El modelo base, la máquina de Boltzmann (BM), es una red neuronal estocástica que usa unidades binarias y también tiene un salto de energía basado en física estadística (la distribución de Boltzmann) [47].

A diferencia de una BM, en la que todas las neuronas pueden conectarse entre sí, en una restringida se impone una estructura de un grafo bipartito. Las partes que tiene son, la capa visible donde se ven representados los datos observados, y la capa oculta en la que es donde se aprende a extraer características de los datos. La restricción que se impone es que ninguna neurona tiene conexiones con ninguna otra neurona de la misma capa, haciendo así el cálculo más rápido [31]. El aprendizaje en esta red se da por un algoritmo llamado Divergencia Contrastiva que consiste en ir ajustando los pesos para que la red pueda reconstruir los datos de entrada a partir de sus representaciones en las capas ocultas.

Redes de creencia profunda (DBN)

Las DBN son el siguiente paso de las RBM ya que consiste en apilar varias de las últimas para así formar una red profunda. Introduce el entrenamiento en dos fases principales. La primera de ella es el pre-entrenamiento codicioso capa a capa (*Greedy Layer-wise Training*) donde cada capa se entrena como una RBM no supervisada y la salida de cada una de ellas sirve para la siguiente capa [48]. Esto reduce los problemas de gradiente en redes muy profundas. La segunda parte del entrenamiento es el ajuste fino o fine-tuning en el que, como ya la red conoce las características básicas, se añade una capa de salida y se entrena la red junta usando retropropagación para perfeccionar así los pesos [49].

2.3.2. Auge de la especialización

Redes convolucionales (CNN)

Las CNNs son el estándar para el procesamiento de datos en estructura de cuadrícula, como pueden ser las imágenes o los videos. Han tenido éxito ya que tienen una gran capacidad para la extracción jerárquica de características, queriendo imitar de alguna forma el funcionamiento del ojo humano.

Como se menciona en el artículo de Dumoulin y Visin [50], las CNN aprenden de forma jerárquica en la que las capas iniciales detectan bordes, colores y texturas, las capas intermedias son las que tratan de detectar formas con esas características, y las capas profundas son las que se encargan de reconocer los objetos completos que se están detectando.

Para entender cómo funcionan este tipo de redes hay que partir de la idea de que se tiene el filtro o *kernel* que va pasando por la imagen. En cada posición de la imagen, el filtro multiplica sus valores por los píxeles de la imagen y suma todo. Si el filtro después de


realizar esto tiene algún valor que puede coincidir con la forma de un borde dará un valor alto, si no, bajo.

A diferencia del MLP donde cada neurona se conecta con todas las demás, las CNN usan dos conceptos clave en su funcionamiento [30].

- Las neuronas no procesan toda la información, tan solo procesan pequeñas regiones de la imagen, por ejemplo, a la vez, teniendo así campos receptivos locales.
- Se utiliza el mismo filtro o *kernel* para toda la imagen, lo que consigue que se pueda reducir drásticamente el número de parámetros y permite detectar una característica de la imagen sin importar su posición. A este proceso se le llama la comparación de pesos o *weight sharing*.

Después de la convolución, es cuando viene la capa de *Pooling*, en la cual se mantiene el valor máximo de una pequeña región y esto sirve para que la red no se centre demasiado con la posición exacta, sino que solo se quiere guardar la información relevante, reduciendo así el tamaño de los datos.

Esta estructura se puede entender de manera gráfica en la Figura 8, donde se muestra el proceso que se seguiría en una CNN para detectar un número y clasificarlo correctamente.



Fuente 8. Estructura básica de una CNN [51].

Dentro de las CNN, hay distintos tipos de redes, dependiendo de cómo fluya la información entre sus capas y cómo se es capaz de gestionar la eficacia.

- CNN Clásica
 - En esta tipología se pueden destacar LeNet-5 o VGG. Son estructuras más secuenciales, teniendo una capa tras otra y se basan en el apilamiento de convoluciones y *pooling*. El problema que tenían es que según se añadían capas el gradiente se iba perdiendo, lo que limitaba el aprendizaje.
- CNN Residual
 - Se introducen las *skip connections* o conexiones de salto, donde en vez de forzar que cada capa tenga la visión completa, se permite saltar de capa. Esto permite el uso de más capas. ResNet hace que se aprenda de forma residual, lo que facilita la convergencia [52]. El DenseNet en cambio

conecta cada capa con todas las anteriores, reutilizando así las características.

- CNN Optimizadas
 - Son ejemplos de este tipo el MobileNet y el EfficientNet, que se enfocan en maximizar la precisión usando la menor cantidad de recursos computacionales posibles. El EfficientNet en concreto usa un método llamado *Compound Scaling* o escalado compuesto, que lo que hace es que en vez de hacer la red más profunda, escala uniformemente el ancho, profundo y resolución de la imagen [53].
- CNN Modernas
 - Con el paso del tiempo, han ido apareciendo otras arquitecturas que eran mejores que las CNN y por ello estas se han ido mejorando para poder competir. Se rediseñan las CNN clásicas, pero añadiendo las mejores prácticas que usan los *transformers* como el ViT. Utilizan *kernels* más grandes, normalización de las capas y estructura de etapas mucho más fluida. Un ejemplo de este tipo es el ConvNext que demostró que este tipo de CNN pueden competir con los *transformers* [54].

Redes recurrentes (RNN)

En el caso de las RNN ya no se procesan entradas independientes, sino que se espera que estas tengan un orden determinado y un contexto temporal. Hay una diferencia principal con las redes tradicionales, las RNN tienen conexiones hacia atrás, lo que hace que aparezca un bucle de retroalimentación. Esto hace que se pueda mantener un estado interno o memoria de lo que ha sucedido en pasos anteriores [29]. En vez de que la entrada que esperan sea estática, se procesan una serie de datos, donde la salida en el tiempo t no depende solo de la entrada actual, sino también de los tiempos anteriores.

La parte fundamental de una RNN es su estado oculto (h) donde, cuando se recibe una entrada, esta se combina con el estado oculto anterior y se genera un nuevo estado oculto que es el que pasa al siguiente paso. Esto permite poder capturar dependencias contextuales, lo que es vital para el procesamiento del lenguaje natural y el análisis de audio [55].




Figura 9. Estructura de una RNN [55].

Este tipo de red de neuronas tiene un problema considerable cuando se trata de recordar información que han obtenido hace mucho tiempo, es decir, las dependencias a largo plazo. Por ello, se ha ido evolucionando hacia versiones más avanzadas como son las LSTM (*Long Short-Term Memory*) que usan mecanismos para decidir qué información borrar y cuál guardar.

2.3.3. Arquitecturas de reconstrucción y generación

Arquitecturas de segmentación

La segmentación consiste en clasificar cada píxel de la imagen dentro de una categoría en específico.

Por un lado se tienen las arquitecturas Encoder-Decoder, la cual es la base de muchas otras arquitecturas posteriores. Tiene dos partes principales. El *Encoder* o codificador que se encarga de reducir el tamaño de la imagen mientras que se extraen las características de esta a través de una red de neuronas que puede ser de distintos tipos. El *Decoder* o decodificador toma esas características extraídas y las proyecta de vuelta en el tamaño original para clasificar cada píxel [56]. Este tipo de arquitecturas puede ser de gran utilidad en medicina, concretamente cuando se quiere delimitar de forma precisa alguna estructura pixel a pixel.

Por otro lado se tienen todas las subarquitecturas que aparecen desde U-Net. En el artículo de Ronneberger, Fischer y Brox [57], se muestra cómo se puede entrenar modelos que sean precisos teniendo pocos datos con este tipo de arquitectura. Tiene una estructura simétrica, de ahí la forma de “U”, debido a que la ruta de expansión, usada para localización precisa, es prácticamente idéntica a la de contracción, que sirve para capturar el contexto. Una característica importante que tiene esta arquitectura es que conecta las capas del *encoder* directamente con las del *decoder*, haciendo que la información espacial no se pierda durante la compresión, pudiendo así localizar estructuras de forma más precisa.




Figura 10. Estructura del U-Net [57].

Esta arquitectura ha ido evolucionando hacia modelos más especializados con los que se puede hacer una segmentación mucho más precisa. Existen variantes actuales como puede ser el caso del nnU-Net que reemplazan las convoluciones simples que se hacen en la arquitectura U-Net por bloques de ConvNext o por mecanismos basados en atención. Estos mecanismos de atención permiten que la red se enfoque solo en las regiones relevantes de la imagen, lo que ayuda a la precisión de diagnóstico. Un gran paso que se dio es el hecho de poder hacer segmentación médica en 3D gracias a modelos como el 3D U-Net, que permite procesar tomografías y resonancias con volumen tridimensional [58].

Modelos generativos

Mientras que en la arquitectura de *Encoder-Decoder* no impone qué debe ser la salida que se obtenga, en el caso de los *Autoencoders* sí que hay una gran restricción, la salida debe reconstruir la misma entrada. Por lo que todo *Autoencoder* es un *Encoder-Decoder*, pero no al revés.

Un Autoencoder es una arquitectura de red neuronal que se diseña para aprender representaciones de datos de manera no supervisada, teniendo como objetivo tomar una entrada, comprimirla y reconstruirla lo más fielmente posible [59]. Este proceso se puede ver en la Figura 11.





Figura 11. Estructura del *Encoder-Decoder* [59].

El proceso que se sigue parte de la entrada que recibe en *encoder*, la cual la comprime en una representación con menor dimensionalidad llamada espacio latente o *embedding*. Cuando se ha hecho esto, se llega a una pequeña red llamada *bottleneck* o cuello de botella, que se encarga de que solo se guarde la información más relevante. Después de esto, el *decoder* toma esta representación comprimida e intenta reconstruirla tal cual como estaba al inicio de todo. El uso de este tipo de redes es útil ya que al reducir la dimensionalidad, supera a otras técnicas más clásicas al capturar relaciones no lineales, así como elimina el ruido con el *bottleneck* [59]. Estos *Autoencoders* han ido evolucionando hasta modelos como el que se muestra en Kingma y Welling [60] en los que se demuestra que se pueden generar datos de forma probabilística con este tipo de arquitecturas.

También hay una serie de arquitecturas de redes de neuronas que han cogido especial relevancia en los últimos años ya que permiten generar contenidos, como los *deepfakes*, vídeos o audios, entre otros. En concreto, destacan las redes GAN (Generative Adversarial Network), propuestas por Goodfellow *et al.* [33] ya que revolucionaron el funcionamiento de las redes, basándose en una confrontación entre ellas para así aprender.



Fuente 12. Estructura de las GAN [61].

El generador trata de crear los datos sintéticos para recrear el contenido real y así poder llegar a engañar al discriminador para que lo identifique como real. El discriminador en cambio tiene que encargarse de saber detectar bien qué contenido es real y cuál ha sido creado. Cuando el discriminador detecta un contenido falso, el generador se va ajustando en base a lo que ha fallado con respecto al contenido real y así va mejorando. Esto se

repite hasta que llega un punto en el que el generador ya ha aprendido los detalles del contenido y consigue que el discriminador lo clasifique como real en vez de como falso.

Este tipo de redes son especialmente relevantes ya que consiguen, por ejemplo, crear contenidos hiperrealistas o generar datos sintéticos para entrenar modelos.

Este tipo de redes tienen un problema y es que son más inestables, difíciles de entrenar y muchas veces generan imágenes borrosas y poco delimitadas. De la mejora de estas redes, como se muestra en el artículo de Radford, Metz y Chintala [62] aparecieron las redes DCGAN, las cuales estabilizan las GAN para imágenes usando convoluciones. Este comportamiento se muestra en la Figura 13.




Figura 13. Estructura de una DCGAN [62].

Para que la nueva red fuese más estable, se hicieron una serie de cambios en su arquitectura. Uno de ellos fue que se quitó el *pooling* para pasar a usar convoluciones estratificadas en el generador para aumentar el tamaño de la imagen desde un vector de ruido y en el discriminador se hacen convoluciones con *stride* o paso largo para reducir la resolución. También se eliminan las capas densas usando así una estructura convolucional como se ve en la Figura 13, ayudando a la red a aprender relaciones espaciales de los píxeles. Se usa *batch normalization* y se usan funciones de activación específicas, usando en el generador ReLu para todas las capas menos la salida, donde usa Tanh, y en el discriminador usando LeakyReLu.

2.3.4. La revolución de la atención

Arquitecturas más modernas fueron surgiendo como fue el caso de los *transformers*, que marcaron la decadencia de las RNN y empezaron a ser competidores directos de las CNN. Actualmente, los *transformers* suponen la base de la IA moderna.

Las RNN procesan la información paso a paso, lo que hace que se pueda generar un cuello de botella y afectar así al rendimiento, al igual que les cuesta tener almacenamiento a largo plazo. En el artículo de Vaswani *et al.* [13] se introducen los *transformers*, los cuales utilizan la *self-attention*. Este mecanismo hace que cada elemento de una secuencia del objeto que se quiera procesar esté apuntando a los demás elementos, todos a la vez, para

entender así el contexto global. Con esta estructura, al no ser paralelas, se pueden entrenar mucho más rápido con las GPUs actuales y, al tener relaciones globales, no importa el orden de la secuencia que recojan, ya que el propio *transformer* calcula su relación.




Figura 14. Estructura de un transformer base [63].

Un ejemplo de transformer se muestra en el artículo de Dosovitskiy *et al.* [64] donde presentan ViT (Vision Transformers). La estructura que sigue ViT es que, en vez de procesar toda la imagen a la vez, lo que hace es dividirla en forma de cuadrícula en parches o *patches* de, por ejemplo, 16x16. Cuando se tienen estos *patches*, cada uno de ellos se convierte en un vector, llamando a este proceso linealización o *flattening*. Con esos vectores, se hace lo que se denomina *position embedding*, que consiste en añadir información sobre la posición del *patch* para que la red sepa a donde corresponde dentro de la imagen. Con todo esto, se hace el procesamiento de atención en el que la red analiza cómo cada uno de los *patches* se relaciona con los demás para así entender la representación de la imagen completa. Este proceso se puede ver reflejado en la Figura 15.




Figura 15. Estructura del ViT [64].

Ya no solo en el campo del procesamiento de imágenes, los transformers forman parte de herramientas que se usan a diario como son los modelos de lenguaje (LLMs) o modelos multimodales, ya sea especializados o generales.

Un ejemplo conocido de LLM es el caso de GPT-5 o de Gemma, que son utilizados por millones de personas a diario y que son capaces de entender una cantidad sorprendente de parámetros y generar así un lenguaje similar al humano con una coherencia significativa.

Los modelos multimodales también están ganando importancia, especialmente en el ámbito médico, como puede ser el caso del modelo Med-Gemma de Google. Este modelo es de especial referencia ya que ha sido entrenado con destinos contenidos médicos, ya sea imágenes, literatura o casos clínicos, por lo que presenta las características perfectas para poder usarlo con *fine-tuning* para ayuda al diagnóstico de enfermedades [65] [66].

Los *transformers* muestran por tanto que para poder procesar información no hace falta que se haga de una forma secuencial, gracias al mecanismo de *self-attention* se puede saltar entre las partes más relevantes del contenido que se esté analizando. Mientras que las CNN solo ven los datos colindantes, los ViT quitan esta idea al poder ver una imagen como un conjunto de conceptos con una relación. Como se puede ver en el artículo de Steiner *et al.* [67], la atención es capaz de superar a la convolución porque no asume nada sobre la imagen que está tratando, dejando así que las propias características de la imagen determinen qué es lo relevante.

Esta arquitectura supone un cambio de paradigma dentro de la IA, haciendo que se abandonen modelos especializados y rígidos como las CNN o las RNN, para pasar a modelos universales y masivos que se basen en la atención.

2.3.5. Nuevos paradigmas y bio-inspiración

Redes de Spiking (SNN)

Este tipo de redes neuronales se basan en los impulsos discretos o *spikes*, queriendo así dejar de lado los valores continuos como son los pesos, ya que se pretende poder imitar la comunicación electroquímica que hay entre las neuronas cerebrales de las personas. En una SNN las neuronas solo se activan cuando alcanzan un umbral tras recibir los impulsos. Esto supone una gran eficiencia ya que no se usan las neuronas a menos que haya un impulso que las despierte, lo que es extremadamente conveniente para hardware especializado. No solo importa el hecho de que se reciba el impulso, sino que también existe una dimensión temporal en la que depende del momento exacto en el que ocurra el impulso [68].

Estructuras no euclidianas (*Graph Neural Networks* - GNN)

En redes neuronales como las CNN se asume que los datos están posicionados en estructuras euclidianas, es decir, en forma de rejilla o píxeles, por ejemplo. Las GNN definen los datos como distintos nodos y las relaciones entre estos datos constituyen las aristas entre los nodos. Para poder pasar información, se actualiza la información de la que dispone cada nodo dependiendo de la información que reciba de sus nodos vecinos. Al tratarse de grafos, hay invarianza ante la permutación ya que da igual el orden en el que listes los nodos, la estructura de la conexión siempre es la misma. Las GNN son de especial relevancia para el mundo de la biología y química ya que pueden resultar de especial ayuda para el desarrollo de medicamentos o para predicciones en sus desarrollos [69] [70].

2.4. Aplicación de las Redes Neuronales en Medicina

2.4.1. Aplicaciones generales

Las redes neuronales y, en concreto, técnicas de deep learning, son cada vez más utilizadas dentro del ámbito sanitario. Ya no son solo experimentos teóricos sobre lo que se podría hacer, sino que están empezando a crearse herramientas que tratan de modificar la práctica clínica actual.

Las redes neuronales aportan una gran ventaja al poder encontrar patrones definidos en datos masivos o muy complejos, superando con creces la capacidad del ojo humano de detectar anomalías muy sutiles.

Un ejemplo de esto es el uso de estos avances de la tecnología en la rama de la cardiología y el procesamiento de señales médicas. Gracias a redes como las RNN o las LSTM (*Long Short-Term Memory*) se consiguen analizar datos que varían continuamente en el tiempo, como puede ser el caso de un ECG, pudiendo detectar arritmias sutiles o predecir fallos cardíacos. Este tipo de redes neuronales funcionan especialmente bien en la

monitorización de datos que, por ejemplo, estén extraídos por dispositivos inteligentes o wearables que tengan puesto los pacientes.

Ya no solo en lo que es del diagnóstico son útiles las redes de neuronas, también en el ámbito de investigación médico son de gran relevancia. Son de gran ayuda para predecir estructuras proteicas, lo que es vital para poder ayudar al diagnóstico de enfermedades raras, o también ayudan a simular compuestos, haciendo que se reduzcan los años de investigación necesarios para predecir qué compuestos serán más efectivos frente a virus o bacterias. Por ejemplo, la Agencia Europea de Medicamentos publicó una guía concretamente para establecer unas directrices sobre el uso de la IA en el desarrollo de fármacos y de ensayos clínicos [71].

Ha evolucionado hasta tal punto el uso de estos modelos que la Organización Mundial de la Salud (OMS) llegó a publicar la primera guía mundial para la gobernanza y ética de la IA aplicada a la salud [72]. De esta forma, estableció el marco estándar para el uso de redes neuronales a nivel global que estuviesen destinadas al sector médico.

Más recientemente, la FDA (*Food and Drug Administration*) de Estados Unidos ha publicado una actualización de la lista de *Medical Devices*, que se basan en IA y machine learning, que están autorizados para su uso en los hospitales [73]. En esta lista se recogen más de 1.000 dispositivos que se basan en IA/*machine learning* autorizados, y se destaca especialmente que el 75% de ellos están destinados al área de radiología.

2.4.2. Aplicaciones en diagnóstico por imagen

Aparte de todos los usos ya mencionados, el área más madura es la de diagnóstico por imágenes. Se usaban en su mayoría CNN para distintos casos de uso que mejoran la predicción de enfermedades, aunque recientemente han ido apareciendo nuevas arquitecturas que se están adentrando en el sector sanitario, como es el caso de los *transformers*.

Un caso de uso es con la detección precoz de algunos tipos de cánceres como puede ser el de mama o melanomas, pudiendo identificar los primeros signos de la enfermedad a través de las mamografías o de las imágenes dermatológicas respectivamente.

También hay un uso extendido de este tipo de modelos para el tratamiento y análisis de imágenes de tomografías (TAC) y de resonancias magnéticas (MRI). Con ellas, se pretende hacer una segmentación automática de los tumores cerebrales, medición de tamaño de algunos órganos o la detección de enfermedades neurodegenerativas. Gracias a las radiografías de tórax, por ejemplo, se es capaz de detectar enfermedades como puede ser la neumonía.

La Comisión Europea, ha destinado a su proyecto “Horizonte Europa” una inversión significativa para el despliegue de IA multimodal que ayude a acelerar el diagnóstico del cáncer [74]. Esto recalca el hecho de que el uso de la IA puede traer beneficios significativos a la población general, y ya concretamente en el ámbito de la salud, puede

mejorar e incluso llegar a salvar muchas vidas si se proporcionan los medios para llevar una investigación más minuciosa.

2.4.3. Arquitecturas clásicas aplicadas a imágenes médicas

Una representación clara de que realmente estas arquitecturas clásicas se consideran a la hora de ayudar al diagnóstico es la que se ve en el artículo de Yang *et al.* [75], en la que se comparan once arquitecturas de redes neuronales para el caso de ayuda al diagnóstico clínico de patologías pulmonares en pacientes de COVID-19. En este artículo se pueden ver tres de los modelos que se han utilizado en la parte de desarrollo de este proyecto, siendo estos el ResNet50, el DenseNet121 y el EfficientNetB0. Además de estos, estudian el desempeño de otros modelos clásicos como son VGG [76], Inception [77], SqueezeNet, MobileNet y ShuffleNet. No solo comparan el rendimiento de los modelos, sino que también experimentan con el uso de distintas configuraciones, como el número de *epoch* y *batch size*, y datasets para ver cuáles son los mejores.

Teniendo en cuenta que el artículo parte del supuesto que se trabaja con *datasets* pequeños, no hay una arquitectura ni modelo claramente ganadora.

En la Figura 16, se puede ver una tabla resumen de las principales arquitecturas mencionadas en dicho artículo, así como sus principales aportaciones.

Arquitectura	Año	Innovación clave	Ventaja en medicina
VGG	2014	Uso de pequeños filtros (3x3) y una gran profundidad	Es muy sencilla de implementar y es excelente para aprender texturas finas en tejidos
Inception	2014	Tiene módulos “inception” que procesan la información a distintas escalas en paralelo	Es ideal para detectar lesiones de diferentes tamaños (tumores grandes vs pequeños)
ResNet	2015	Conexiones residuales (<i>skip connections</i>) para evitar que el gradiente se pierda	Permite tener redes muy profundas, habiéndose vuelto el estándar en radiografías y TACs complejos
DenseNet	2017	Conecta cada capa con todas las capas siguientes	Reutiliza las características, por lo que es muy eficiente cuando hay pocos datos médicos
EfficientNet	2019	Escalamiento compuesto, equilibrando profundidad, ancho y resolución	Tiene la máxima precisión con el menor coste computacional

Figura 16. Tabla comparativa de los modelos

De los modelos estudiados en profundidad en este documento se obtienen las siguientes conclusiones:

- El RestNet50 se posiciona como una de las arquitecturas más equilibradas y flexibles, teniendo una capacidad superior para mitigar posibles problemas de gradiente gracias a sus conexiones residuales. Es consistente aun variando el tamaño de lote y se recomienda como modelo base para cualquier estudio con imágenes médicas.
- El DenseNet121 funciona mejor cuando trabaja con un *dataset* más acotado. También destaca ya que, al conectar todas las capas, aprovecha mucho mejor la información que recoge de la imagen con menos parámetros que el ResNet. Destaca por su eficiencia de parámetros.
- El EfficientNetB0 consigue los mismos resultados, o incluso mejores, que modelos mucho más pesados como puede ser el VGG, utilizando así bastante menos poder computacional. Aunque es el modelo más optimizado, puede ser muy sensible con la configuración de los hiperparámetros y la resolución de la entrada.

Aunque actualmente existen otras arquitecturas nuevas como los *transformers*, estas arquitecturas más clásicas siguen siendo las que más se utilizan en entornos sanitarios y de investigación ya que son las que requieren menor capacidad de cómputo y su comportamiento es más predecible.

2.4.4. Modelos específicos diseñados para imágenes médicas

En cuanto a este tipo de modelos, destacan los modelos de segmentación clásica, como es el caso del *U-Net* original que conforma el punto de partida de muchas segmentaciones médicas [57]. Una mejora de este modelo original es el *Attention U-Net*, ya que mejora la precisión que se obtiene al enfocar el modelo a estructuras relevantes más pequeñas de las imágenes, como pueden ser los tumores cerebrales, y además suprimen el ruido de fondo [78].

Otra mejora de esa arquitectura base marcada por el *U-Net* se ve en el artículo de Zhou *et al.* [79], en el que se muestra cómo conseguir un mejor rendimiento entre el codificador y el decodificador mediante el uso de caminos de salto densos.

Estos modelos anteriores trabajan con representaciones en 2D como son las imágenes. Desde ese punto ha habido una nueva evolución, siendo ahora el estado del arte, y son los modelos de segmentación pero en 3D. Con ellos se consigue analizar mejor los volúmenes de los datos que se recogen de un MRI o de un CT, por ejemplo.

Como se puede ver en el ejemplo de Milletari, Navab y Ahmadi [80] donde se analizan imágenes del cáncer de próstata, con este tipo de modelos que incluyen nuevas variaciones con respecto a la base, se consigue estudiar este cáncer mediante imágenes de MRI en 3D.

El estado del arte en este punto se encuentra en el modelo de nnU-Net ya que consigue automatizar el preprocesamiento, la arquitectura y el entrenamiento [81]. Para todos los estudios actuales que se realizan es el mayor competidor y contra el cual se intentan obtener conclusiones en las competencias con otros modelos o arquitecturas.

De este tipo de modelos, surgen algunas versiones las cuales ya están preentrenadas, lo que ayuda al rendimiento cuando se tienen pocos datos etiquetados. En el caso del modelo Med3D se tiene este planteamiento, estando preentrenado con varios *datasets* médicos para así poder acelerar investigaciones posteriores que partan de su uso [82]. También, hay casos más específicos como es el de RadImageNet, utilizado en el presente trabajo, que están mucho más focalizados, en este caso en radiografías [83]. Esto se hace ya que queriendo centrarse en el ámbito médico, de esta forma se consigue superar a ImageNet, que son imágenes genéricas, y así se pueden obtener mejores resultados en investigaciones de carácter médico.

Como se ha comentado antes, se tiende recientemente hacia el uso de *transformers*, viendo este comportamiento de igual forma en el ámbito médico. Esto se puede ver en el modelo de TransUNet, cuya estructura se encuentra en la Figura 17, que mezcla las capacidades de las CNN y de los *transformers* para conseguir así una segmentación precisa de los órganos [84].




Figura 17. Estructura de TransUNet. Siendo (a) la capa del *transformer* y (b) la estructura que propone este modelo [84].

Como se puede ver también en el artículo de Hatamizadeh *et al.* [85], se hace este modelo híbrido entre CNN y *transformers*, en este caso con el modelo UNETR, para conseguir segmentar imágenes médicas como se ve en la Figura 18.




Figura 18. Estructura general del modelo UNETR, con codificador *transformer* y decodificador CNN [85].

2.4.5. Modelos multimodales aplicados a medicina

Los modelos multimodales permiten que la IA no reciba tan sólo imágenes, sino que ayudan a que se entienda un contexto dentro de la literatura médica y, por ejemplo, el historial del paciente.

Unos de los hitos principales que han ocurrido en los últimos años en referencia a este tipo de modelos son los modelos de CheXNet y el de CheXpert. Aunque estos modelos no entran dentro de ser multimodales, ya que predicen etiquetas, se consideran relevantes ya que sentaron las bases de cómo poder procesar imágenes de forma masiva.

El primero de ellos, el CheXNet, consiste en una red de neuronas densas entrenada con más de cien mil imágenes médicas, en concreto radiografías de tórax [86]. Fue relevante ya que ayudó a mejorar el rendimiento que se tenía a la hora de detectar la neumonía. Posteriormente, se evolucionó hacia el modelo CheXpert, con el cual se introducían datos masivos, pero con etiquetas de incertidumbre, que lo que pretendían era ayudar al modelo a detectar las enfermedades cuando el diagnóstico no es claro, como sucede en el entorno médico real [87].

Posteriormente, se siguió evolucionando este tipo de modelos hasta llegar a los modelos multimodales como los que hoy en día se conocen. En 2023 aparece el modelo multimodal BioMedCLIP, que aplica el aprendizaje contrastivo utilizando un *dataset* de quince millones de imágenes pareadas con texto de artículos científicos [88]. Este tipo de aprendizaje consiste en tratar de acertar el diagnóstico mediante la ayuda de los textos. Su característica más relevante es el *zero-shot learning*, que consiste en que este modelo puede detectar enfermedades que nunca antes había visto en su entrenamiento, ya que entiende la relación entre las imágenes que recibe y los textos que las acompañan.

Un ejemplo más reciente de este tipo de modelos es Med-Gemma, siendo un conjunto de modelos que están diseñados por Google en específico para el entorno sanitario [89]. No se trata de un modelo de clasificación, ya que concretamente entra dentro de los LLMs (Large Multimodal Model) y puede resultar de gran ayuda, por ejemplo, para la redacción de informes y para la ayuda al diagnóstico.

2.4.6. Modelos planteados para el presente trabajo

En el presente trabajo se han podido utilizar en la parte práctica cinco modelos que se van a comentar en profundidad para así entender su funcionamiento. Además de estos, se han querido incluir, por su gran relevancia, dos modelos especializados que se plantearon estudiar, pero que por razones que se expondrán posteriormente no se acabaron desarrollando.

ResNet50

Cuando comenzaron a surgir las redes neuronales, se tendía a pensar que cuanto más profunda fuese esta red, mejor. Se acabó demostrando en el artículo de He *et al.* [52] que al añadir más capas en la red, el error del entrenamiento en vez de disminuir, aumentaba, y esto no se trataba de un *overfitting*, sino a la degradación del gradiente.

Aunque hay modelos más pequeños, se ha querido utilizar la versión del ResNet50. Esta versión utiliza una serie de bloques *bottleneck* o cuello de botella con los cuales trata de ser más eficiente computacionalmente, manejando así la carga en sus 50 capas, de ahí el nombre. La estructura del bloque consiste en tres capas convolucionales, ya que es un modelo CNN. Este bloque utiliza tres capas convolucionales distintas:

- Una primera capa 1x1 con la que reduce la información que recibe
- Una segunda capa 3x3 que es donde se realiza el procesamiento de la información
- Una tercera capa 1x1 que restaura la información a la dimensión original que tenía

La red está organizada empezando por una capa inicial a la que la siguen cuatro etapas principales o *stages*. Estos bloques se repiten siguiendo el patrón de [3, 4, 6, 3]. Esta estructura se puede ver en la Figura 19.




Figura 19. Estructura del ResNet50 [90].

Los mismos autores que en el primer artículo escribieron una evolución del modelo, demostrando que el orden en el que se ponen las capas sí afecta al resultado [91]. En este artículo se presenta la pre-activación, donde se mueve el *batch normalization* (BN) y la ReLu antes de la convolución. Esto causa que la información fluya mejor, beneficiando así al gradiente, y mejorando el entrenamiento en redes que son muy profundas.

En el artículo de Xie *et al.* [92] se introduce el concepto de cardinalidad. Esto consiste en que, en vez de simplemente hacer la red más profunda, se hacen una serie de grupos de convoluciones en los bloques. Esta es la evolución del ResNet50, manteniendo la complejidad computacional, pero aumentando la capacidad de representación del modelo.

DenseNet

Este modelo parte del artículo de Huang *et al.* [93], que ganó el premio del *Best Paper Award* en CVPR 2017. Marca los fundamentos de este modelo de CNN ya que, en vez de que cada capa reciba solo la entrada anterior o la suma de las entradas anteriores como en el ResNet, en este caso se introducen las conexiones densas. Esto quiere decir que cada capa recibe la información de todas las capas anteriores a ella mediante la concatenación de estas. Utiliza la reutilización de características en las que, al saber las de las capas anteriores, no tiene que aprenderlas, lo que hace que se reduzca el número de parámetros necesarios.

Este modelo tiene dos tipos principales de bloques:

- El *dense block* que es donde se produce la concatenación de las características de las capas
- La *transition layer* que son las capas que unen los dense blocks y se encargan de reducir el tamaño y el número de canales para tener así un mejor rendimiento

El 121 que acompaña al nombre representa el número total de capas convolucionales que tiene el modelo:

- Se tiene 1 capa inicial
- Siguen 4 *dense blocks* con una configuración de bloques de [6, 12, 24, 16]. Dentro de cada bloque se tiene la estructura de:
 - $\text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}(1 \times 1) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}(3 \times 3)$
 - Esto genera un total de 116 capas ya que $(6 + 12 + 24 + 16)$ de configuración de los bloques por 2 convoluciones que tiene cada bloque
- Hay 3 *transition layer* entre los bloques densos
- Se tiene 1 capa final de clasificación

Esta estructura se puede ver a grandes rasgos es la Figura 20.




Figura 20. Estructura del DenseNet121. Se están mostrando cinco capas y con $k=4$ [93].

Otro parámetro importante a tener en cuenta es el *growth rate* (k) ya que esta define cuántos mapas de características se añaden en cada capa nueva dentro de un *dense block*.

En una versión posterior que se sacó de este mismo artículo, se presentó una actualización del modelo, siendo este el DenseNet-BC, siendo este realmente el que más se suele usar. Este cambio se hizo buscando que la red fuese más eficiente y se produjeron dos cambios principales que dan lugar al nombre de este modelo mejorado:

- El *bottleneck* (B) donde antes de la convolución 3×3 se añade una capa 1×1 para así reducir el número de canales de entrada, ayudando así a que sea más manejable y computacionalmente más eficiente
- La *compression* (C) consiste en que en las *transition layers* se reduce el número de mapas de características con un factor de reducción $\theta \in (0,1]$ para comparar así el modelo. Si este factor es mayor a 0,5 entonces la *transition layer* reduce a la mitad el número de canales que recibe

Este modelo generaba problemas en cuanto al rendimiento en memoria, como se puede ver en el artículo de Pleiss *et al.* [94]. Concretamente se abordan los problemas de RAM y VRAM que se causan por culpa de la concatenación constante ya que se crean copias redundantes. Proponen una solución que se basa en compartir almacenamiento y en un tratamiento inteligente de los gradientes durante el proceso de *backpropagation*.

EfficientNet-B0


En el artículo de Tan y Le [53] se presentaba este modelo como solución a los problemas de pérdida del gradiente y a rendimientos ineficientes de los modelos. Anteriormente para tratar de mejorar un modelo, lo que se hacía era añadir más capas, pero esto traía consigo una serie de problemas que causaban que los modelos fuesen ineficaces. Este modelo

aportaba como mejora el concepto del *compound scaling*, que consiste en escalar simultáneamente y de forma equilibrada la profundidad, ancho y resolución de la imagen.

Tiene como base una red de búsqueda de arquitectura neuronal (NAS) que ayuda a maximizar la precisión y la eficiencia. Su bloque fundamental es el MBConv (*Mobile Inverted Bottleneck Convolution*) que son convoluciones separables en profundidad con conexiones residuales y módulos *Squeeze-and-Excitation* (SE) para la atención de los canales.

La estructura de bloque general tiene la siguiente estructura, que también se puede ver en la Figura 21:

- $\text{Conv}(1 \times 1) \rightarrow \text{BN} \rightarrow \text{Swish} \rightarrow \text{DepthwiseConv}(3 \times 3 / 5 \times 5) \rightarrow \text{BN} \rightarrow \text{Swish} \rightarrow \text{SEBlock} \rightarrow \text{Conv}(1 \times 1) \rightarrow \text{BN}$



Fuente 21. Estructura del EfficientNetB0 [95].

Para este escalado que incorporan, cada uno de los tipos de EfficientNet usan un coeficiente distinto, siendo en el caso del B0 $\phi = 0$. La función de activación concreta que se usa en este modelo es la Swish ya que esta ha demostrado mejorar el rendimiento en redes profundas. Para el proceso de aprendizaje de la red se usa el módulo *Squeeze-and-Excitation* el cual determina qué canales son los más relevantes y aplicando un peso a cada canal de características.

Este modelo es mucho más eficiente y, gracias a su menor coste computacional, es más relevante a la hora de dispositivos móviles o con pocos recursos.


Med-Gemma

Este modelo parte de la familia Gemma que son modelos de lenguaje abierto contruidos por Google DeepMind. Se pueden ver estos modelos en el artículo de Gemma Team *et al.* [96], los cuales son abiertos a investigación y desarrollo comercial, pero no de código abierto al público.

El Med-Gemma no es un modelo que parte de cero en su entrenamiento, sino que consiste en una versión con *fine-tuning* de Gemma pero con imágenes y datos dentro del ámbito médico. Como se puede ver en el artículo de Google de Selligren *et al.* [89], este modelo está basado en Gemma 3 y tiene una arquitectura de *transformer* para procesar la

información de manera secuencial y así entender el contexto complejo detrás de los datos médicos.

Como se puede ver en la Figura 22, se tiene un preentrenamiento del modelo con distintos tipos de información, bien sean imágenes y/textos, para posteriormente afinar con datos concretos sobre los que se quiera basar el estudio que se esté realizando.



Fuente 22. Estructura del Med-Gemma [89].

Tiene un codificador de visión como SigLip que está entrenado específicamente con imágenes médicas para convertir estas en representaciones numéricas o *embeddings*. Con ello, se une el resto de la información de la que se disponga dentro del modelo *transformer*.

Con este modelo se trata de mejorar la comprensión de los datos médicos y ayudar así a la predicción y al conocimiento dentro del ámbito médico. Está diseñado para ser eficiente, pudiendo ejecutarse de manera satisfactoria en entornos con una VRAM limitada. Como gran ventaja, se puede destacar que tiene una ventaja de contexto con la que se pueden obtener mejores resultados al poder basarse en historiales clínicos o artículos científicos.

nnU-Net

Este modelo tiene la misma estructura que la base de la que parte, el U-Net, pero con una diferencia significativa y es que representa el estado del arte en segmentación médica actual. No pretende ser un nuevo modelo desde cero, sino demostrar que si se optimiza bien su arquitectura base se es capaz de superar cualquier otro modelo complejo.

La base de este modelo surge del artículo de Ronneberger, Fischer y Brox [57], donde se puede ver en su estructura, como se ha compartido anteriormente, tiene forma de U, de donde viene su nombre.

Como se ha comentado anteriormente, un problema en el desarrollo de investigaciones como la que se está llevando a cabo en este documento es que los *datasets* pueden ser heterogéneos, teniendo así una necesidad de filtrado y ajuste muy compleja. Gracias a este modelo, gran parte de ese proceso se puede automatizar, ya que se decide durante la ejecución qué tipo de planificación de la red se necesita y qué configuración necesita [81]. Dentro del preprocesamiento puede ajustar la resolución y normalizar la intensidad, así como en el entrenamiento ir variando el *batch size* y la función de pérdida. Con esto se demuestra que no es necesario una arquitectura nueva, sino que se necesita configurar la que se tiene de la manera que más se ajuste a los datos que se quieren estudiar.

Antes de entrar en el funcionamiento concreto de este modelo, es crucial entender que no se trata de una red neuronal al uso, sino que es más bien un *framework* sistematizado que pretende eliminar las posibles decisiones subjetivas del investigador. Lo primero que ocurre es que el sistema saca los datos más relevantes de las imágenes, como la distribución de intensidades en los píxeles, el espacio físico entre cortes y el número de clases, entre otros. Tras esto, nnU-Net divide los parámetros entre tres categorías:

- Fijos o *blueprint*
 - Como función de activación se usa Leaky ReLu y en vez de usar *batch normalization* se usa *instance normalization*, ya que esto favorece a los casos con lotes pequeños de imágenes en 3D.
 - La función de pérdida es una combinación entre *Dice Loss* y *Cross Entropy*, lo que ayuda a que haya mayor rendimiento ante órganos muy pequeños en imágenes grandes.
- Basados en reglas o heurísticas
 - Cuando encuentra características distintas en las imágenes, trata de normalizarlas mediante la técnica de *resampling* para que la red no se confunda con las diferentes formas en las que se muestran los mismos datos. También puede calcular el tamaño máximo de los patches para así ver cuánto es el máximo de la GPU y así no bloquearla [97].
- Empíricos para el *fine-tuning*
 - Se hace un ensemble con las distintas versiones que genera (2D, 3D y/o Cascada) y hace una comparación de ellos para elegir así el mejor con validación cruzada.

ConvNextLarge

Este modelo surge como necesidad de respuesta por parte de las CNN ante el creciente éxito de los *transformers*. En el artículo original de Liu *et al.* [54] se puede ver como los autores exponen que el rendimiento que los *transformers* tienen superior no es por la arquitectura en sí, sino por cómo se entrena y las decisiones de diseño.

Los autores partieron de la estructura de una ResNet50 y la fueron modificando con características de los Swin Transformers. Hubo dos cambios fundamentales que se introdujeron:

- Se cambia la estructura de las etapas que tenía el ResNet a una más cercana a la que tienen los *transformers*, ajustando el número de bloques en cada etapa a [3, 3, 27, 3].
- Se sustituye la etapa inicial del ResNet de la convolución de 7x7 y el *pooling* por una capa de *patchify*, que consiste en una convolución de 4x4 con *stride* de 4. Con esto se consigue segmentar la imagen de manera parecida a como los *transformers* generan sus *patches*.

Este modelo usa Depthwise Separable Convolutions, lo que significa que cada canal se procesa de forma individual, reduciendo así los parámetros y permitiendo aumentar el tamaño del *kernel* a 7x7. Al aumentar este *kernel*, la CNN puede ver relaciones contextuales más amplias, como hacen los *transformers*. Trabajos como el artículo de Howard *et al.* [98] sirve de base para este tipo de optimizaciones pero optimizado para alta escala.

Se utiliza lo que se denomina *inverted bottleneck*, ya que primero se expande con una convolución la dimensión, posteriormente se procesa con una convolución 7x7, y finalmente se comprime para reducir la dimensión de nuevo. Esta estructura general se puede observar en la Figura 23.




Figura 23. Estructura general del ConvNext [99].

Como se demuestra en el artículo de Liu *et al.* [54], la clave de este modelo ha sido la simplificación, como cambiando ReLu por GELU (*Gaussian Error Linear Units*), cambiando el *batch normalization* por *layer normalization*, o con la separación de funciones de normalización y activación, previamente pegadas en la estructura.

En concreto, el modelo ConvNextLarge está pensado para competir contra Swin-Large, un *transformer*. Quiere demostrar que las CNN pueden competir con arquitecturas más modernas cuando son configuradas de la manera correcta.

ViT

El artículo original de este modelo es el de Dosovitskiy *et al.* [64] y en él se explica cómo ViT consigue crear una secuencia a través de la rejilla de píxeles que se puede extraer de una imagen. La imagen se divide en distintas partes iguales a la que se les denomina *patches*, como se explicó anteriormente, y cada una de estas partes se aplanan y se convierten en un vector numérico, también llamado *embedding*. El hecho de hacer este proceso hace que no haga falta que se trabajen los *patches* de forma secuencial, lo que mejora el rendimiento general del modelo. El concepto base de este funcionamiento se ve en el artículo de Vaswani *et al.* [13], y en el de Dosovitskiy *et al.* [64] se ve aplicado a imágenes.

Siguiendo la arquitectura de BERT de Devlin *et al.* [100], el ViT tiene un vector extra al inicio de la secuencia de *patches* de la imagen, al que se le llama *[CLS] token* o *Class Token*. Con ello se quiere conseguir que este *token* sirva como representación general, aunque resumida, de toda la imagen, que posteriormente se entrega a una cabeza de clasificación o *MLP Head*.

Una de las partes fundamentales del modelo es precisamente esta cabeza a la que se le llama *Multi-Head Self-Attention*. Su función es permitir que cada uno de los *patches* de la imagen pueda interactuar con los demás, sin importar lo distantes que sean. Esto es una gran mejora ya que mientras que en las CNN lo que se recibe está limitado por el tamaño del *kernel*, en el ViT se tiene un campo receptivo mucho más grande. Esto ayuda a poder tener un contexto general complejo de la imagen [64] [13].

En el artículo original del modelo se demuestra que, por tener un sesgo inductivo mucho menor que las CNN, teniendo así que aprender las relaciones espaciales prácticamente de cero, se tiene un rendimiento menor cuando se trabaja con *datasets* pequeños [64]. En el caso de las CNN se tiene una serie de sesgos como la localidad, que muestra que los píxeles vecinos están relacionados, o la invarianza de traslación. El ViT, consigue superar esa falta de sesgo inductivo cuando se trata de entrenamientos a gran escala, siendo ahí cuando se supera a las CNN, ya que le permite capturar patrones mejor que con filtros más rígidos como en el caso de las convoluciones.

Este modelo presentaba un gran problema en cuanto a complejidad computacional, ya que cuando se trabaja con imágenes de mayor tamaño o resolución se necesitan muchos recursos. Como evolución para solucionar este problema surgió el *Swin Transformer* que, mediante *Window Attention*, conseguía que, en vez de atención global, solo se hiciese a través de esas ventanas. Además, incorpora *Shifted Windows*, lo que hace que las ventanas se puedan comunicar entre sí en capas sucesivas, haciendo así que se vuelva a conseguir la capacidad de modelado global. También aporta cambios en cuanto a su estructura, alejándose de la que tiene el ViT y acercándose a la que tienen las arquitecturas como el U-Net, en la que se reduce la resolución y se aumentan los canales según se profundiza [101]. Esta estructura de ventanas se puede observar en la Figura 24.




Figura 24. Comparativa del tratamiento de la imagen entre *Swin Transformer* y ViT [101].

2.4.7. Aplicaciones de diagnóstico en enfermedades neurológicas

Para el presente trabajo se han considerado dos grupos de enfermedades neurológicas, por un lado las que son neurodegenerativas y desmielinizantes, como el Alzheimer, el Parkinson y la esclerosis múltiple, y por otro lado tumores y lesiones expansivas.

Enfermedades neurodegenerativas y desmielinizantes

Para este tipo de patologías, el *deep learning* se centra en detectar las atrofonas que causan y los posibles cambios en la sustancia blanca del cerebro.

- El Alzheimer y el Parkinson en su base son más parecidos, ya que ambos generan atrofonas en el cerebro, cambiando principalmente su localización. Mientras que el Alzheimer atrofia principalmente el hipocampo y los lóbulos temporales y parietales [102], el Parkinson suele afectar más a los ganglios basales, también denominado sustancia negra [103]. Con modelos de IA se trata de detectar patrones sutiles de las atrofonas antes de que sean tan evidentes que con el ojo humano se puedan detectar.
 - En el artículo de Lian *et al.* [104] se propone un modelo que no solo clasifique la enfermedad de Alzheimer, sino que pueda localizar las regiones más afectadas por la patología. Una arquitectura FCN (*Fully Convolutional Network*) para aprender de imágenes 3D, donde los autores concluyen que al centrar la atención en el hipocampo el AUC (*Area Under the Curve*) mejora.
- La esclerosis múltiple es desmielinizante, lo que quiere decir que se producen lesiones en la sustancia blanca del cerebro, las cuales pueden simular atrofonas [105].
 - Uno de los retos que pueden surgir con enfermedades como esta es la de saber si el tratamiento está funcionando o no. Para ello, como se muestra

en el artículo de Krüger *et al.* [106], se pueden utilizar modelos de *deep learning* para comparar dos MRI del mismo paciente con el uso de *3D Convolutional Neural Networks*, y ver así si las lesiones cambian.

- También suele pasar que como las lesiones son sutiles, pueden pasar desapercibidas por el ojo humano. Para ello sirven de gran ayuda este tipo de modelos, como se puede ver en el artículo de Eijlers *et al.* [107]. Gracias a estos modelos, usando el *deep learning* para hacer un análisis de las texturas del cerebro, se puede saber el estado de la sustancia blanca, adelantándose así a la detección de lesiones.

Tumores y lesiones expansivas

Para estas enfermedades no solo se pretende clasificar, sino que también se debe delimitar la masa, como con métodos de explicabilidad, para localizar así la patología.

- Los gliomas son infiltrantes, lo que los hace difíciles de delimitar. Pueden confundirse con un absceso o incluso con esclerosis múltiple tumefacta, que es una lesión que puede parecer un tumor. Este tipo de tumores, que pueden subdividirse en Astrocitoma y Glioblastoma, se originan en las células gliales, las cuales tienen un crecimiento infiltrativo, siendo eso lo que causa que no se pueda segmentar automáticamente [108].
 - Este tipo de tumor es complejo de detectar por su naturaleza infiltrativa. En el artículo de Bakas *et al.* [109] se puede ver el desafío BraTS que trata de la detección de tumores cerebrales mediante segmentación. Se define que los modelos tienen tres áreas fundamentales que segmentar, la que indique el núcleo del tumor, la que indique el tumor en sí y una última donde se vea el edema.
 - Hay un artículo que demuestra que estas técnicas de IA ayudan a mejorar la detección como el de Chang *et al.* [110] en el que se demuestra que con una ResNet se puede saber si el glioma tiene la mutación IDH, la cual es relevante a la hora de poder evitar cirugías innecesarias.
- Los meningiomas son extra-axiales, que quiere decir que se generan fuera de la estructura del cerebro, naciendo en las meninges, y están bien delimitados normalmente, suelen desplazar masa pero no se infiltran tanto [111].
 - Se ha demostrado en distintos estudios cómo el *deep learning* ayuda tanto a la detección de enfermedades como a analizar, en este caso tumores, de cara a cirugías, esto se puede ver en el artículo de Bouget *et al.* [112].
- Los tumores pituitarios tienen una localización concreta en la silla turca, en la glándula hipófisis [113]. Puede confundirse con un aneurisma o con quistes si no se usa contraste en el proceso de obtención de la imagen.

Como se puede observar para todas las enfermedades, el *deep learning* tiene gran influencia en el ámbito médico ya que puede ser muy relevante de cara a la ayuda al diagnóstico.

2.4.8. Reto de la explicabilidad

La explicabilidad de los modelos es una preocupación recurrente dentro del estudio médico, ya que es importante que se muestre el procedimiento que se ha seguido hasta obtener las conclusiones, en este caso diagnóstico, al que se haya llegado.




Figura 25. Número de artículos publicados al año de análisis de imágenes médicas [114].

Como se puede observar en la Figura 25, cada vez tiene más importancia la explicabilidad de los modelos aplicados al ámbito médico. Concretamente, hay estudios como el de van der Velden *et al.* [114] que hablan sobre métodos de explicabilidad para el diagnóstico a través de mapas de calor en las imágenes, permitiendo así al personal sanitario validar las conclusiones a las que lleguen los modelos. Se le da especial importancia a estos métodos de explicabilidad visual ya que son los más rápidos de identificar por parte de la persona que recibe el diagnóstico e indica las características concretas que inclinan el diagnóstico. A esta explicabilidad de la IA también se la llama, en inglés XAI, como se puede ver en la figura.

Como se puede ver en el artículo recogido por Ghassemi *et al.* [115], la explicabilidad es un problema ya no solo ético, sino también clínico. Habla sobre si realmente métodos como el Grad-CAM son realmente fiables para la detección de patologías en imágenes médicas como MRI o Rayos X. En este artículo se concluye que estos métodos de

explicabilidad no sustituyen el criterio crítico del personal sanitario ya que presentan limitaciones.

Para poder llevar a cabo esta explicabilidad y convertir las activaciones neuronales en información de diagnóstico útil y comprensible para el personal sanitario, hay diversas formas de hacerlo dependiendo en qué se basen los modelos.

En el caso de modelos que estén basados en gradientes y activaciones, los dos principales métodos de explicabilidad son el Grad-CAM y el Layer-CAM.

El Grad-CAM o *Gradient-weighted Class Activation Mapping* es el estándar para las redes neuronales convolucionales (CNN). Genera un mapa de calor o *heatmap* superpuesto a las imágenes, resaltando las áreas donde los gradientes de la última capa convolucional son más fuertes. Esto puede ayudar al personal sanitario a evaluar el resultado del diagnóstico aportado por el modelo, ya que se puede ver si se ha fijado, por ejemplo, en una masa tumoral o en algún artefacto concreto de la imagen. Todo el desarrollo de este método de explicabilidad se ve recogido en su artículo original redactado por Selvaraju *et al.* [116].

Una evolución de este es el Layer-CAM, que permite obtener mapas de calor más precisos ya que puede combinar información de distintas capas, y no solo de la última. Esto hace que sea más fácil detectar microlesiones neurodegenerativas, por ejemplo, las cuales el Grad-CAM podría no señalar.

Para los que son métodos de perturbación y de teoría de juegos se usa más el *Occlusion Sensitivity* y el SHAP (*Shapley Additive explanations*).

El método de Occlusion consiste en cubrir sistemáticamente partes de las imágenes con parches de algún color sólido, y ver cómo este hecho afecta a la probabilidad de la predicción. Al trabajar de esta forma es computacionalmente más costoso, aunque se usa porque aporta una validación más intuitiva ya que, si la región específica del modelo deja de detectar el tumor, ya se sabe que ahí está la posible patología.

Basado en la teoría de juegos aparece el SHAP, que usa técnicas *model-agnostic*, es decir, es compatible con cualquier tipo de arquitectura que tenga el modelo. En su funcionamiento asigna a cada pixel o región, dependiendo del estudio, un “valor de Shapley”, indicando así cuánto contribuyó esa zona a la conclusión final respecto a la predicción media que se haya conseguido. Como bien se puede ver en el artículo de Lundberg y Lee [117], su uso también se extiende a imágenes y a trabajar su interpretación.

En cuanto a la explicabilidad en los modelos que actualmente están más en la vanguardia como son los *transformers*, se encuentra principalmente el método de *Attention Rollout*. Este método se centra en ver cómo fluye la información dentro de los distintos *patches* de la imagen y con ello mapea la atención de la red. Este proceso se recoge en profundidad por Abnar y Zuidema [118], donde se explica todo el proceso de cómo se consigue procesar la atención que está poniendo el modelo.

2.4.9. Retos éticos y regulatorios del uso de la IA en medicina

En este apartado se quiere centrar el foco en aquello que está faltando o fallando dentro de la investigación científica, concretamente médica, en el entorno de la medicina. Se trata de un enfoque más crítico y prospectivo.

El principal riesgo ético que puede surgir es entre el derecho individual a la privacidad y protección de datos y el derecho a la salud con el beneficio colectivo que implica la investigación. Las restricciones legales actuales, centradas principalmente en asegurar la privacidad de los pacientes, ralentizan la investigación en materia médica. Se podría dar una cierta paradoja ética ya que al proteger tan exhaustivamente la privacidad individual, estamos privando a la sociedad de una herramienta de diagnóstico, por ejemplo, que ayude a mejorar vidas. La falta de acceso a los datos masivos, los cuales pudiesen aportar su consentimiento, no es solo un problema técnico, sino que forma parte a ser un problema de desarrollo conjunto en el que nunca se estarían obteniendo los resultados todo lo buenos que se podría.

Adicionalmente, se está burocratizando cada vez más la ciencia, en el que se puede ver que en el caso hospitalario, la gestión de proyectos de IA implica cambiar las prioridades, teniendo que dedicar una gran parte del tiempo a gestionar aspectos legales. Esta necesidad de desviar el foco de la investigación hacia la elaboración de trámites hace que se genere un coste de oportunidad grave. La innovación médica se ve desplazada a regiones que tengan marcos regulatorios más laxos, lo que genera un riesgo de que los modelos sean dependientes de otros estándares éticos.

La falta de disponibilidad de datos para el entrenamiento hace aparecer un reto tanto técnico como ético, ya que se depende de la información obtenida solo de algunos hospitales o regiones que permitan el uso de dichos datos. Esto genera un gran sesgo en las investigaciones, haciendo que los resultados no puedan ser confiables y que las conclusiones obtenidas siempre sean incompletas.

Estos problemas se deben resolver para poder avanzar en el desarrollo tecnológico en el ámbito médico, y ya concretamente en el caso de asistentes a diagnóstico como se presenta en este documento. Se debería fomentar la anonimización avanzada de los datos, haciendo que en vez de bloquear los datos por defecto, se debería favorecer sistemas de Aprendizaje Federado. En ese tipo de aprendizaje, los datos no salen del centro en el que se encuentren, la información no sale de sus dueños originales, tan solo las conclusiones y el conocimiento que obtuviesen los modelos entrenados por esos datos. De esta forma, se estarían protegiendo los datos de los pacientes a la vez que no se detiene el desarrollo tecnológico.

Estas cuestiones son también recogidas en distintos artículos académicos que abordan la importancia de tener la cuestión ética presente. Un ejemplo de ello se puede ver en Geis *et al.* [\[119\]](#) donde se habla en específico del sesgo que puede haber en los *datasets* por parte de las imágenes, así como de la responsabilidad en la que se incurre cuando se comente un error de diagnóstico de la IA.

2.5. Limitaciones de los enfoques actuales

Pese a que el desarrollo y la aplicación de la inteligencia artificial al campo de la medicina viene ya desde hace tiempo, sigue habiendo grandes limitaciones que provocan que cada vez cueste más escalar ciertos resultados o que surjan nuevas necesidades para poder seguir explotando las funcionalidades.

Ya en la subdisciplina del *machine learning* se pueden apreciar limitaciones en cuanto a la gran dependencia que hay de la calidad de las características principales que se sea capaz de sacar, determinando en gran medida la calidad de los resultados obtenidos. Esto se podría paliar de alguna manera si se pudiesen usar grandes cantidades de datos, pero esos modelos tienen escasa capacidad para trabajar con grandes volúmenes de datos. Pese a esto, sí que tiene el beneficio de tener una gran interpretabilidad ya que dispone de diversas herramientas para mostrar los resultados obtenidos y así poder explicar por qué se ha decidido lo que se ha presentado como resultado. Esto último, como se ha explicado anteriormente, es vital dentro de los entornos clínicos en los que se quiere encasillar el presente documento.

También, en la subdisciplina del deep learning, existe la misma limitación en cuanto a los volúmenes de datos que se necesitan para obtener resultados de alta calidad. En modelos como los que se han entrenado en este proyecto, la cantidad de datos de los que disponga el *dataset* va a ser extremadamente relevante a la hora de la fiabilidad de los resultados obtenidos. Cuantos más datos, mejores resultados se podrán conseguir. En los modelos de *deep learning*, en este caso destinados al ámbito médico, sigue habiendo una gran limitación en cuanto a la explicabilidad de los resultados que arrojan los modelos. También, cómo se explicará más adelante, la integridad de los datos en cuanto a posibles sesgos que pueda haber en los *datasets* es un condicionante importante del desempeño de los modelos.

Uno de los mayores problemas, y de donde surge la necesidad de utilizar herramientas de explicabilidad como las que se explican en este trabajo, es por el efecto de caja negra que hacen los modelos a la hora de tratar los datos, como se comenta en el artículo de Kelly *et al.* [120]. Los modelos proporcionan un diagnóstico, pero sin estas herramientas no se sabe el por qué cree que es una enfermedad u otra, por ejemplo.

También, en el caso de que no se disponga de unos datos generalizados de entrenamiento, si se cuenta con una muestra concreta de un hospital, por ejemplo, puede surgir el problema que se plantea en el artículo de Zech *et al.* [121] que demuestra que los modelos pueden llegar a aprender artefactos concretos de las imágenes de las máquinas específicas de un hospital, condicionando así su uso externo.

Por último, como destaca Finlayson *et al.* [122], los modelos de IA son susceptibles a ataques que provoquen cambios graves en los modelos y, por tanto, en los diagnósticos. Como se resalta en el artículo, un cambio sutil en los píxeles de las imágenes puede hacer que la red neuronal cambie completamente su configuración, haciendo así que falle su

diagnóstico. Por ello, se plantea una gran vulnerabilidad de los modelos a la vez que una preocupación por la ética médica que debe seguirse.

3. RESULTADOS

3.1. Estructura del desarrollo

En esta parte de desarrollo se hace un recorrido desde el punto de partida en el que se tiene que decidir de dónde se va a empezar el proyecto, eligiendo las características del *dataset* y de dónde sacarlo, hasta las conclusiones sobre los resultados finales obtenidos. Se pretende plasmar cómo, mediante la metodología elegida de CRISP-ML(Q) se consigue llevar a cabo el proyecto que se planteó en apartados anteriores. Esta estructura se puede ver reflejada de manera resumida en la Figura 26.




Figura 26. Planificación del desarrollo del proyecto.

3.2. Preparación de los *datasets* para el estudio

Para poder comenzar la parte de desarrollo, y tras haber hecho todo el análisis previamente comentado, se necesitaba partir de la búsqueda de los *datasets* que se usarían en la prueba de los modelos. Concretamente, se estaban buscando imágenes de resonancias magnéticas del cerebro (MRI) y que tuviesen una vista de corte axial del cráneo, viéndose estas representadas en escala de grises.

Teniendo en cuenta las enfermedades en las que se ha decidido poner el foco, de las cuales se ha hablado previamente, se establecen 7 clases de clasificación distintas, siendo esto una clase por enfermedad y añadiendo una clase para los cerebros sanos sin ninguna patología neurológica. De esta forma, no solo se pretende conseguir que se clasifique correctamente la enfermedad que se muestre en la imagen, sino que también ayuda a hacer una clasificación adicional entre sí se encuentra alguna patología o no. Se trata de conseguir que los modelos estén sesgados lo mínimo posible, no haciendo así que por defecto tenga que detectar una enfermedad. Esta decisión también favorece al escalado de este tipo de soluciones, ya que abarca más posibilidades de detección.

El obtener un *dataset* con un tamaño suficiente y que estuviese compuesto por unas imágenes de calidad no fue sencillo, ya que no hay *datasets* extensos de uso general de estas enfermedades, por lo que se tuvo que recurrir a obtener *datasets* distintos por cada

una de las enfermedades a estudiar. Todos ellos fueron obtenidos de Kaggle y se validó que se podrían usar para fines como el del presente trabajo.

- En este *dataset* se encuentran imágenes de distintas enfermedades, las cuales todas se utilizan en este trabajo. Por un lado, se tienen imágenes divididas en carpetas sobre tres distintas etapas de la progresión de la enfermedad de Alzheimer. Por otro lado, se tienen tres carpetas con las imágenes referentes a los tres tipos de tumores cerebrales estudiados y otra carpeta de la enfermedad de esclerosis múltiple. También se tiene una carpeta de control con imágenes de cerebros sanos. Todo este contenido se encontraba en formato JPG/PNG. Se puede ver un ejemplo en la Figura 27 [\[123\]](#).





Figura 27. Ejemplos de imágenes del dataset [\[123\]](#).

- En el caso del Parkinson, se encontró un *dataset* que va enfocado a la clasificación binaria de la enfermedad, diferenciando así entre si se padece la patología o no. Todo este contenido se encontraba en formato JPG/PNG. Se puede ver un ejemplo de estas imágenes en la Figura 28. [\[124\]](#).



(Parkinson)

(Sano)

Figura 28. Ejemplos de imágenes del *dataset* [124].

- En el caso de la enfermedad de esclerosis múltiple fue complejo poder encontrar imágenes, ya que los *datasets* contenían imágenes en formato de “.nii”, que es un formato médico para captar mejor los volúmenes. Se eligió un *dataset* que disponía de imágenes de muchos pacientes distintos, en los cuales se incluían diferentes vistas [125]. Para poder utilizar estas imágenes junto al resto, se cambiaron de formato las imágenes con un código desarrollado para ello, quedando como en el Figura 29 [126].





Figura 29. Ejemplo de las imágenes del *dataset* [126].

- En el caso de los distintos tumores cerebrales, se tuvo que recurrir a distintos *datasets* ya que se necesitaba más volumen de imágenes que el que se encontró en uno solo. En estos, se pueden apreciar distintas carpetas de imágenes dependiendo del tipo de tumor del que se trate, así como en algunos casos una extra de control con cerebros sanos. Todo este contenido se encontraba en formato JPG/PNG y se puede ver un ejemplo en la Figura 30. [127] [128] [129].



(Glioma)

(meningioma)

(tumor pituitario)

Figura 30. Ejemplos de imágenes del *dataset* [127] [128] [129].

Con todo esto, después de haber limpiado las imágenes que no tuvieran buena resolución o el corte axial del cerebro que se quiere estudiar, se consiguen siete clases de clasificación distintas, una por cada enfermedad más la de los cerebros sanos. En este punto, se pasó a una fase en la que se decidió adaptar el *dataset* final obtenido a las características particulares de cada uno de los modelos que se quería evaluar, configurando así aspectos como la resolución de la imagen o la normalización que se hacía de la misma. Se decidió dedicar el 70% de las imágenes a entrenamiento, el 15% a validación y el 15% restante a test [130].

De esta forma se consiguió adaptar el *dataset* base a los distintos modelos haciendo transformaciones deterministas y no estadísticas, garantizando así que las imágenes resultantes tienen un significado físico e interpretable. Gracias a hacerlo de esta forma, se puede usar el mismo *dataset* base para todos los modelos, independientemente de que luego tengan arquitecturas o configuraciones particulares. Para tratar de evitar sesgos derivados del orden y disposición del *dataset* base, se hace un barajado explícito antes de dividir las imágenes.

Al estar obteniendo las imágenes de las enfermedades de distintas fuentes, podía darse el caso de que hubiese imágenes repetidas, lo que podía influir negativamente en los resultados del modelo. Este hecho podría causar que los modelos aprendan artificios de las imágenes en vez de las características clínicas relevantes de estas. Para tratar de reducir este riesgo al máximo, y al no poder decidir en base de las imágenes ya que variaba según la fuente, se decidió hacer una comparación de los *hashes* de las imágenes, evitando así que hubiese duplicados y obteniendo un conjunto de *dataset* final más pulido [130].

Esta manera de proceder, aun así, incurre en la aparición de un posible sesgo o leakage en el conjunto de *dataset* final a usar y, aunque se conocía este riesgo, se decidió seguir el estudio con ello y evaluar los resultados que se obtuvieron teniendo esto en cuenta. Este sesgo aparecía por el hecho de que, las imágenes de los cerebros están divididas en capas o *slices*, pero no se pueden detectar y separar las *slices* que pertenecen al mismo paciente en algunos *datasets*. Esto causa que puedan existir *slices* del mismo paciente en diferentes particiones, generando así esa fuga de información entre los datos de

entrenamiento, validación y test. Esta casuística causa que haya modelos de los estudiados que, en vez de aprender de las características clínicas más relevantes, se estén viendo influenciados y aprendiendo sobre artefactos concretos de las imágenes y/o el formato de estas. Aunque este es un riesgo esperado y controlado dentro de las posibilidades, es importante mencionar que por el objetivo del presente estudio que se está realizando, no es crítico y permite realizar un desarrollo bastante enfocado.

Con estos *datasets* finales, se pasa a una fase en la que se pretende que los distintos modelos sepan clasificar correctamente las imágenes en sus clases correspondientes.

3.3. Métricas de evaluación de resultados

Para poder analizar los modelos evaluados, hay que tener en cuenta una serie de métricas que se van a poder obtener de cada uno de los modelos ejecutados y con las que se va a evaluar su desempeño.

Por un lado, se tiene un informe de clasificación, el cual tiene distintas métricas que resultan de gran utilidad. Una de ellas es la **precisión**, que es la calidad de las predicciones positivas que se hacen, es decir, cuántas de las predicciones hechas eran correctas. Otra de ellas es la sensibilidad o exhaustividad (**recall**) que tengan los modelos, que indica la cantidad total de positivos que el modelo encontró. Puede parecer parecido a la precisión, pero en este caso se trata de, entre todos los positivos que existan, saber cuántos se lograron detectar. Esta métrica es importante ya que el coste de un falso negativo es especialmente alto cuando se trata de detectar enfermedades como las que se están estudiando.

Una vez que se tienen estas dos métricas, se puede obtener el **F1-score**, que es la combinación en medida de la media armónica entre las dos métricas anteriores. Sirve para equilibrar la visión global que se obtiene del resultado. Adicionalmente se muestra el soporte que tan solo indica el número real de ocurrencias de la clase en el set de datos, con lo cual entre todos los modelos debería ser el mismo. Si este valor está muy desbalanceado entre las clases, puede indicar que los resultados no serán muy confiables.

Al final de este informe, se añaden además tres métricas adicionales. La primera de ellas es la exactitud o *accuracy*, la cual indica el porcentaje total de aciertos, aunque es útil, no es una métrica suficiente para poder basarse solo en ella ya que depende del contexto del estudio que se esté haciendo. La segunda de ellas es el *macro average* que se calcula a partir del cálculo de la métrica para cada clase y saca el promedio simple, tratando todas las clases por igual. La tercera, y relacionada con la segunda, es el *weighted average* que calcula el promedio teniendo en cuenta el número de soporte de cada clase. Las clases con más ejemplos pueden tener más peso en el resultado final que se obtenga.

Por otro lado, se tiene la matriz de confusión de la clasificación entre las clases en la fase de test por parte de cada uno de los modelos. Básicamente esta matriz enfrenta lo que se predijo frente a la realidad, teniendo en el eje Y los valores reales y en el eje X las

predicciones del modelo. Con ella podemos ver entre qué clases se está equivocando el modelo, pudiendo así estudiar si tiene sentido o indica un posible fallo de entrenamiento.

3.4. Entrenamiento de los modelos de deep learning

Para poder desarrollar el entrenamiento y, pese a que se trata de un proceso de *fine-tuning*, se tiene una gran necesidad computacional. Se creó un notebook de Google Colab [\[131\]](#) en el que se fueron poniendo cada uno de los modelos pero, al tener esta necesidad computacional, ejecutarlo en local no era una opción ya que no se disponía de un equipo suficiente en el que no se llegara al tiempo máximo de ejecución de la versión gratuita del Colab.

Se solicitó el uso de entornos de ejecución de investigación a través de la universidad, consiguiendo acceso durante 3 meses a una GPU NVIDIA H200. Gracias a disponer de este equipamiento, se pudieron ejecutar los distintos modelos sin problemas, obteniendo los resultados que se van a pasar a comentar en el siguiente apartado.

El planteamiento inicial que se dio a este trabajo fue de trabajar sobre cinco modelos con características distintas que pudiesen proporcionar conclusiones distintas. Se empezó decidiendo usar el ResNet, ya que es ampliamente usado cuando se trata de clasificación médica, al que posteriormente se le sumó el DenseNet para poder comparar. Como versión más optimizada de CNN se decidió incorporar el EfficientNet y evaluar si esa optimización se notaba también en los resultados que se obtuviesen. Adicionalmente se querían añadir algunos modelos que estuviesen especialmente enfocados en el área médica y en la segmentación médica, y se eligieron el modelo de Google con imágenes médicas el Med-Gemma y el nnU-Net que destaca para segmentación.

Con todos ellos se pretendía hacer un ejercicio de *fine-tuning* y así poder hacer un estudio más específico y adaptado al conjunto de *dataset* que se había creado. Para poder hacer esto, se buscaron una serie de pesos de los modelos ResNet50 y DenseNet121 que estuvieran preentrenados con imágenes médicas, concretamente con RadImageNet [\[83\]](#). En el caso de EfficientNet, se optó por usarlo preentrenado con *ImageNet* y medir así posibles variaciones. Estas variaciones vendrían dadas por el hecho de que usando el modelo de esa forma, no estaría preentrenado tan solo con imágenes del contexto médico, sino que tendría distintos tipos de imágenes, estando así menos focalizado en la tipología de las imágenes que iba a recibir.

En el caso de los modelos de Med-Gemma y de nnU-Net, no se consiguió obtener estos pesos iniciales con los que poder hacer *fine-tuning* ya que no están disponibles públicamente. Pese a que se evaluaron distintas formas de seguir usándolos, al final se desistió con su evaluación ya que no se disponía de una forma viable que pudiese equipararse a los otros modelos que ya se estaban evaluando.

Como se ha comentado, para entrenar los modelos se creó un Google Colab en la que se fueron introduciendo las distintas partes de los modelos para su posterior ejecución.

El desarrollo comenzaba con la importación e instalación de las librerías necesarias, así como la configuración general de cada uno de los modelos. En esta parte es en la que se establecen los parámetros de entrenamiento como el número de *epoch* o los distintos directorios a los que necesita acceder. Posteriormente se configuran los generadores de datos para poder utilizarlos, en los que en la parte de *train* se hace un *shuffle* explícito para evitar así posibles sesgos del modelo.

- ResNet50
 - Se carga el modelo con los pesos que se han obtenido gracias a RadImageNet [\[83\]](#), pudiendo así hacer *fine-tuning* con las imágenes de MRI que se están estudiando en este proyecto.
 - Se añade la cabeza en la que se fija un *dropout* del 30% para evitar el sobreajuste y una capa “Dense” con función de activación *softmax* para hacer la clasificación.
 - Se añade una parte en la que se quiere conseguir adicionalmente la métrica de F1-Macro para poder obtener unas conclusiones más precisas.
 - Hay un bloque que trabaja los callbacks, que es donde se producen las siguientes acciones:
 - El guardado de *checkpoints*.
 - El *EarlyStopping*, que hace que si la validación empeora 3 *epochs* seguidos se pare el entrenamiento.
 - Se genera la matriz de confusión y el *heatmap* que arroja el Grad-CAM.
 - Se registran todos los *logs* para su posterior tratamiento y así poder obtener gráficas sobre el desarrollo del entrenamiento.
 - Con todo esto, cuando se termina el entrenamiento, se prueba con la parte de test, viendo así el rendimiento del modelo. Se guardan los pesos finales que se han obtenido, así como un reporte detallado con las métricas que se obtienen y la matriz de confusión final.
- DenseNet121
 - La estructura de este modelo es prácticamente idéntica a la del ResNet50, teniendo en cuenta que se cargan los pesos también de RadImageNet [\[83\]](#).
- EfficientNetB0
 - La estructura de este modelo vuelve a ser similar a la de los anteriores, pero con una característica diferencial. En lugar de cargar los pesos de RadImageNet, en este caso se usa ImageNet. Esto podría suponer un punto

de partida teóricamente peor que los demás modelos, aunque se demostrará que no es así.

Al comenzar a hacer pruebas en el entorno de ejecución, se vio su gran capacidad computacional, por lo que se decidieron añadir dos modelos nuevos que aportan nuevas visiones en cuanto al tipo de modelos que son. Dichos modelos son concretamente el ConvNextLarge, como CNN mejorada para competir con *transformers*, y ViT, un *transformer*.

- ConvNextLarge
 - Este modelo está entrenado de manera mucho más precisa y optimizada, tratando de aprovechar al máximo los recursos de la GPU H200. Se usa “*mixed_float16*”, que hace que los cálculos se realicen en 16 bits, manteniendo variables críticas en 32 bits. Con eso se consigue un entrenamiento más rápido, aunque la última capa se fuese a que sea de 32 bits para evitar errores.
 - Usa también *ImageNet* en vez de *RadImageNet*.
 - Su entrenamiento tiene dos partes. La primera de ellas sirve para entrenar lo que sería una cabeza nueva, haciendo así que el conocimiento previo no se pierda. La segunda es en sí ya llevar a cabo el *fine-tuning* con las imágenes que se tenían, utilizando un *learning rate* muy bajo.
 - Con este modelo sí que se llevan a cabo transformaciones en las imágenes con “*train_datagen*”, permitiendo así que el modelo soporte mejor el ruido y no aprenda de los artefactos de estas.
 - Se sustituye Grad-CAM por Layer-CAM ya que esta permite proporcionar una explicabilidad mejorada.
- ViT
 - Hay que tener en cuenta que este modelo es un *transformer*, no una CNN como lo eran los anteriores. Coge la imagen de 224x224 y la divide en *patches* de 16x16, teniendo un total de 196. El modelo va tratando las imágenes con Atención Global, tratando así de reconocer relaciones entre los *patches* que ha sacado.
 - Este modelo, en vez de estar entrenado con *ImageNet*, lo está con ImageNet-21k, habiendo pasado así de conocer 1.000 clases a 21.000.
 - En este caso, se utilizan tres funciones de activación distintas, dependiendo en qué fase se esté.

- En el *backbone*, la base del modelo se utiliza GELU ya que tiene una curvatura más suave que ReLU, no cortando en seco valores negativos.
 - En la capa “*Dense*” se utiliza ReLU ya que es el estándar en las capas intermedias por ser menos costosa computacionalmente a la par que efectiva.
 - En la capa de salida se usa la función *softmax* para convertir los números en probabilidades entre las 7 clases.
- Este modelo también entrena en dos fases, por un lado, se entrena la cabeza y por otro lado se hace el *fine-tuning*. Una característica de este proceso de entrenamiento es que se usa una *learning rate* muy baja, tratando así de no influir bruscamente en su conocimiento preentrenado.
 - El ViT está diseñado con HuggingFace/PyTorch, que requiere las imágenes en (canales, alto y ancho), pero el TensorFlow usa (alto, ancho, canales), por lo que hay una función “*Permute*” que hace de traductor. Por otro lado, el modelo devuelve un objeto con mucha información y la capa “*Lambda*” hace de filtro para el Keras para quedarse solo con las características principales, almacenadas en “*last_hidden_state*”.
 - En cuanto a la explicabilidad se utiliza *Attention Rollout* que accede a las matrices de atención del modelo, combina las de todas las capas y muestra un *heatmap* que representa en qué *patches* concretos está mirando el *CLS Token*, que es el nodo que toma la decisión final. Al final de cada *epoch* se llama a una función *callback* que muestra este *heatmap*.

Con los resultados de cinco modelos se consiguió una visión muy amplia ante CNN, arquitecturas modernas y *transformers*, viéndose sólo limitada por la falta que se ha comentado de modelos médicos especializados.

3.5. Evaluación de resultados de deep learning

Una vez que se ejecutaron los modelos, de cada uno de ellos se sacó el informe de clasificación de la parte del test y la matriz de confusión entre las distintas clases que se estaban evaluando en dicho test [\[132\]](#).

Se va a pasar a comentar cada uno de los cinco modelos evaluados teniendo en cuenta que se ha señalado los valores en los que se considera que hay especial relevancia. En las tablas del informe de clasificación, se ha marcado con un color verde claro los datos que superan el 90%, considerándose así buenos, y en un verde más intenso aquellos valores que superan el 95% por ser especialmente buenos. También, en las matrices de confusión, se ha resaltado en rojo intenso cuando los modelos se equivocan excesivamente en la clasificación, habiendo establecido el límite en diez o más errores para un error grave, y cualquier valor inferior se considera error leve y está indicado en un rojo claro.

Para la facilidad de visualización de las tablas, se ha abreviado el nombre de las enfermedades en Alzheimer (A), Esclerosis Múltiple (ES), Glioma (G), Meningioma (M), Parkinson (PA), Pituitaria (PI) y Sano (S).

Conclusiones generales

ResNet					DenseNet				
	Precisión	Recall	F1-Score	Support		Precisión	Recall	F1-Score	Support
Alzheimer	0,93	0,94	0,93	480	Alzheimer	0,88	0,95	0,91	480
Esclerosis múltiple	0,91	0,88	0,9	688	Esclerosis múltiple	0,87	0,88	0,87	688
Glioma	0,95	0,87	0,9	617	Glioma	0,91	0,83	0,87	617
Meningioma	0,86	0,83	0,84	546	Meningioma	0,76	0,73	0,74	546
Parkinson	0,92	0,96	0,94	681	Parkinson	0,9	0,91	0,91	681
Pituitaria	0,91	0,97	0,94	511	Pituitaria	0,85	0,93	0,89	511
Sano	0,84	0,89	0,86	618	Sano	0,82	0,79	0,8	618
Accuracy	-	-	0,9	4141	Accuracy	-	-	0,86	4141
Macro avg	0,9	0,9	0,9	4141	Macro avg	0,86	0,86	0,86	4141
Weighted avg	0,9	0,9	0,9	4141	Weighted avg	0,86	0,86	0,86	4141

(a)

(b)

EfficientNet				
	Precisión	Recall	F1-Score	Support
Alzheimer	0,95	0,97	0,96	480
Esclerosis múltiple	0,98	0,99	0,98	688
Glioma	0,99	0,97	0,98	617
Meningioma	0,96	0,99	0,98	546
Parkinson	1	1	1	681
Pituitaria	0,99	0,99	0,99	511
Sano	0,96	0,94	0,95	618
Accuracy	-	-	0,98	4141
Macro avg	0,98	0,98	0,98	4141
Weighted avg	0,98	0,98	0,98	4141

(c)

ConvNetLarge					ViT				
	Precisión	Recall	F1-Score	Support		Precisión	Recall	F1-Score	Support
Alzheimer	0,9874	0,9812	0,9843	480	Alzheimer	0,91	0,97	0,94	480
Esclerosis múltiple	0,9956	0,9826	0,989	688	Esclerosis múltiple	0,9	0,89	0,9	688
Glioma	0,9951	0,987	0,991	617	Glioma	0,93	0,88	0,91	617
Meningioma	0,9854	0,9872	0,9863	546	Meningioma	0,86	0,86	0,86	546
Parkinson	0,9956	1	0,9978	681	Parkinson	0,92	0,91	0,92	681
Pituitaria	0,9942	1	0,9971	511	Pituitaria	0,92	0,95	0,94	511
Sano	0,9713	0,9871	0,9791	618	Sano	0,87	0,87	0,87	618
Accuracy	-	-	0,9894	4141	Accuracy	-	-	0,9	4141
Macro avg	0,9892	0,9893	0,9892	4141	Macro avg	0,9	0,91	0,9	4141
Weighted avg	0,9894	0,9894	0,9894	4141	Weighted avg	0,9	0,9	0,9	4141

(d) (e)

Figura 31. Resultados del informe de clasificación de los modelos.

En la Figura 31 se muestran las distintas métricas para cada uno de los modelos evaluados en cada una de las enfermedades que se trata de clasificar. Se puede observar a simple vista que los modelos que han obtenido métricas generales muy buenas son el EfficientNet y el ConvNextLarge, teniendo prácticamente todos sus valores por encima del 95%. Esto indica que a estos modelos no les cuesta clasificar las imágenes correctamente.

También se aprecia en la Figura 31 (b) que en el caso del modelo DenseNet sí que le cuesta más clasificar las imágenes, teniendo valores en sus métricas incluso por debajo del 70%. Los modelos ResNet y ViT tienen buenos resultados, aunque muestran un margen de mejora en su clasificación.

Precision		Recall		F1 - Score	
AVG Precision A	0,93	AVG Recall A	0,96	AVG F1-Score A	0,94
AVG Precision ES	0,93	AVG Recall ES	0,92	AVG F1-Score ES	0,93
AVG Precision G	0,96	AVG Recall G	0,91	AVG F1-Score G	0,93
AVG Precision M	0,89	AVG Recall M	0,88	AVG F1-Score M	0,88
AVG Precision PA	0,95	AVG Recall PA	0,96	AVG F1-Score PA	0,95
AVG Precision PI	0,93	AVG Recall PI	0,97	AVG F1-Score PI	0,95
AVG Precision S	0,89	AVG Recall S	0,90	AVG F1-Score S	0,89

Figura 32. Comparativa de métricas medias entre modelos por enfermedad.

Por otra parte, se ha querido estudiar para cuál de las enfermedades estudiadas se consiguen métricas promedio mejores, y esto es precisamente lo que se recoge en la Figura 32.

Se aprecia que en general, para todas las enfermedades, se consiguen resultados buenos, teniendo gran parte de los mismos por encima del 90%. Esto muestra que en general hay una buena capacidad de clasificación por parte de los modelos.

Las enfermedades que mejor se identifican son las de PA, referente al parkinson, y PI que se trata del tumor de pituitaria. Dentro de la clase del Parkinson se puede destacar que sus métricas están muy equilibradas, y en cuanto al tumor de pituitaria, destaca su Recall con un valor del 97% indicando que los modelos prácticamente nunca pasan por alto imágenes que pertenecen a esta clase. Se puede apreciar que las clases del tumor de meningioma y de los cerebros sanos tienen bastante margen de mejora, teniendo por lo general valores por debajo del 90%.

Con todos estos resultados, se observa que son coherentes tanto desde la parte técnica como desde la parte clínica. Las clases con un mayor rendimiento general hacen referencia a enfermedades que tienen características más representativas, por lo que puede ser más sencillo para los modelos el detectarlas correctamente. Por ejemplo, el tumor pituitario tiene una ubicación concreta, lo cual lo hace más sencillo de identificar.

Por otro lado, las dos clases con menor rendimiento, los sanos y con meningioma, poseen unas características que hacen que sean más fácilmente confundibles. El meningioma puede confundirse con algunos tipos de gliomas o con otras patologías, y en el caso de los cerebros sanos lo que puede estar pasando es que los modelos se confunden buscando alguna patología arrojando así falsos positivos. Esto puede estar pasando porque las características patológicas sean en algunos casos muy sutiles o porque las imágenes no tengan la mejor calidad posible y hagan que aparezca un sesgo en la clasificación.

ResNet								DenseNet							
	A	ES	G	M	PA	PI	S		A	ES	G	M	PA	PI	S
A	449	0	0	0	0	0	31	A	454	0	0	0	0	0	26
ES	0	608	2	2	45	4	27	ES	0	604	4	10	37	1	32
G	0	5	534	53	3	9	13	G	0	9	511	70	7	9	11
M	0	5	22	452	4	38	25	M	1	10	29	396	4	75	31
PA	0	21	1	2	655	0	2	PA	0	46	2	3	620	2	8
PI	0	0	2	11	0	497	1	PI	0	0	8	26	1	475	1
S	36	30	3	5	8	0	536	S	58	24	9	19	19	0	489

(a) (b)

EfficientNet							
	A	ES	G	M	PA	PI	S
A	466	0	0	0	0	0	14
ES	0	678	0	1	0	0	9
G	0	0	600	16	0	1	0
M	0	0	3	541	0	2	0
PA	0	1	0	1	678	0	1
PI	0	0	1	4	0	506	0
S	23	12	1	0	1	0	581

(c)

ConvNetLarge								ViT							
	A	ES	G	M	PA	PI	S		A	ES	G	M	PA	PI	S
A	471	0	0	0	0	0	9	A	465	0	0	0	0	0	15
ES	0	676	0	0	3	0	9	ES	0	614	2	3	35	2	32
G	0	0	609	8	0	0	0	G	0	5	546	52	6	4	4
M	0	1	3	539	0	3	0	M	0	4	25	467	2	37	11
PA	0	0	0	0	681	0	0	PA	0	39	3	1	623	0	15
PI	0	0	0	0	0	511	0	PI	0	0	4	15	4	488	0
S	6	2	0	0	0	0	610	S	44	19	5	6	7	0	537

(d)

(e)

Figura 33. Resultados de las matrices de confusión de los modelos.

La Figura 33 representa los errores de clasificación que han tenido los distintos modelos evaluados. Como se podría ver con las métricas comentadas anteriormente, la mayor parte de las clasificaciones erróneas provienen de las clases de cerebro sano y meningioma. Pese a eso, hay modelos que se equivocan en la clasificación considerablemente más que otros.

En cuanto a sobre qué enfermedades son las que se están confundiendo en la clasificación, se sacan las siguientes conclusiones generales:

- Las imágenes de la enfermedad de Alzheimer se confunden en exclusiva con los cerebros sanos. En etapas iniciales de la enfermedad es común confundir esta enfermedad con un cerebro sano, ya que la enfermedad está provocada por una atrofia en áreas específicas que hace que se pierda volumen. Esto mismo puede pasar con el propio envejecimiento del cerebro, por lo que en algunos casos puede ser difícil diferenciar si se trata de un envejecimiento normal o el desarrollo de esta enfermedad en etapas iniciales.

- La enfermedad con la que más se confunde la esclerosis múltiple es el Parkinson, seguido por la clase de cerebros sanos. Es relativamente frecuente que se confundan las imágenes de cerebros con esclerosis múltiple con cerebros sanos ya que a veces es complejo detectar las lesiones provocadas por la enfermedad.
- Como se ha comentado anteriormente, el meningioma y el glioma se suelen confundir a la hora del diagnóstico, viéndose este hecho reflejado también la Figura 33. Destaca especialmente el caso de la confusión entre el meningioma con el tumor pituitario, ya que el número de errores es significativamente alto.
- La enfermedad con la que más se confunde el Parkinson es con la esclerosis múltiple, aunque también hay casos en los que se confunde con cerebros sanos. Aunque clínicamente no se confundan tanto, tiene sentido que los modelos las confundan debido a posibles artefactos de las imágenes que condicionen el diagnóstico y generen estos falsos positivos. También, en etapas avanzadas de ambas enfermedades, se pueden mostrar atrofas en la estructura del cerebro, lo que puede hacer que se malinterpreten los resultados.
- El tumor de pituitaria se suele confundir principalmente con los otros dos tipos de tumores cerebrales evaluados, principalmente con el meningioma pero también con el glioma.
- Los cerebros sanos se confunden mayoritariamente con la enfermedad de Alzheimer y con la esclerosis múltiple.

SUMA -->	Error grave	Error leve	Total
ResNet	352	56	408
DenseNet	523	67	590
EfficientNet	65	22	87
ConvNextLarge	0	44	44
ViT	339	62	401

Figura 34. Errores totales por modelo evaluado.

Como se puede observar en la Figura 34, el modelo Densenet tiene el peor rendimiento general por tener el mayor número de errores clasificando. En un punto medio se encontraría el ResNet y el ViT, con un número de errores similar. Este dato es relevante ya que el ViT no supera en rendimiento a los modelos convolucionales, habiéndose esperado que fuese un mayor competidor en cuanto a rendimiento. Esto puede deberse a la alta heterogeneidad de las imágenes del *dataset*, el número limitado de imágenes de las que se dispone y un sesgo ya comentado en cuanto a la distribución de las imágenes. Esto puede haber causado que el modelo ViT tuviese mayores problemas para generalizar, causando estos resultados peores que los esperados. Finalmente, los modelos EfficientNet y ConvnextLarge muestran resultados mucho mejores al tener un número de errores totales bastante inferior al resto.

Esta comparativa no es del todo justa ya que el modelo de ConvNextLarge ha sido entrenado por más epoch que el resto de los modelos, con lo cual era esperable que

arrojase resultados mejores. Los modelos de CNN tienen un *fine-tuning* con 10 *epoch*, mientras que en el caso de este modelo comentado se trataba de 5 *epoch* para entrenar la cabeza y 20 para hacer *fine-tuning*. Esto se quería hacer para ver la gran capacidad que muestra este modelo y demostrar que es competidor directo de los *transformers* actuales en cuanto a rendimiento. Por ello, de igual forma, se quería profundizar en las capacidades de los *transformers*, al ser estos el estado del arte actual, habiendo hecho el doble de *epoch*, es decir 20 en total, repartidos en 10 para la cabeza y 10 de *fine-tuning*.

Para sacar una visión más justa de la comparativa de los modelos, cuando el ConvNextLarge había hecho los 5 *epoch* para la cabeza, tenía las siguientes métricas, teniendo en cuenta que son las de entrenamiento.

Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
0,8854	0,8839	0,3048	0,8838	0,8821	0,2969

Figura 35. Métricas del ConvNextLarge en los 5 *epoch* de entrenamiento de la cabeza.

Cuando había realizado los 10 primeros *epochs* de *fine-tuning*, las métricas que se tenían eran las siguientes.

Epoch	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
5	0,9874	0,9869	0,0334	0,9708	0,9698	0,098
10	0,9964	0,9962	0,0115	0,9795	0,9788	0,0893

Figura 36. Métricas del ConvNextLarge en los 10 primeros *epoch* de *fine-tuning*.

De igual forma, en la Figura 37 se muestran los resultados de las métricas obtenidas en el caso del modelo ViT cuando había realizado 10 y 20 *epochs*.

Epoch	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
10	0,8914	0,8930	0,3046	0,8887	0,8900	0,3038
20	0,9053	0,9066	0,2716	0,8969	0,8978	0,2893

Figura 37. Métricas arrojadas por ViT en los primeros 10 y 20 *epoch*.

Para ahora poder comparar los resultados de las métricas de los entrenamientos de los distintos modelos, se han recogido dichas métricas tras los 10 *epoch* en la Figura 38. Para

ello, en los modelos de ConvNextLarge y ViT se han contado los *epoch* dedicados al entrenamiento de la cabeza.

Modelo	Accuracy	F1-macro	Loss	Val_Accuracy	Val_F1-macro	Val_loss
ResNet	0,9134	0,9113	0,2279	0,8928	0,8868	0,3064
DenseNet	0,8265	0,8263	0,4724	0,8515	0,8501	0,3919
Efficient Net	0,9827	0,9821	0,0498	0,9754	0,8747	0,076
ConvNext Large	0,9874	0,9869	0,0334	0,9708	0,9698	0,098
ViT	0,8914	0,8930	0,3046	0,8887	0,8900	0,3038


Figura 38. Desempeño de los 5 modelos tras 10 *epoch*.

Teniendo ahora una visión de cómo se encontraban los cinco modelos exactamente cuándo llevaban 10 *epoch* de entrenamiento, se observa que se llega al mismo resultado que el que se comentaba al inicio de esta sección, confirmando así que el hecho de tener distinto número de *epoch* los dos últimos modelos no ha sesgado los resultados.

También, como conclusión, también se puede observar que el hecho de haber decidido entrenar más los modelos más modernos, ConvNextLarge y ViT, no ha hecho que sus resultados aumenten con respecto a las métricas que arrojaban en la Figura 38.

Explicabilidad

Como se ha comentado anteriormente, la explicabilidad dentro de los resultados que arrojan los modelos empleados para la ayuda al diagnóstico es crucial, por lo que se han empleado este tipo de técnicas en los modelos evaluados. En las siguientes figuras se aprecian los resultados del Grad-CAM de tres de los modelos evaluados sobre las enfermedades del meningioma en la Figura 39 y del Alzheimer en la Figura 40.



(ResNet)

(DenseNet)

(EfficientNet)

Figura 39. Resultados del *heatmap* del Grad-CAM para el meningioma.

Como se aprecia en las imágenes de la Figura 39 por los colores rojizos, el modelo que más acierta en localizar el tumor es el EfficientNet, mientras que en el caso de los otros dos modelos está más disperso. El DenseNet sí que consigue localizar el tumor, aunque también se centre en otras zonas sanas, pero en el caso del ResNet ni se consigue detectar dónde está ubicada la patología.




Figura 40. Resultados del *heatmap* del Grad-CAM para el Alzheimer.

En la Figura 40 se ven las regiones marcadas del *heatmap* en los distintos modelos, siendo los resultados obtenidos a partir de imágenes distintas. Se supone que las áreas más rojizas es donde los modelos identifican que se encuentra la patología. Aunque a simple vista no es fácil determinar dónde está la enfermedad, cómo sí se podría hacer en el ejemplo anterior, se pueden usar las métricas de precisión para determinar si se ha localizado bien o no. Observando las imágenes de la Figura 40 de izquierda a derecha, se puede apreciar que cuanto más dispersa sea la zona que muestra, menos precisión en la localización tiene. Por ello, la figura referente al modelo EfficientNet es la que consigue, de nuevo, detectar la patología y localizarla con la mayor exactitud.




Figura 41. Ejemplo conseguido de salida del Attention Rollout con ViT

En el caso de los transformers, como es el caso del ViT, en vez de usar Grad-CAM se usa *Attention Rollout*, que genera un *heatmap* sobre la imagen, pero basándose en la estructura de patches de este tipo de modelos. Se puede ver un ejemplo de esto en la Figura 41.

En esta figura lo que está buscando el modelo son signos de atrofia, que son los patrones que va causando la enfermedad de Alzheimer. Ésta, suele detectarse en los ventrículos laterales, que están a los lados de la zona más oscura del medio, y en la corteza temporal. Estas áreas son las que están comprendidas dentro del rectángulo rojo de la Figura 42.




Figura 42. Ejemplo conseguido de salida del *Attention Rollout* con ViT

El color celeste indicaría que el modelo tiene una mayor activación al lado de los ventrículos, lo que tendría sentido ya que con esta enfermedad estos se expanden por la pérdida de tejido cerebral circundante. También se aprecia que ese mismo color está en los bordes del cerebro, por lo que se está detectando un ensanchamiento de los surcos cerebrales. También se aprecia que las características que detecta no son simétricas, lo que es común en etapas iniciales o moderadas de la enfermedad.

Pese a que se puedan empezar a concluir diagnósticos de figuras como la 42, el modelo aún arroja resultados con zonas difusas y poco precisas ($\approx 90\%$).

Rendimiento

Se ha querido también hacer una comparativa sobre el rendimiento que han tenido los modelos durante el entrenamiento, viéndolo de forma visual. No se tiene la gráfica del modelo ViT pero su rendimiento se presupone similar al mostrado en el ConvNextLarge ya que sus arquitecturas son las más parecidas.




Figura 43. *Epoch loss* para cada uno de los modelos.

En las gráficas de la Figura 42, se puede observar cómo han ido mejorando los modelos, viendo representado en naranja lo referente al entrenamiento y en morado lo de la validación. Se aprecia como en los primeros 5 *epoch* hay una mejora significativa de todos los modelos, tanto en entrenamiento como validación, a excepción de la validación del ConvNextLarge. Este modelo tras 10 *epoch* prácticamente se estanca y no sigue mejorando, aunque tiene aun así el mejor valor de todos.

Viendo que en la Figura 42 la pérdida del ViT está en torno a 0,3 se puede ver que, aunque su arquitectura se parezca más al ConvnextLarge, tiene un rendimiento muy similar al Resnet, lo que es coherente con otras conclusiones que se han ido sacando sobre los modelos en este estudio.

Pese a que los resultados obtenidos son buenos y muestran que los modelos han funcionado satisfactoriamente, para considerarlos hay que tener en cuenta el sesgo que se comentó al principio de esta sección, ya que hace que no puedan ser fiables al 100% si se estuviese buscando la máxima rigurosidad.

4. CONCLUSIONES Y TRABAJOS FUTUROS

Una vez realizado todo el trabajo, se puede concluir que se ha cumplido exitosamente el objetivo principal que se había fijado ya que se ha hecho un estudio completo de cómo se podrían establecer las bases de un asistente al diagnóstico. Se han evaluado distintas arquitecturas y modelos, habiendo obtenido una vista general del estado del arte aplicable a un proyecto de estas características.

No solo se ha tratado de obtener métricas de los modelos y hacer una comparación de ellas, sino que se ha ido más allá tratando de entender la profundidad de los conceptos que se estaban tratando y los posibles riesgos o sesgos que se podrían presentar. Se ha abordado en profundidad cómo sería el tratamiento de datos médicos óptimo para este tipo de desarrollos en ámbitos en los que se quiera la máxima rigurosidad.

El estudio que se ha realizado proporciona una amplia visión general sobre el panorama actual de la aplicación de modelos de IA al entorno médico. En consecuencia, se han conseguido cumplir todos los objetivos que se habían planteado para este proyecto.

El valor aportado por el presente trabajo son las lecciones aprendidas y el conocimiento práctico que se ha obtenido, independientemente de que los resultados no busquen tener una rigurosidad minuciosa. El trabajo aporta valor al sector médico mediante los siguientes puntos:

- Se ha tratado de hacer una selección lo más minuciosamente posible de los datos que conformaban el *dataset* final, pudiendo así validar mejor los resultados y poder sacar conclusiones relevantes. Este paso es crucial ya que hay muchos artículos de los comentados que obvian este paso, induciendo así un sesgo en las conclusiones y limitando las posibilidades del estudio realizado.
- En cuanto a la tipología de los datos utilizados, estos son relevantes ya que al haber utilizado distintos *datasets* dependiendo de las enfermedades, pese a inducir un sesgo inevitable, también hace que el estudio deba tener en cuenta más factores, aumentando así el análisis que se realiza.
- Se han generado las bases de un asistente al diagnóstico médico de enfermedades neurológicas al haber conseguido replicar a pequeña escala una detección con precisión superior del 95% en alguno de los casos. Al no ser una clasificación binaria, entre enfermo o sano, se consigue establecer un modelo robusto de diagnóstico de las principales patologías neurológicas estudiadas.
- Se han utilizado distintos modelos de redes de neuronas, habiendo así tratado distintos tipos de arquitecturas convolucionales y de *transformers*. A esto se le suma el hecho de que se han tenido que hacer transformaciones de las imágenes para que los modelos pudieran usarlas.
- Se obtiene un análisis completo, a través de las conclusiones obtenidas, que no sirve solo de manera teórica, sino que se puede extrapolar al conocimiento

práctico aplicable en entornos sanitarios como hospitales y que puede ayudar a entender cómo funcionan estos modelos en casos en los que los datos sean heterogéneos.

Una conclusión general que se puede sacar de este trabajo es que hace falta una democratización de los modelos médicos especializados, ya que el hecho de que no la haya supone una barrera significativa a la hora de avanzar en este campo. La limitación de acceso a estos modelos, así como la dificultad de obtención de datos de estudio hace que se ralentice la investigación de este tipo de modelos en entornos reales.

Como trabajos futuros se podría tratar de replicar el presente trabajo disponiendo de un dataset con más clases de enfermedades neurológicas, con más imágenes por clase y tratando así de evitar el sesgo en el que se ha tenido que incurrir para desarrollar este estudio. De esta forma, y pudiendo plantear modelos actuales y específicos del sector médico, se conseguirían resultados a mayor escala y con una capacidad superior de aplicación real.

También se podría plantear el hecho de, dentro del propio asistente de diagnóstico, añadir técnicas avanzadas de *machine learning* para mejorar el diagnóstico de enfermedades mediante biomarcadores y así conseguir ayudar a todas las personas que las sufren.

Este trabajo sirve como evidencia de que las herramientas de inteligencia artificial pueden dejar de ser una caja negra, en la que no se entiende el proceso y se obtienen conclusiones sin explicación. Al confrontar cinco modelos distintos con siete clases de clasificación distintas, dependiendo de la enfermedad que se esté diagnosticando, se consigue apoyar a la detección de diagnósticos neurológicos complejos. Se ha logrado que este tipo de herramientas sean entendibles para un público más general mediante técnicas de explicabilidad, ahondando en el hecho de que no importa solo que los modelos acierten, sino que se comprendan sus resultados.

Se ha conseguido mostrar que la inteligencia artificial es aplicable y necesaria en entornos tan complejos y relevantes como es el ámbito sanitario, y concretamente el diagnóstico médico, pudiendo generar así un gran impacto en el.

5. BIBLIOGRAFÍA

- [1] R. Sharma, "CRISP-DM Explained: A Proven Data Mining Methodology," *Udacity Blog*, 13 de marzo de 2025. [En línea]. Disponible en: <https://www.udacity.com/blog/2025/03/crisp-dm-explained-a-proven-data-mining-methodology.html>.
- [2] A. A. Awan, "The Machine Learning Lifecycle," *KDnuggets*, 23 de septiembre de 2022. [En línea]. Disponible en: <https://www.kdnuggets.com/2022/06/making-sense-crispmlq-machine-learning-lifecycle-process.html>.
- [3] MLOps Guide, "CRISP-ML(Q). The ML Lifecycle Process," *ML-Ops.org*. [En línea]. Disponible en: <https://ml-ops.org/content/crisp-ml>.
- [4] S. Studer *et al.*, "Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology," *arXiv preprint arXiv:2003.05155*, 11 de marzo de 2020. [En línea]. Disponible en: <https://arxiv.org/pdf/2003.05155>.
- [5] Unión Europea, "Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas sobre inteligencia artificial (Ley de Inteligencia Artificial)," *Diario Oficial de la Unión Europea*, L 2024/1689, 12 de julio de 2024. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32024R1689>.
- [6] Intersoft Consulting, "General Data Protection Regulation (GDPR)," *GDPR Info*. [En línea]. Disponible en: <https://gdpr-info.eu/>.
- [7] Boletín Oficial del Estado, "Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales," *BOE*, núm. 294, ref. BOE-A-2018-16673, 6 de diciembre de 2018. [En línea]. Disponible en: <https://www.boe.es/buscar/doc.php?id=BOE-A-2018-16673>.
- [8] Comisión Europea, "Reglamento relativo al Espacio Europeo de Datos de Salud (EEDS)," *Salud Pública - Comisión Europea*. [En línea]. Disponible en: https://health.ec.europa.eu/ehealth-digital-health-and-care/european-health-data-space-regulation-ehds_es.
- [9] Unión Europea, "Regulation (EU) 2017/745 of the European Parliament and of the Council of 5 April 2017 on medical devices (Consolidated text)," *Official Journal of the European Union*, ref. 02017R0745-20260101, 1 de enero de 2026. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A02017R0745-20260101>.
- [10] V. Subramanian, "NVIDIA H200 Price Guide 2026: GPU Cost, Rental & Cloud Pricing," *JarvisLabs Blog*, 8 de enero de 2026. [En línea]. Disponible en: <https://docs.jarvislabs.ai/blog/h200-price>.

- [11] A. L. Samuel, "Some Studies in Machine Learning Using the Game of Checkers," *IBM Journal of Research and Development*, vol. 3, no. 3, pp. 210-229, julio de 1959. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/5392560>.
- [12] Y. LeCun, Y. Bengio, y G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436-444, mayo de 2015. [En línea]. Disponible en: <https://www.nature.com/articles/nature14539>.
- [13] A. Vaswani *et al.*, "Attention Is All You Need," *arXiv preprint arXiv:1706.03762*, jun. 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1706.03762>.
- [14] A. M. Turing, "Computing Machinery and Intelligence," *Mind*, vol. LIX, no. 236, pp. 433-460, octubre de 1950. [En línea]. Disponible en: <https://www.cs.mcgill.ca/~dprecup/courses/AI/Materials/turing1950.pdf>.
- [15] J. McCarthy, M. L. Minsky, N. Rochester, y C. E. Shannon, "A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence," *AI Magazine*, vol. 27, no. 4, pp. 12-14, agosto de 1955. [En línea]. Disponible en: <https://archive.computerhistory.org/resources/access/text/2023/06/102720392-05-01-acc.pdf>.
- [16] NASA, "What is Artificial Intelligence?," *NASA.gov*, 2024. [En línea]. Disponible en: <https://www.nasa.gov/what-is-artificial-intelligence/>.
- [17] W. S. McCulloch y W. Pitts, "A logical calculus of the ideas immanent in nervous activity," *The Bulletin of Mathematical Biophysics*, vol. 5, no. 4, pp. 115-133, diciembre de 1943. [En línea]. Disponible en: <https://link.springer.com/article/10.1007/BF02478259>.
- [18] Google Cloud, "What is Machine Learning?," *Google Cloud Learn*. [En línea]. Disponible en: <https://cloud.google.com/learn/what-is-machine-learning>.
- [19] F. Ramírez, "Historia de la IA: Frank Rosenblatt y el Mark I Perceptrón, el primer ordenador fabricado específicamente para crear redes neuronales en 1957," *Telefónica Tech Blog*, 20 de julio de 2018. [En línea]. Disponible en: <https://telefonicatech.com/blog/historia-de-la-ia-frank-roosenblatt-y-e>.
- [20] Y. Wu y J. Feng, "Development and Application of Artificial Neural Network," en *Artificial Neural Networks*, P. J. G. Lisboa, Ed. Londres, Reino Unido: IntechOpen, 2018, pp. 1-11. [En línea]. Disponible en: <https://link.springer.com/article/10.1007/s11277-017-5224-x>.
- [21] C. C. Aggarwal, *Neural Networks and Deep Learning: A Textbook*. Cham, Suiza: Springer International Publishing, 2018. [En línea]. Disponible en: <https://link.springer.com/book/10.1007/978-3-319-94463-0>.
- [22] D. O. Hebb, *The Organization of Behavior: A Neuropsychological Theory*. Nueva York, NY, EE. UU.: Psychology Press (Taylor & Francis), 2005. [En línea]. Disponible

en: <https://www.taylorfrancis.com/books/mono/10.4324/9781410612403/organization-behavior-hebb>.

[23] F. Rosenblatt, "The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain," *Psychological Review*, vol. 65, no. 6, pp. 386-408, noviembre de 1958. [En línea]. Disponible en: <https://homepages.math.uic.edu/~lreyzin/papers/rosenblatt58.pdf>.

[24] S. R. Alty y C. C. Took, "Widrow-Hoff LMS Adaline Demonstrator for Schools and Colleges," *IEEE-USA E-Books*, 2021. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/9454374>.

[25] M. L. Minsky y S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA, EE. UU.: MIT Press, 1969. [En línea]. Disponible en: <https://direct.mit.edu/books/monograph/3132/PerceptronsAn-Introduction-to-Computational>.

[26] T. Kohonen, *Self-Organizing Maps*, 3ª ed. Berlín, Alemania: Springer-Verlag, 2001. [En línea]. Disponible en: <https://books.google.es/books?id=M-zxCAAAQBAJ>.

[27] S. Grossberg, "Adaptive Resonance Theory: How a brain learns to consciously attend, learn, and recognize a changing world," *Neural Networks*, vol. 37, pp. 1-47, enero 2013. [En línea]. Disponible en: <https://doi.org/10.1016/j.neunet.2012.09.017>.

[28] J. J. Hopfield, "Hopfield network," *Scholarpedia*, vol. 2, no. 5, p. 1977, mayo 2007. [En línea]. Disponible en: http://www.scholarpedia.org/article/Hopfield_network.

[29] D. E. Rumelhart, G. E. Hinton, y R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, no. 6088, pp. 533-536, octubre 1986. [En línea]. Disponible en: <https://www.nature.com/articles/323533a0>.

[30] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, noviembre 1998. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/726791>.

[31] G. E. Hinton y R. R. Salakhutdinov, "Reducing the Dimensionality of Data with Neural Networks," *Science*, vol. 313, no. 5786, pp. 504-507, julio 2006. [En línea]. Disponible en: <https://www.cs.toronto.edu/~hinton/absps/science.pdf>.

[32] A. Krizhevsky, I. Sutskever, y G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," en *Advances in Neural Information Processing Systems (NIPS)*, vol. 25, F. Pereira, C. J. C. Burges, L. Bottou, y K. Q. Weinberger, Eds. Lake Tahoe, NV, EE. UU.: Curran Associates, Inc., 2012, pp. 1097-1105. [En línea]. Disponible en: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.

- [33] I. J. Goodfellow *et al.*, "Generative Adversarial Networks," 2014, *arXiv:1406.2661*. [En línea]. Disponible en: <https://arxiv.org/abs/1406.2661>.
- [34] A. Gu y T. Dao, "Mamba: Linear-Time Sequence Modeling with Selective State Spaces," 2023, *arXiv:2312.00752*. [En línea]. Disponible en: <https://arxiv.org/abs/2312.00752>.
- [35] A. Gu, K. Goel, y C. Ré, "Efficiently Modeling Long Sequences with Structured State Spaces," 2021, *arXiv:2111.00396*. [En línea]. Disponible en: <https://arxiv.org/abs/2111.00396>.
- [36] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929-1958, 2014. [En línea]. Disponible en: <https://jmlr.csail.mit.edu/papers/volume15/srivastava14a/srivastava14a.pdf>.
- [37] S. Salman y X. Liu, "Overfitting Mechanism and Avoidance in Deep Neural Networks," *arXiv:1901.05611*, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1901.05611>.
- [38] K. Kawaguchi, L. P. Kaelbling, y Y. Bengio, "Generalization in Deep Learning," *arXiv:1710.05468 [stat.ML]*, 2020. [En línea]. Disponible en: <https://arxiv.org/abs/1710.05468>.
- [39] M. S. Advani, A. M. Saxe, y H. Sompolinsky, "High-dimensional dynamics of generalization error in neural networks," *Neural Networks*, vol. 132, pp. 428-446, dic. 2020. [En línea]. Disponible en: <https://doi.org/10.1016/j.neunet.2020.08.022>.
- [40] G. J. Gardner y S. R. Dorling, "Artificial neural networks (the multilayer perceptron) — A review of applications in the atmospheric sciences," *Atmospheric Environment*, vol. 32, no. 14, pp. 2627-2636, ago. 1998. [En línea]. Disponible en: [https://doi.org/10.1016/S1352-2310\(97\)00447-0](https://doi.org/10.1016/S1352-2310(97)00447-0).
- [41] H. Ramchoun, M. A. J. Idrissi, Y. Ghanou, y M. Ettaouil, "Multilayer Perceptron: Architecture Optimization and Training," *International Journal of Interactive Multimedia and Artificial Intelligence*, vol. 4, no. 1, pp. 26-30, 2016. [En línea]. Disponible en: https://www.ijimai.org/journal/sites/default/files/files/2016/03/ijimai20164_1_4_pdf_13686.pdf.
- [42] K. Hornik, M. Stinchcombe, y H. White, "Multilayer feedforward networks are universal approximators," *Neural Networks*, vol. 2, no. 5, pp. 359-366, 1989. [En línea]. Disponible en: [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- [43] J. J. Hopfield, "Neural networks and physical systems with emergent collective computational abilities," *Proceedings of the National Academy of Sciences (PNAS)*, vol. 79, no. 8, pp. 2554-2558, abr. 1982. [En línea]. Disponible en: <https://www.pnas.org/doi/10.1073/pnas.79.8.2554>.

- [44] R. J. McEliece, E. C. Posner, E. R. Rodemich, y S. S. Venkatesh, "The capacity of the Hopfield associative memory," *IEEE Transactions on Information Theory*, vol. 33, no. 4, pp. 461-482, jul. 1987. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/1057328>.
- [45] J. J. Hopfield y D. W. Tank, "'Neural' computation of decisions in optimization problems," *Biological Cybernetics*, vol. 52, no. 3, pp. 141-152, jul. 1985. [En línea]. Disponible en: <https://doi.org/10.1007/BF00339943>.
- [46] P. Smolensky, "Information Processing in Dynamical Systems: Foundations of Harmony Theory," en *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations*, D. E. Rumelhart y J. L. McClelland, Eds. Cambridge, MA, EE. UU.: MIT Press, 1986, pp. 194-281. [En línea]. Disponible en: <https://scispace.com/pdf/information-processing-in-dynamical-systems-foundations-of-3hzuasvhos.pdf>.
- [47] D. H. Ackley, G. E. Hinton, y T. J. Sejnowski, "A learning algorithm for Boltzmann machines," *Cognitive Science*, vol. 9, no. 1, pp. 147-169, ene. 1985. [En línea]. Disponible en: [https://doi.org/10.1016/S0364-0213\(85\)80012-4](https://doi.org/10.1016/S0364-0213(85)80012-4).
- [48] G. E. Hinton, S. Osindero, y Y.-W. Teh, "A fast learning algorithm for deep belief nets," *Neural Computation*, vol. 18, no. 7, pp. 1527-1554, 2006. [En línea]. Disponible en: <https://www.cs.toronto.edu/~hinton/absps/fastnc.pdf>.
- [49] Y. Bengio, P. Lamblin, D. Popovici, y H. Larochelle, "Greedy layer-wise training of deep networks," en *Advances in Neural Information Processing Systems (NIPS)*, vol. 19, B. Schölkopf, J. Platt, y T. Hoffman, Eds. Cambridge, MA: MIT Press, 2007, pp. 153-160. [En línea]. Disponible en: https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf.
- [50] V. Dumoulin y F. Visin, "A guide to convolution arithmetic for deep learning," *arXiv preprint arXiv:1603.07285*, mar. 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1603.07285>.
- [51] K. O'Shea y R. Nash, "An introduction to convolutional neural networks," *arXiv preprint arXiv:1511.08458*, nov. 2015. [En línea]. Disponible en: <https://arxiv.org/abs/1511.08458>.
- [52] K. He, X. Zhang, S. Ren, y J. Sun, "Deep residual learning for image recognition," en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770-778. [En línea]. Disponible en: <https://arxiv.org/abs/1512.03385>.
- [53] M. Tan y Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," en *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019, pp. 6105-6114. [En línea]. Disponible en: <https://arxiv.org/abs/1905.11946>.

- [54] Z. Liu, H. Mao, C. Y. Wu, C. Feichtenhofer, T. Darrell, y S. Xie, "A ConvNet for the 2020s," en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 11976-11986. [En línea]. Disponible en: <https://arxiv.org/abs/2201.03545>.
- [55] I. D. Mienye, T. G. Swart, y G. Obaido, "Recurrent neural networks: A comprehensive review of architectures, variants, and applications," *Information*, vol. 15, no. 9, art. no. 517, sep. 2024. [En línea]. Disponible en: <https://doi.org/10.3390/info15090517>.
- [56] K. Aitken, V. V. Ramasesh, Y. Cao, y N. Maheswaranathan, "Understanding how encoder-decoder architectures attend," *arXiv preprint arXiv:2110.15253*, oct. 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2110.15253>.
- [57] O. Ronneberger, P. Fischer, y T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," en *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, vol. 9351, 2015, pp. 234-241. [En línea]. Disponible en: <https://arxiv.org/abs/1505.04597>.
- [58] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, y O. Ronneberger, "3D U-Net: Learning dense volumetric segmentation from sparse annotation," en *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2016, pp. 424-432. [En línea]. Disponible en: <https://arxiv.org/abs/1606.06650>.
- [59] D. Bank, N. Koenigstein, y R. Giryes, "Autoencoders," *arXiv preprint arXiv:2003.05991*, mar. 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2003.05991>.
- [60] D. P. Kingma y M. Welling, "Auto-encoding variational Bayes," *arXiv preprint arXiv:1312.6114*, dic. 2013. [En línea]. Disponible en: <https://arxiv.org/abs/1312.6114>.
- [61] M. Krichen, «Generative Adversarial Networks», en *2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, Delhi, India, 2023, pp. 1-7, [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/10306417>.
- [62] A. Radford, L. Metz, y S. Chintala, «Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks», *arXiv:1511.06434 [cs.LG]*, nov. 2015. [En línea]. Disponible en: <https://arxiv.org/abs/1511.06434>.
- [63] T. Lin, Y. Wang, X. Liu, y X. Qiu, «A Survey of Transformers», *arXiv:2106.04554 [cs.LG]*, jun. 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2106.04554>.
- [64] A. Dosovitskiy *et al.*, «An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale», *arXiv:2010.11929 [cs.CV]*, oct. 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2010.11929>.

- [65] Google DeepMind, «MedGemma: A collection of open models optimized for medical text and image comprehension», *DeepMind*, 2024. [En línea]. Disponible en: <https://deepmind.google/models/gemma/medgemma/>.
- [66] Google Health AI, «MedGemma», *Google for Developers*, 2024. [En línea]. Disponible en: <https://developers.google.com/health-ai-developer-foundations/medgemma>.
- [67] A. Steiner, A. Kolesnikov, X. Zhai, R. Wightman, J. Uszkoreit, y L. «How to train your ViT? Data, Augmentation, and Regularization in Vision Transformers», *arXiv:2106.10270 [cs.CV]*, jun. 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2106.10270>.
- [68] W. Maass, «Networks of spiking neurons: The third generation of neural network models», *Neural Networks*, vol. 10, n.º 9, pp. 1659-1671, dic. 1997, doi: 10.1016/S0893-6080(97)00011-7. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0893608097000117>.
- [69] F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, y G. Monfardini, «The Graph Neural Network Model», *IEEE Transactions on Neural Networks*, vol. 20, n.º 1, pp. 61-80, ene. 2009, doi: 10.1109/TNN.2008.2005605. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/4700287>.
- [70] M. M. Bronstein, J. Bruna, T. Cohen, y P. Veličković, «Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges», *arXiv:2104.13478 [cs.LG]*, may 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2104.13478>.
- [71] European Medicines Agency (EMA), «Artificial intelligence (AI)», *European Medicines Agency*, 2024. [En línea]. Disponible en: <https://www.ema.europa.eu/en/about-us/how-we-work/data-regulation-big-data-other-sources/artificial-intelligence>.
- [72] Organización Mundial de la Salud (OMS), «La OMS publica el primer informe mundial sobre inteligencia artificial aplicada a la salud y seis principios rectores para su diseño y utilización», *Noticias de la OMS*, 28 de junio de 2021. [En línea]. Disponible en: <https://www.who.int/es/news/item/28-06-2021-who-issues-first-global-report-on-ai-in-health-and-six-guiding-principles-for-its-design-and-use>.
- [73] U.S. Food and Drug Administration (FDA), «Artificial Intelligence-Enabled Medical Devices», *FDA*, 2024. [En línea]. Disponible en: <https://www.fda.gov/medical-devices/software-medical-device-samd/artificial-intelligence-enabled-medical-devices>.
- [74] EUCAIM, «European Federation for Cancer Images», *EUCAIM*, 2024. [En línea]. Disponible en: <https://cancerimage.eu/>.
- [75] Y. Yang *et al.*, «A comparative analysis of eleven neural networks architectures for small datasets of lung images of COVID-19 patients toward improved clinical decisions»,

Computers in Biology and Medicine, vol. 139, art. n.º 104887, dic. 2021, doi: 10.1016/j.compbio.2021.104887. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8461289/>.

[76] K. Simonyan y A. Zisserman, «Very Deep Convolutional Networks for Large-Scale Image Recognition», *arXiv:1409.1556 [cs.CV]*, sep. 2014. [En línea]. Disponible en: <https://arxiv.org/abs/1409.1556>.

[77] C. Szegedy *et al.*, «Going Deeper with Convolutions», *arXiv:1409.4842 [cs.CV]*, sep. 2014. [En línea]. Disponible en: <https://arxiv.org/abs/1409.4842>.

[78] O. Oktay *et al.*, «Attention U-Net: Learning Where to Look for the Pancreas», *arXiv:1804.03999 [cs.CV]*, abr. 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1804.03999>.

[79] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, y J. Liang, «UNet++: A Nested U-Net Architecture for Medical Image Segmentation», *arXiv:1807.10165 [cs.CV]*, jul. 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1807.10165>.

[80] F. Milletari, N. Navab, y S.-A. Ahmadi, «V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation», *arXiv:1606.04797 [cs.CV]*, jun. 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1606.04797>.

[81] F. Isensee *et al.*, "nnU-Net: Self-adapting Framework for U-Net-Based Medical Image Segmentation," *arXiv preprint arXiv:1809.10486*, 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1809.10486>.

[82] S. Chen, K. Ma, y Y. Zheng, "Med3D: Transfer Learning for 3D Medical Image Analysis," *arXiv preprint arXiv:1904.00625*, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1904.00625>.

[83] X. Mei *et al.*, "RadImageNet: An Open Radiologic Deep Learning Research Dataset for Effective Transfer Learning," GitHub, 2022. [En línea]. Disponible en: <https://github.com/BMEII-AI/RadImageNet>.

[84] J. Chen *et al.*, "TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation," *arXiv preprint arXiv:2102.04306*, 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2102.04306>.

[85] A. Hatamizadeh *et al.*, "UNETR: Transformers for 3D Medical Image Segmentation," *arXiv preprint arXiv:2103.10504*, 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2103.10504>.

[86] P. Rajpurkar *et al.*, "CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning," *arXiv preprint arXiv:1711.05225*, 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1711.05225>.

- [87] J. Irvin *et al.*, "CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison," arXiv preprint arXiv:1901.07031, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1901.07031>.
- [88] S. Zhang *et al.*, "BiomedCLIP: a multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs," arXiv preprint arXiv:2303.00915, 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2303.00915>.
- [89] A. Sellergren *et al.*, "MedGemma Technical Report," arXiv preprint arXiv:2507.05201, 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2507.05201>.
- [90] Thinking Stack, "A Comprehensive Guide to ResNet50: Architecture and Implementation," *Thinking Stack Blog*, 2024. [En línea]. Disponible en: <https://www.thinkingstack.ai/blog/business-use-cases-11/a-comprehensive-guide-to-resnet50-architecture-and-implementation-56>.
- [91] K. He, X. Zhang, S. Ren, y J. Sun, "Identity Mappings in Deep Residual Networks," arXiv preprint arXiv:1603.05027, 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1603.05027>.
- [92] S. Xie, R. Girshick, P. Dollár, Z. Tu, y K. He, "Aggregated Residual Transformations for Deep Neural Networks," arXiv preprint arXiv:1611.05431, 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1611.05431>.
- [93] G. Huang, Z. Liu, L. van der Maaten, y K. Q. Weinberger, "Densely Connected Convolutional Networks," arXiv preprint arXiv:1608.06993, 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1608.06993>.
- [94] G. Pleiss *et al.*, "Memory-Efficient Implementation of DenseNets," arXiv preprint arXiv:1707.06990, 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1707.06990>.
- [95] W. Chen *et al.*, "A robust approach for multi-type classification of brain tumor using deep feature fusion," *Frontiers in Neuroscience*, vol. 17, p. 1191060, jun. 2023. [En línea]. Disponible en: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2024.1288274/full>.
- [96] Gemma Team *et al.*, "Gemma: Open Models Based on Gemini Research and Technology," arXiv preprint arXiv:2403.08295, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2403.08295>.
- [97] F. Isensee, P. F. Jäger, S. A. A. Kohl, J. Petersen, y K. H. Maier-Hein, "Automated Design of Deep Learning Methods for Biomedical Image Segmentation," arXiv preprint arXiv:1904.08128, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1904.08128>.
- [98] A. G. Howard *et al.*, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," arXiv preprint arXiv:1704.04861, 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1704.04861>.

- [99] A. Erdoğan, "ConvNeXt — Next Generation of Convolutional Networks," *Medium*, 2024. [En línea]. Disponible en: <https://medium.com/@atakanerdogan305/convnext-next-generation-of-convolutional-networks-325607a08c46>.
- [100] J. Devlin, M. W. Chang, K. Lee, y K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," arXiv preprint arXiv:1810.04805, 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1810.04805>.
- [101] Z. Liu *et al.*, "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows," arXiv preprint arXiv:2103.14030, 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2103.14030>.
- [102] C. R. Jack Jr. *et al.*, "NIA-AA Research Framework: Toward a biological definition of Alzheimer's disease," *Alzheimer's & Dementia*, vol. 14, no. 4, pp. 535-562, abr. 2018. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S1552526018300724>.
- [103] R. B. Postuma *et al.*, "MDS clinical diagnostic criteria for Parkinson's disease," *Movement Disorders*, vol. 30, no. 12, pp. 1591-1601, oct. 2015. [En línea]. Disponible en: <https://movementdisorders.onlinelibrary.wiley.com/doi/10.1002/mds.26424>.
- [104] C. Lian, M. Liu, J. Zhang, y D. Shen, "Hierarchical Fully Convolutional Network for Joint Atrophy Localization and Alzheimer's Disease Diagnosis using Structural MRI," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 6, pp. 1418-1433, jun. 2020. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6588512/>.
- [105] A. J. Thompson *et al.*, "Diagnosis of multiple sclerosis: 2017 revisions of the McDonald criteria," *The Lancet Neurology*, vol. 17, no. 2, pp. 162-173, feb. 2018. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S1474442217304702>.
- [106] J. Krüger *et al.*, "Fully automated longitudinal segmentation of new or enlarged multiple sclerosis lesions using 3D convolutional neural networks," *NeuroImage: Clinical*, vol. 28, p. 102445, 2020. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S2213158220302825>.
- [107] A. J. C. Eijlers *et al.*, "Predicting cognitive decline in multiple sclerosis: a 5-year follow-up study," *Brain*, vol. 141, no. 9, pp. 2605–2618, sep. 2018. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/30169585/>.
- [108] T. Komori, "The 2021 WHO classification of tumors, 5th edition, central nervous system tumors: the 10 basic principles," *Brain Tumor Pathology*, vol. 39, no. 2, pp. 47–50, abr. 2022. [En línea]. Disponible en: <https://link.springer.com/article/10.1007/s10014-022-00428-3>.

- [109] S. Bakas *et al.*, "Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features," *Scientific Data*, vol. 4, p. 170117, sep. 2017. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/28872634/>.
- [110] K. Chang *et al.*, "Residual Convolutional Neural Network for the Determination of IDH Status in Low- and High-Grade Gliomas from MR Imaging," *Clinical Cancer Research*, vol. 24, no. 5, pp. 1073–1081, mar. 2018. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/29167275/>.
- [111] R. Goldbrunner *et al.*, "EANO guideline on the diagnosis and management of meningiomas," *Neuro-Oncology*, vol. 23, no. 11, pp. 1821–1834, nov. 2021. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/34181733/>.
- [112] D. Bouget, A. Pedersen, S. A. M. Hosainey, O. Solheim, e I. Reinertsen, "Meningioma Segmentation in T1-Weighted MRI Leveraging Global Context and Attention Mechanisms," *Frontiers in Radiology*, vol. 3, p. 1188445, jul. 2023. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/37492175/>.
- [113] O. Casar-Borota, P. Burman y M. B. Lopes, "The 2022 WHO classification of tumors of the pituitary gland: An update on aggressive and metastatic pituitary neuroendocrine tumors," *Journal of Internal Medicine*, vol. 296, no. 6, pp. 531–551, dic. 2024. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11669403/>.
- [114] B. H. M. van der Velden, H. J. Kuijf, K. G. A. Gilhuijs y M. A. Viergever, "Explainable artificial intelligence (XAI) in deep learning-based medical image analysis," *Medical Image Analysis*, vol. 81, p. 102528, oct. 2022. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S1361841522001177>.
- [115] M. Ghassemi, L. Oakden-Rayner y A. L. Beam, "The false hope of current approaches to explainable artificial intelligence in health care," *The Lancet Digital Health*, vol. 3, no. 11, pp. e745–e750, nov. 2021. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S2589750021002089>.
- [116] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," en *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2017, pp. 618–626. [En línea]. Disponible en: https://openaccess.thecvf.com/content_ICCV_2017/papers/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.pdf.
- [117] S. M. Lundberg y S. I. Lee, "A unified approach to interpreting model predictions," en *Proc. 31st Int. Conf. Neural Inf. Process. Syst. (NIPS)*, 2017, pp. 4765–4774. [En línea]. Disponible en: <https://proceedings.neurips.cc/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf>.

- [118] S. Abnar y W. Zuidema, "Quantifying Attention Flow in Transformers," en *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 4190–4197. [En línea]. Disponible en: <https://arxiv.org/abs/2005.00928>.
- [119] J. R. Geis *et al.*, "Ethics of Artificial Intelligence in Radiology: Summary of the Joint European and North American Multisociety Statement," *Radiology*, vol. 293, no. 2, pp. 436–440, nov. 2019. [En línea]. Disponible en: <https://pubs.rsna.org/doi/full/10.1148/radiol.2019191586>.
- [120] C. J. Kelly, A. Karthikesalingam, M. Suleyman, G. Corrado y D. King, "Key challenges for delivering clinical impact with artificial intelligence," *Nature Medicine*, vol. 25, no. 10, pp. 1454–1456, oct. 2019. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/31665002/>.
- [121] J. R. Zech *et al.*, "Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study," *PLOS Medicine*, vol. 15, no. 11, p. e1002683, nov. 2018. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/30399157/>.
- [122] S. G. Finlayson, J. D. Bowers, J. Ito, J. L. Zittrain, A. L. Beam e I. S. Kohane, "Adversarial attacks on medical machine learning," *Science*, vol. 363, no. 6433, pp. 1287–1289, mar. 2019. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/30898923/>.
- [123] A. Fatahi, "Multi-Class Neurological Disorder (MCND) Dataset," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/alifatahi/multi-class-neurological-disorder-mcnd-dataset>.
- [124] S. Vaghasiya, "NTUA-Parkinson Dataset," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/shayalvaghasiya/ntua-prakinson>.
- [125] O. Orvile, "Multiple Sclerosis Brain MRI Lesion Segmentation," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/orvile/multiple-sclerosis-brain-mri-lesion-segmentation>.
- [126] A. Morales Valverde, "paso_nii_a_jpg.py," *GitHub*, 2025. [En línea]. Disponible en: https://github.com/AngelaMoralesValverde/Medic_Models/blob/main/paso_nii_a_jpg.py.
- [127] O. Orvile, "Brain Cancer MRI Dataset," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/orvile/brain-cancer-mri-dataset>.
- [128] R. Mandal, "Brain Tumor (MRI Scans) Dataset," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/rm1000/brain-tumor-mri-scans>.
- [129] S. M. Hossein y Hashemi, "Crystal Clean: Brain Tumors MRI Dataset," *Kaggle*, 2024. [En línea]. Disponible en: <https://www.kaggle.com/datasets/mohammadhossein77/brain-tumors-dataset>.

[130] A. Morales Valverde, "prep_dataset.py," *GitHub*, 2025. [En línea]. Disponible en: https://github.com/AngelaMoralesValverde/Medic_Models/blob/main/prep_dataset.py.

[131] A. Morales Valverde, "Medic_Models.ipynb," *GitHub*, 2024. [En línea]. Disponible en: https://github.com/AngelaMoralesValverde/Medic_Models/blob/main/Medic_Models.ipynb.

[132] A. Morales Valverde, "BrainDiseaseDetection.ipynb," *GitHub*, 2024. [En línea]. Disponible en: https://github.com/AngelaMoralesValverde/Medic_Models/blob/main/BrainDiseaseDetection.ipynb.

[133] Google, "Gemini," *Google AI*, 2026. [En línea]. Disponible en: <https://gemini.google.com>.

6. ANEXOS

6.1. Anexo A. Declaración del uso de IA

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL GENERATIVA (IAG) EN EL TRABAJO DE FIN DE GRADO (TFG)

He usado IAG en mi TFG

Marca lo que corresponda:

<u>SI</u>	NO
-----------	----

Si has marcado SI, completa las siguientes 3 partes de este documento:

Parte 1: declaración sobre comportamiento legal, ético y responsable

Ten presente que el uso de IAG conlleva unos riesgos y puede generar una serie de consecuencias académicas graves: la evaluación de tu TFG puede verse comprometida si el uso de la IAG comporta la utilización de datos de carácter confidencial, materiales protegidos por derechos de autoría, o datos de carácter personal, y se hace sin cumplir las condiciones exigidas en cada caso (autorización de los interesados, autorización de los titulares, seguimiento de las instrucciones de la Universidad).

Pregunta	
1. En mi interacción con herramientas de IAG he facilitado datos de carácter confidencial contando siempre con la debida autorización de los interesados. La confidencialidad abarca toda información que una persona u organización desea proteger por razones legales, comerciales, de privacidad o estratégicas (como patentes o secretos comerciales).	
SÍ, he usado estos datos con la autorización de los interesados	<u>NO, no he usado datos de carácter confidencial</u>
2. En mi interacción con herramientas de IAG he facilitado materiales protegidos por derechos de autoría contando siempre con la autorización de los respectivos titulares.	
SÍ, he usado estos materiales con autorización de los titulares de derechos de autor; o bien sin ella porque se ajustan a una de las excepciones o límites que permite la ley: ● obra en dominio público ● obra licenciada (licencias Creative Commons) ● uso de fragmentos con fines de investigación (derecho de cita)	<u>NO, no he usado materiales protegidos por derechos de autoría</u>

3. En mi interacción con herramientas de IAG he facilitado datos de carácter personal con la debida autorización de los interesados.	
SÍ, he usado estos datos con autorización de los interesados y conforme a las instrucciones contenidas en la guía aprobada por la Universidad	<u>NO, no he usado datos de carácter personal</u>
4. Mi utilización de la herramienta de IAG ha respetado sus términos de uso , así como los principios éticos esenciales, no orientándola de manera maliciosa a obtener un resultado inapropiado para el trabajo presentado, es decir, que produzca una impresión o conocimiento contrario a la realidad de los resultados obtenidos, que suplante mi propio trabajo o que pueda resultar en un perjuicio para las personas.	
<u>SI</u>	NO

Parte 2: declaración de uso técnico

Utiliza el siguiente modelo de declaración tantas veces como sea necesario, a fin de reflejar todos los tipos de iteración que has tenido con herramientas de IAG. Incluye un ejemplo por cada tipo de uso realizado donde se indique: *[Añade un ejemplo]*.

Declaro haber hecho uso del sistema de IAG ChatGPT-5.2 y Gemini 3 para:

Documentación y redacción:

- *Soporte a la reflexión en relación con el desarrollo del trabajo: proceso iterativo de análisis de alternativas y enfoques utilizando la IAG*

N/A

- *Revisión o reescritura de párrafos redactados previamente*

N/A

- *Búsqueda de información o respuesta a preguntas concretas*

Dentro del proceso de investigación sobre los temas abordados en el trabajo, se ha utilizado la IAG para la búsqueda de conocimiento como, por ejemplo, de las enfermedades que se exponen en este documento. También para realizarle preguntas concretas sobre el funcionamiento de algunos modelos.

- *Búsqueda de bibliografía*

Al comenzar el trabajo, en una primera fase de investigación general sobre el panorama en

el que se iba a centrar el estudio, pregunté a la IAG sobre las fuentes más relevantes de estudios que tuviesen que ver con la investigación realizada en este proyecto.

- *Resumen de bibliografía consultada*
- *Traducción de texto consultados*

Desarrollar contenido específico

Se ha hecho uso de IAG como herramienta de soporte para el desarrollo del contenido específico del TFG, incluyendo:

- *Asistencia en el desarrollo de líneas de código (programación)*

Le he pedido ayuda para entender algunas cosas dentro de la depuración del código de los modelos que he aplicado

- *Generación de esquemas, imágenes, audios o vídeos*

N/A

- *Procesos de optimización*

En casos en los que me daba un error, le he pedido ayuda a la IAG para optimizar mi código y mejorar su rendimiento

- *Tratamiento de datos: recogida, análisis, cruce de datos...*

N/A

- *Inspiración de ideas en el proceso creativo*

N/A

- *Otros usos vinculados a la generación de puntos concretos del desarrollo específico del trabajo*

Si crees necesario incluirlo, añade, en cada uno de los casos:

empleando el prompt ... (escribe la petición realizada a la IAG)

teniendo como interacción ... (describe qué interacción realizaste con la IAG tras la respuesta del prompt)

Ejemplo: **Declaro haber hecho uso del sistema de IAG Chat GPT 3.5 para buscar información empleando el prompt: “Dime un ejemplo concreto que ilustre la**

aplicación de la propuesta urbanística de la Ciudad de los 15 minutos en España” teniendo como interacción la proposición del ejemplo concreto del distrito de Chamartín que se ha reflejado en la memoria.

Parte 3: reflexión sobre utilidad

Aporta una valoración personal (formato libre) sobre las fortalezas y debilidades que has identificado en el uso de herramientas de IAG en el desarrollo de tu trabajo. Menciona si te ha servido en el proceso de aprendizaje, o en el desarrollo o en la extracción de conclusiones de tu trabajo.

En proyectos tan extensos como este, en el que se necesita tener un conocimiento amplio del entorno antes de empezar a desarrollar nada, el hecho de poder contar con la IAG es una ventaja considerable. En vez de tener que ir buscando información una a una, con su uso, se es capaz de retener y comprender mucha más información en un menor tiempo, agilizando así el desarrollo y permitiendo que se puedan centrar los esfuerzos en la base técnica y teórica de lo que se está haciendo en vez de en obtener la información.

Gracias, por ejemplo, al uso de la IAG para depurar y comprender mejor el código que se va elaborando, se puede emplear el tiempo en conseguir los mejores resultados posibles, en este caso de los modelos.


Como desventaja cabe destacar que, aunque la capacidad de conocimiento que aporta es innegable, siempre debe haber un pensamiento crítico detrás que vaya cuestionando las respuestas. Por ejemplo, cuando se trata del código, es importante tener el conocimiento técnico uno mismo claro, ya que estos modelos de IAG carecen del contexto y de las necesidades que se tienen cuando se desarrolla el proyecto.

6.2. Anexo B. Declaración de originalidad

Yo,**Ángela Morales Valverde**..... declaro que el TFG "**.....Asistente de detección de enfermedades cerebrales con imágenes y datos médicos.....**" es totalmente original mío, que no ha sido presentado en ninguna otra universidad como TFG y que todas las fuentes que han sido utilizadas han sido adecuadamente citadas y aparecen en las referencias bibliográficas.

Getafe/Colmenarejo, a12 de febrero de 2026.....

Firma: Ángela Morales Valverde

A handwritten signature in black ink, appearing to read 'Ángela M.', with a stylized flourish at the end.